

中国人工智能学会通讯



- 度量学习研究进展
- 基于图的半监督学习理论及其应用
- 网络数据结构特征研究
- 生物序列的特征化描述方法

12 期

2017年 第7卷

中国人工智能学会主办

 Hazzi 哈智

人工智能

科技不仅改变生活，更可成为艺术。

杭州哈智机器人有限公司

机器人/人工智能/智能语音助手
云计算/大数据时代





本刊声明

本通讯刊登的文章仅反映作者的观点，不代表本刊立场。其原创文章转载，请申请授权，并注明出处。

目 录 |

► 01 机器学习技术专题

前言·····	张敏灵	01
度量学习研究进展·····	叶翰嘉，詹德川	02
基于图的半监督学习理论及其应用 ·····	苏航，董胤蓬，胡文波	09
网络数据结构特征研究 ·····	范长俊，程光权，黄金才，刘忠	17
生物序列的特征化描述方法·····	何文颖，邹权	29
面向大规模数据的高斯过程机器学习模型研究进展 ·····	贺建军，许小可	36

► 02 学会优博获奖论文精华版

面向用户消费行为理解的数据挖掘方法研究·····	吴乐	43
个性化推荐的可解释性研究·····	张永锋	52

• 简 讯 •

2017世界智能制造大会——制造业+人工智能技术论坛 顺利召开·····		60
中国人工智能学会与罗兰贝格联合发布 《中国人工智能创新应用白皮书》·····		60



中国人工智能学会通讯

第7卷 第12期

2017年12月31日出版

本刊声明

本通讯刊登的文章仅反映作者的观点，不代表本刊立场。其原创文章转载，请申请授权，并注明出处。

中国人工智能学会通讯



主 办

中国人工智能学会

主 编

李德毅（CAAI理事长，中国工程院院士）

执行主编

马少平（CAAI副理事长，清华大学教授）

副 主 编

王国胤（CAAI副理事长，重庆邮电大学教授）

王卫宁（CAAI秘书长，北京邮电大学研究员）

委 员（按姓氏拼音排序）

曹 鹏	陈 杰	董振江	杜军平	桂卫华
韩力群	何 清	黄河燕	黄心汉	贾英民
蒋昌俊	焦李成	李 斌	李德毅	刘 宏
刘 民	刘成林	刘增良	鲁华祥	马华东
马少平	马世龙	苗夺谦	朴松昊	乔俊飞
任福继	任友群	孙富春	孙长银	谭铁牛
王 轩	王飞跃	王国胤	王捍贫	王万森
王卫宁	王小捷	王亚杰	王志良	吴朝晖
吴晓蓓	夏桂华	严新平	杨 强	杨春燕
杨放春	余 凯	余有成	张学工	赵春江
周志华	祝烈煌	庄越挺		

编 辑 部

主 任：孙伟玲

副 主 任：刘奕群

责任编辑：于 蕙

通讯地址：北京市海淀区西土城路10号 北京邮电大学167信箱

电 话：010-62283663

电子信箱：msc@caai.cn

网 址：http://caai.cn

创刊日期：2011年

主办单位：中国人工智能学会

编辑出版：中国人工智能学会通讯编辑部

印 刷：北京金龙传奇印刷技术有限公司

张敏灵

依托中国人工智能学会机器学习专业委员会，邀请了来自南京大学、清华大学、国防科技大学、天津大学、大连民族大学的多位优秀青年学者撰写专题稿件。专题内容涉及机器学习理论方法和技术应用的若干方面，包括度量学习、半监督学习、特征学习、贝叶斯学习、机器学习在生物信息学中的应用等。专题论文在介绍相关领域最新研究进展基础上，还对未来进一步的工作进行了展望。希望本专题内容对机器学习及相关领域的研究者有所裨益。



东南大学计算机学院教授。中国人工智能学会机器学习专业委员会秘书长，江苏省人工智能学会学术工作委员会主任。主要研究领域为机器学习、数据挖掘。



研究进展

叶翰嘉，詹德川

南京大学

摘要：距离是人类在对对象的感知过程中极为重要的一个因素，距离刻画出对象之间的关系。度量学习源于对对象间关系的利用。这种弱监督信息不但在大多数情况下能够广泛获取，也描述了对象之间的高阶语义。通过学习对象之间的距离或相似度，度量学习能够用于分析对象之间的关联、比较关系；同时，在利用对象关系的过程中，能够辅助挖掘有效的对象表示，以及对象之间的语义关系，为后续任务提供帮助。结合度量学习在科研领域的广泛研究，本文对度量学习的研究进展进行总结，并介绍前沿方向的研究动态。

度量学习简介

度量对象之间距离的方法有很多，给定一组对象的特征表示，欧式距离、汉明距离等多种度量方式，都可以给出一个反映其相似、不相似关系的数值。在许多问题中，关注的是一组而非单个对象的关系。如在聚类问题中，关注的是同簇样本的内聚性；在核方法中，需要反映样本之间相似度的核矩阵；在索引问题中，优先输出距离最接近的样本。单一形式的距离无法直接应用于所有实际问题中，距离本身的定义可能也存在欠缺（如欧氏距离中假设所有特

征权重相等，特征之间互不相关），因此，度量学习研究考虑从数据中根据指示信息学习出有效的距离度量，学习到的度量或产生的对象表示用于辅助目标问题。

度量学习方法最初在文献 [1] 中提出，提供弱监督信息，即给出每一对输入的样本之间相似或不相似的标记，定义 d 维学习样本 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的（平方化）马氏距离 $d_M^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^T \mathbf{M} (\mathbf{x} - \mathbf{y})$ ，使得相似样本之间的马氏距离较小，而不相似样本之间的马氏距离较大。 $\mathbf{M} \in S_+^d$ 为 $d \times d$ 维半正定矩阵。学到的马氏距离可用于聚类，针对于使用

欧氏距离的聚类效果有明显的提升。马氏距离考虑了特征之间的关联性以及权重，由于其形式简单，在优化问题中容易规划为凸问题，在后续工作中被广泛使用。距离度量一般需要满足4个条件，即非负、对称、自反与三角不等式关系。使用马氏距离获得的度量由于矩阵 M 的半正定性一般不满足自反性，因此，将学到的距离 d_M 称作伪距离度量。在学习过程中，考虑到距离度量的单调性，一般优化平方化之后的马氏距离 d_M^2 简化整体形式，后文中的马氏距离都特指平方之后的马氏距离。文献[1]中使用所有样本构成二元组会生成大量的约束，增加计算负担同时也会存在冗余。因此，后续的一些工作，在学习马氏距离的同时，也尝试不同的指导信息的形式。如在文献[2]中，提出使用三元组作为监督信息。在第 t 个三元组 (x', y', z') 中，以 x' 为中心， y' 与 x' 接近，而 z' 与 x' 不相似。在这种指示下，令 x' 和 z' 之间的马氏距离大于 x' 和 y' 之间的马氏距离。文献[2]提出 Large Margin Nearest Neighbor (LMNN) 在要求距离度量满足此种约束之外，还要求保持一个间隔来增强泛化性，在生成三元组的过程中，令 y' 是 x' 的同类欧氏距离近邻，而 z' 是异类欧氏距离近邻。文献[3]提出 Information Theoretical Metric Learning (ITML) 使用随机抽样的二元组进行指导，并提出一种关于度量矩阵的正则化方法，基于信息论的观点，该正则化方法结合对应的优化方法使度量矩阵自动满足半正定约束，而避免半正定投影过程。更高阶的信息在度量学习中也被使用，如文献[4]中提出四元组关系 (x', y', z', w') ，即 (x', y') 之间的距离和 (z', w') 之间的距离存在比较关系。这种样本对之间的比较关系形式常用于检

索过程中，也常用于复杂类别样本之间的关系刻画。文献[5]将四元组关系扩展为类比关系，令 (x', y') 与 (z', w') 之间的距离关系一致， (x', y') 与 (z', w') 之间的关系一致。这种利用距离关系指导度量学习的方法可以被概括为通用的形式^[6]，度量学习的理论分析有文献[7-8]。

由于 $(x-y)^T M (x-y) = \|L^T(x-y)\|_F^2$ ，其中 $M = LL^T$ 马氏距离下的度量学习一般会转化为针对样本投影矩阵的学习， $L \in \mathbb{R}^{d \times d}$ 虽然造成问题非凸，但降低了计算开销，一般也能得到较好的效果^[2]。除了马氏距离，度量学习研究也常被扩展到其他非线性形式。如可以同时学习多个不同的距离度量^[9]，使用树形结构生成特征表示辅助度量学习^[10]，或利用深度网络结构生成特征表示，在顶层使用度量约束指导所学特征之间欧氏距离的关系^[11]。学习到的有效的距离可用于后续问题，如分类中，使用近邻分类方式，配合所学的距离。

度量学习前沿进展

度量学习在实际问题中应用广泛。除了使用已有的度量辅助近邻分类与聚类问题，也广泛用于图像检索^[12]、人物识别^[13]、跨领域物体识别^[14]、网络关系学习^[15-16]等领域。当前对度量学习的前沿研究主要包含以下一些领域：考虑对多个度量的学习，增强度量的表示能力；将度量学习用于复杂环境，挖掘对象之间的深层关系；学习鲁棒的度量表示；优化度量学习的训练过程。下文对这些方向分别进行介绍。

多度量学习

由于基于马氏距离的度量学习本身可

以看作在使用投影矩阵 $\mathbf{L}$ 进行线性变换之后, 使用欧氏距离度量样本关系, 因此, 通过投影学到的表示和原始表示相比是一种线性变换关系。为了构建非线性的度量关系, 可以在空间中使用多个度量, 不同的局部区域使用不同的度量度量距离。相比于全局度量学习与非线性树形、深度度量学习, 这种方式在计算复杂度和模型表示程度之间进行权衡。如在文献 [2] 中提出 LMNN 的多度量扩展, 针对每一个簇学习一个度量, 在有新样本时使用训练集中所有样本隶属的度量计算对应的距离进行评测。多度量的方案也能够扩展到为每一个样本学习一个度量, 但这种方式往往需要在训练过程中包含所有测试样本, 增加复杂度并容易过拟合^[17]。文献 [9] 中提出一种组合求解方式 Sparse Compositional Metric Learning (SCML), 即通过训练数据预先生成一组基, 并假设多个度量矩阵均通过这组基加权求和构成。不同局部区域的样本和对应基的系数之间建立不同的参数化映射, 通过优化参数映射的系数使得不同的样本具有不同的度量, 并能够确定新样本的度量。鉴于参数化映射无法适用于所有情况, 文献 [18] 提出 Instance Specific METric Subspace (IsMets), 利用贝叶斯方式为每一个样本构建子空间。具有 N 个样本的训练数据 X 中, 样本 x_n 在度量矩阵 $\mathbf{M}_{x_n}$ 与其余 $N-1$ 个样本 x_{-n} 下产生的概率可定义为 $\frac{1}{N-1} \sum_{i \neq n} \mathcal{N}(x_n | x_i, \mathbf{M}_{x_n}^{-1})$, 即样本度量的选择可以放置在对度量产生的特定子空间中, 并用高斯分布 $\mathcal{N}$ 进行刻画。对子空间的选择可以使用多项分布 z_{nk} 进行描述, 即样本在局部度量集合 $\mathcal{M}$ 和子空间指示变量 Z 下的条件分布为

$$\begin{aligned} p(X|Z, \mathcal{M}) &= \prod_{n=1}^N p(x_n | \mathcal{M}) \\ &= \prod_{n=1}^N \prod_{k=1}^K p(x_n | M_{x_n}, z_{nk})^{z_{nk}} \end{aligned}$$

假设度量从 Wishart 分布抽样, 再建立到标记变量的映射, 最终可通过变分的方式推断出每个样本的度量分布; 同时对于新的样本, 也可以进行推断。

复杂语义度量学习

对象本身属性的复杂性造成对象之间的关系可能包含对象之间的多个潜在联系, 并具有歧义信息。如社交网络中, 用户之间好友关系的构成可能有多种不同因素。同一个用户和其他多个用户的相似好友关系的构成原因可能各不相同; 评分系统中用户对商品的较低评价可能只是由于商品的某个因素, 而不能全盘否定用户和商品的联系。现有的大多数方法认为对象关系的表示是固定单一的, 以及两个对象之间的相似、不相似关系的构成只有一种可能的原因^[15]。文献 [16] 工作中强调对给定对象关系中模糊语义的多样化处理, 挖掘对象在不同层面多义性的表现, 提出 Unified Multi-Metric Learning (UM²L) 框架 (见图 1)。首先, 考虑多个度量关系对应多种可能的语义 $\mathcal{M}=\{M_1, M_2, \dots, M_K\}$, 因此, 对象之间的关系可以用多个距离 $d_{M_1}^2, d_{M_2}^2, \dots, d_{M_K}^2$ 进行描述; 其次, 使用算子映射 κ 将多个距离结合为反映样本关系的综合相似度表示 $f=\kappa(-d_{M_1}^2, -d_{M_2}^2, \dots, -d_{M_K}^2)$ 。利用给定的 T 个三元组模糊关系约束 $\mathcal{T}=\{(x^t, y^t, z^t)\}_{t=1}^T$ 综合距离之间的关系。通过选择不同形式的映射算子, 同一个目标能够反映出对象之间的复杂关系, 如下:

$$\min_{\mathcal{M}_k} \frac{1}{T} \sum_{t=1}^T \ell(f_1(x^t, y^t) - f_{-1}(x^t, z^t)) + \lambda \sum_{k=1}^K \Omega_k(M_k)$$

式中, $\ell(\cdot)$ 为非负损失函数, 输入值越大损

失越小； $f_{l/-1}$ 表示使用不同的算子得到的综合相似度； Ω_k 表示针对每一个度量矩阵的正则项； λ 是非负权重。上述公式统一了对象之间的多种复杂关系。如当两个算子都为max算子时，目标函数保证相似的两个样本只在某个距离度量下相似，而不相似的两个样本在所有距离度量下都不相似，

这种关系满足在异构社交网络中用户之间的关系；而当算子分别取min和max时，目标函数使相似样本的距离在所有的度量语义上都比不相似的距离要小，可用于对象之间的关联性在不同模态之间的保持。这种算子也可以扩展到更复杂的核形式，或用于统一已有的一些经典方法。




图1 UM²L方法主要思想，使用多个度量刻画潜在的多个语义成分，对象之间关系的复杂性表现在不同的语义分量中。最终使综合的度量关系与给定的指示信息一致

以往的多度量学习方法假设不同局部的样本具有不同度量，因此每一个样本只包含一个度量。UM²L方法中每一个度量的应用范围扩展至所有样本，因此每一对样本关系都可以用多个度量关系刻画，使模型能够刻画样本之间的多样化语义。该框架具有统一的优化形式，并有理论保证。在应用过程中，以往的方法专注于分类等任务，将训练得到的多个模型进行融合^[9]。文献[16]工作在模型的测试阶段，不但考虑使用模型的融合应对单一判定的任务，也考虑利用不同语义的模型在多个语义层面上对不同对象进行分析。因此在测试过程中分两种不同情况考虑。首先，在分类问题中，结合学习到的多个语义下的度量，计算相似性后找到不同的候选集，在候选集中做进一步相似性度量处理；其次，学到的多个不同语义下的度量可以用作社交

群体发现（使用不同的度量分别计算样本之间的相似度，同一种相似度下相近的对象视为当前语义下的近邻）、异构特征分解（根据学到的多语义度量对应的特征对高维特征进行分解）、图像隐藏信息挖掘（对象在未指定的语义度量下通过近邻关系判定是否有缺失的语义信息）、复杂语义推荐（根据用户的信息展现不同语义下的商品做推荐）等。

鲁棒度量学习

在度量学习方法中，指导约束信息的获取是算法的关键组成部分。在某些场合下会考虑使用样本的类别信息生成样本之间的比较关系。如使用欧氏距离作为先导进行选取或随机选取。这种选取方式可能导致指导信息不吻合最终度量的需要，在已有的方法中，一般使用多阶段方法不断利

用上一轮学到的度量指导约束当前阶段样本对的选取^[2]，或利用优化策略在所有可能的相似样本集合中进行选择^[19]。

大多数度量学习方法通过样本的原始特征，以及提供的辅助连接信息获取度量，而忽视了特征与辅助信息的可信度。样本上的噪声或扰动能够改变样本间的关系，从而影响度量的学习。文献[20]中提出在学习度量过程中，显式考虑样本的扰动能够帮助学到鲁棒的度量矩阵，并且提出 Distance metric learning Facilitated by disTurbances (DRIFT) 方法。该方法中，将每个样本的噪声或扰动视作随机分布，在考虑分布的前提下度量样本之间的期望距离。在期望距离中，样本的扰动可以等价转化为在近邻样本上增加无偏扰动 $\epsilon \in p_i(\epsilon)$ 。假设有 $\hat{y}^t = y^t + \epsilon$ ，样本间的期望距离可表示为 $\mathbb{E}_\epsilon[d_M^2(x, \hat{y})] = d_M^2(x, y) + \mathbb{E}_\epsilon[\epsilon^T M \epsilon]$ 。目标函数中，使用期望距离满足相似约束的条件，并用 KL 散度正则近邻样本扰动分布 $p_i(\epsilon)$ 的与其先验 $p_0(\epsilon)$ ，从而更好地估计度量矩阵

$$\min_{M, p_i} \|M\|_F^2 + \lambda_1 \sum_{i=1}^N \text{KL}(p_i(\epsilon) \| p_0(\epsilon)) + \lambda_2 \sum_{t=1}^T \ell(d_M^2(x^t, z^t) - \mathbb{E}_\epsilon[d_M^2(x^t, \hat{y}^t)])$$

优化目标中，一方面使用期望距离在优化过程中将相似区域尽可能扩张，从而加大模型的适用范围，增强鲁棒性；一方面，由于考虑每一个样本的扰动分布，对于离群点或者错误选择的指导信息，会自动给予较低的权重，在整体过程中进行忽略。因此，该方法能够更好地利用辅助信息，从而学习鲁棒的度量。实验中，当给定的三元组中一部分相似、不相似关系被人工倒置之后，一般的度量学习方法会在错误

的指导下得到较差的解，使整体性能下降；DRIFT 方法在此情况下能够不受影响，甚至取得更好的结果。DRIFT 的主要思想如图 2 所示。




图2 DRIFT 方法主要思想，考虑相似近邻的期望距离，相当于在相似近邻上增加扰动。在优化过程中，扩展了相似近邻的范围，增强度量的鲁棒性

高效度量学习

由于度量学习通过样本对指导模型的训练，因此当样本数目很大时，针对样本对的关系优化会造成巨大的优化开销。考虑到大量的样本对，一般会使用随机优化的方法，每次抽取一个样本对进行优化^[21]。文献[18]中基于贝叶斯思路，提出一种只利用样本标记信息的训练思路，但在训练样本子空间的过程中能够考虑样本之间的关系；在文献[22]中也提出过利用类别中心的方法，使样本和对应的聚类中心接近来减少约束数目。

除了约束数目，度量学习的优化问题也要考虑特征维度。由于考虑到特征之间的关系，因此一般优化的度量矩阵都是特征维度的平方级别。除了使用投影替代度量矩阵，也可以在矩阵上附加低秩约束来减轻计算负担^[23]；或使用稀疏假设，在优化过程中增进式学习各个元素^[9,24]。在文献[25]工作中提出 Feature Aware Metric Learning (FARM)，将度量矩阵分解为对角矩阵和完整矩阵的乘积。即 $M = \text{diag}(w) \hat{M} \text{diag}(w)$ 。

$$\min_{\mathbf{M}, \mathbf{w}} \sum_{t=1}^T \ell(\mathbf{d}_M^2(x^t, z^t) - \mathbf{d}_M^2(x^t, y^t)) + \lambda_1 \Omega(\hat{\mathbf{M}}) + \lambda_2 \|\mathbf{w}\|_1$$

对角矩阵中的向量 $\mathbf{w}$ 假设为稀疏，用于选择特征；而完整矩阵 $\hat{\mathbf{M}}$ 用于刻画特征之间的相关性。通过施加不同的正则项，可以使得度量具有不同的结构性质。如当 Ω 为核范数时，最终的度量为分块对角矩阵。在优化过程中，使用迭代方法求解，当对角矩阵选择出合适的特征之后，在后续过程中只要关注剩余部分的特征即可，因此降低了整个优化过程的计算负担。同时，由于在度量学习过程中考虑了特征选择，该方法也能够识别出特征中存在的噪声，在一定程度上增强了模型的鲁棒性。

深度度量学习

度量学习也可以利用深度网络对特征抽取的能力，以及端到端的训练范式来取得更好的效果。针对某个二元组、三元组中不同的样本，其对应的深度网络之间会

共享参数^[26]，并在最后一层计算样本间的欧氏距离来度量特征表示的优劣。不同的损失函数能够考虑样本之间的异构性^[27]，类别之间的差异性^[28]，以及更全面地利用当前通过网络的本样本^[29-30]。学到的特征表示可以用于图像细粒度分类^[28]、聚类^[29-30]，人脸识别^[27]等任务。

结束语

度量学习考虑通过距离度量的方式刻画对象之间的相关、比较关系。基于样本之间关系的指导信息，度量学习能够得到对象的有效表示，使得相似的样本距离较小，而不相似的样本距离较大。在后续的研究中，度量学习可能在复杂环境的应用中会更加广泛，如潜在的样本分布发生变化，以及类别、特征变化等情形^[31]。在学习度量时也应该考虑重用相关任务中学到的度量结果，简化当前任务的复杂度。

参考文献

- [1] E. P. Xing, A. Y. Ng, M. I. Jordan, and S. Russell. Distance metric learning with application to clustering with side-information. In: NIPS, pages 505-512, 2003.
- [2] K. Q. Weinberger and L. K. Saul. Distance metric learning for large margin nearest neighbor classification. JMLR, 10:207-244, 2009.
- [3] J. V. Davis, B. Kulis, P. Jain, S. Sra, and I. S. Dhillon. Information-theoretic metric learning. In: ICML, pages 209-216, 2007.
- [4] M. T. Law, N. Thome, and M. Cord. Learning a distance metric from relative comparisons between quadruplets of images. IJCV, pages 1-30, 2016.
- [5] S. J. Hwang, K. Grauman, and F. Sha. Analogy-preserving semantic embedding for visual object categorization. In: ICML, pages 639-647, 2013.
- [6] B. Kulis. Metric learning: A survey. Foundations and Trends in Machine Learning, 5(4):287-364, 2012.
- [7] Bellet, A. Habrard, and M. Sebban. Metric Learning. Morgan & Claypool Publishers, 2015.
- [8] Q. Cao, Z.-C. Guo, and Y. Ying. Generalization bounds for metric and similarity learning. Machine Learning, 102(1):115-132, 2016.
- [9] Y. Shi, A. Bellet, and F. Sha. Sparse compositional metric learning. In: AAAI, pages 2078-2084, 2014.
- [10] D. Kedem, S. Tyree, K. Q. Weinberger, F. Sha, and G. R. G. Lanckriet. Non-linear metric learning. In: NIPS, pages 2582-2590, 2012.
- [11] Raia Hadsell, Sumit Chopra, and Yann LeCun. Dimensionality Reduction by Learning an Invariant Mapping. In: CVPR, pages 1735-1742, 2006.
- [12] Q. Qian, R. Jin, S. Zhu, and Y. Lin. Fine-grained visual categorization via multi-stage metric learning. In: CVPR,

- [illegible]



Dr. Yoon is a professor of the Department of Health, Behavior, and Society, and the director of the Center for Communications Programs at the Johns Hopkins University. He has been working in the field of adolescent reproductive health for over 20 years. He has led several large-scale research and programmatic efforts in this field, including the Adolescent Reproductive Health Program in Bangladesh, the Adolescent Reproductive Health Program in India, and the Adolescent Reproductive Health Program in Kenya. He has also been involved in the development and implementation of several national-level policies and programs related to adolescent reproductive health. Dr. Yoon is a frequent speaker at international conferences and has published numerous articles and books on this topic.

詹德川

博士，南京大学计算机软件新技术国家重点实验室副教授。近年来发表论文十余篇，其中包括 ACM Trans、IEEE Trans 等重要国际学术期刊和 IJCAI、ICML、NIPS、AAAI 等中国计算机学会 A 类会议。现担任中国人工智能学会机器学习专业委员会、江苏省计算机协会人工智能专业委员会委员。主要研究方向为移动智能、机器学习、数据挖掘。

基于图的半监督学习理论及其应用

苏航，董胤蓬，胡文波

清华大学

0 引言

随着计算机、通信、传感等信息技术的飞速发展，以及互联网应用的日益普及，人们能够以更加快速、方便、廉价的方式来获取和存储数据资源，使得数字化信息以指数方式迅速增长。面对极度膨胀的数据量，传统的以标注数据为基础的机器学习模型已经远远不能满足数据分析和处理的要求，使人们处于数据到处“泛滥”而所获知识和价值甚少的困境^[1]。半监督学习在一定程度上避免了数据资源的浪费，通过充分地利用少量的有监督数据和大量的无监督数据来改善算法性能，从而解决了监督学习的模型泛化能力不强和无监督学习的模型不精确等问题。因此，半监督学习可以最大限度地发挥数据的价值，使机器学习模型从体量巨大、结构繁多的数据中挖掘出隐藏在背后的规律，成为近年来机器学习领域比较活跃的研究方

向，被广泛应用于社交网络分析、文本分类、计算机视觉和生物学医学信息处理等诸多的领域^[2-3]。

基于图的半监督学习方法是半监督学习研究中被广泛采用的一种方法，近年来有大量的工作专注在此领域，也产生了诸多卓有成效的进展^[4]。该方法将数据样本间的关系映射为一个相似度图，其中图的节点表示数据点（包括标记数据和无标记数据）；图的边被赋予相应权重，代表数据点之间的相似度，通常来说相似度越大，权重越大。对无标记样本的识别可以通过图上标记信息传播的方法实现，节点之间的相似度越大，标签越容易传播；反之，传播概率越低。基于图的半监督学习算法简单有效，符合人类对于数据样本相似度的直观认知，又可以针对实际问题来灵活地定义数据之间的相似性，具有很强的灵活性。尤其需

要指出的是，基于图的半监督学习具有坚实的数学基础作为保障，通常可以得到闭式最优解，因此具有广泛的适用范围。该方法的代表性论文也因此获得了2013年国际机器学习大会“十年最佳论文奖”^[5]，可看出该范式的影响力和重要性。

本文将在总结基于图的半监督学习的基本理论基础上，结合近年来一些最新进展，对基于图的半监督学习的学习方法、主要进展、相关应用，以及未来发展做综述简介。

1 基于图的半监督学习一般性框架

在众多的半监督学习算法中，基于图

的半监督学习是近年来最为活跃的研究领域之一（见图1）。假设有标记样本集为 $L = \{(x_1, y_1), (x_2, y_2), \dots, (x_p, y_p)\}$ 以及未标记的样本集合 $U = \{x_{l+1}, x_{l+2}, \dots, x_n\}$ ，其中 x_i 为样本点、 y_i 为相应的标签。该类方法利用有标注和无标注的数据构建数据图 $G=(V,E)$ ，其中顶点 V 表示样本点，包括了有标记和未标记的样本； E 表示连接两个顶点的相似程度。半监督学习可以通过基于图的邻接关系，将标签从有标签的数据点传播到无标签数据点，从而实现相应样本点的分类。




图1 基于图的半监督学习

在标签传播过程中，保持已标注数据的标签不变，使其像一个源头把标签传向未标注节点。每个节点根据相邻节点的标签来更新自己的标签，与该节点相似度越大，其标签就越容易传播到相邻节点，相似节点的标签越趋于一致。当迭代过程结束时，相似节点的概率分布也趋于相似，可以划分到同一个类别中，从而完成标签传播过程。标签传播在数学上可以通过多种方式来实现在，其中比较经典的是高斯场和谐波函数方法^[5]，该方法将图上每个样本点的标

签由离散值松弛到了连续域，并将随机场上的能量函数优化问题转换成了高斯场上的能量函数优化问题，可以通过求解目标函数

$$Y_u^* = \underset{Y_u \in \{0,1\}}{\operatorname{argmin}} \operatorname{tr}([Y_l; Y_u]^T \begin{bmatrix} L_{ll} & L_{lu} \\ L_{ul} & L_{uu} \end{bmatrix} [Y_l; Y_u]) \quad (1)$$

来实现。其中， X_l 和 Y_u 分别是标记样本和无标记样本的标签矩阵； $L = \begin{bmatrix} L_{ll} & L_{lu} \\ L_{ul} & L_{uu} \end{bmatrix}$ 是相似度图的拉普拉斯矩阵。对方程(1)中

的 Y_u 微分, 可以得到相应的闭式解为

$$Y_u^* = -L_{uu}^{-1} L_{ul} Y_l \quad (2)$$

此方法通过对数值域进行松弛, 使得顶点的边缘概率密度具有封闭形式解, 并且后续的很多方法都采用了相似的松弛, 包括局部和全局一致性学习^[7]、基于流形正则化^[8]等方法。

1.1 核心问题

基于图的半监督学习需要利用图来模拟低维流形, 因此图的构造在模型学习当中起到的是核心作用, 包括如何构建边, 以及如何给边赋权重^[9]。边的构建就是解决如何保持样本空间的局部几何结构的问题, 目前广泛采用的方法是构建 ε 近邻图或者 k -最近邻图的方法来实现^[6]。另一个问题是如何给边赋权重, 由于样本的低维流形分布未知, 因此很难通过计算任意两点沿着流形的距离来定义边的权重, 这也成为影响模型性能的最重要因素。目前普遍采用的是基于欧式距离及其变体的距离定义, 如高斯核函数、余弦核函数等。但这也导致了目前图的结构严重依赖于用户手动设定的相关距离参数, 当参数设定不合理或者参数的设定和任务不匹配时, 就会严重地影响半监督学习算法的性能, 甚至导致其比监督学习或者无监督学习更差的性能, 从而成为制约半监督学习算法应用的最重要因素之一。目前, 如何根据问题选取合适的模型参数, 仍然是一个亟待解决的问题。

1.2 基本假设

需要指出的是, 同其他半监督学习的方法类似, 以上基于图的半监督学习的成立依赖于如下的 2 个基本假设^[6]。

(1) **聚类假设**: 当两个样本位于同一聚类簇时, 它们在很大的概率下有相同的标签。此假设表明, 不同标签样本的分界面不应该出现在样本密度较大的区域, 因此大量未标记样本能够帮助标明样本空间中数据分布的稠密和稀疏区域。

(2) **流形假设**: 位于一个低维流形的局部极小邻域的样例, 在很大的概率下具有相同的标签。这一假设主要考虑模型的局部特性, 利用大量未标记样本使得数据空间更加稠密, 从而有助于更加准确地刻画数据的局部特性。

通常情况下, 聚类假设和流形假设是不矛盾的, 分别着眼于数据的整体特征和局部特征。基于图的半监督学习算法依赖于这些基本的假设。大量的研究表明, 当不满足这些基本假设时, 无监督的样本不仅不能改进模型性能, 反而起到恶化的作用^[6]。因此, 如何使模型满足这些条件, 或者在部分条件不满足的情况下更加“安全”地利用无监督样本仍然是一个活跃的研究领域。

2 近期若干进展

2.1 半监督主动学习

同半监督学习类似, 主动学习是利用未标记样本的另一大类技术^[9], 在学习的过程中自行挑选出一些未标记样本并要求用户进行标记, 然后将这些样本加入训练集进行常规的监督学习, 其技术难点在于如何使用尽可能少的查询来提升泛化性能。显然, 若能将半监督学习与主动学习相结合, 极大地促进对未标记样本进行利用。2003 年, Zhu 等^[10]

首次提出将主动学习和半监督学习相结合的技术，在深入研究标签传播理论的基础上，通过贪心算法，寻找使模型性能获得最大提升的样本点进行标记。近年来，Su 等^[11]进一步利用了拉德马赫复杂度（Rademacher Complexity）理论，通过最小化的预测误差期望，来批量化的选取最有信息量的样本点进行人工标记，并成功地应用于图像分割中。到目前为止，主动学习和半监督学习的融合仍然是一个极有价值的研究方向，有很多问题尚待解决。

2.2 在线修正传播理论

在实际应用中，由于问题的复杂性、时间演进等原因，不可避免地存在大量的分类错误。在很多应用中，用户往往会重新介入到分类的任务中，对其中的错误进行重新修订。可以想像的是在样本空间中，往往存在大量的类似错误，理想的情况是人工修正也能够同时对相似的错误进行修正。但是很显然，将这些用户修正的样本当作标定样本进行重新训练需要消耗大量的时间和计算量，这就需要采用增量学习的模式，在既有模型的基础上有针对性地进行微调，从而实现模型的动态演进。

为了解决这一问题，Su 等^[12]提出了基于修正传播算法的模型动态更新算法，通过引入一个修正传播矩阵，可以有效地将人工修正传播到其他的未标记样本中，从而极大地提高了人工修正的利用效率，降低修正传播的计算量。作者通过在原有的相似度图中引入了虚监督节点，并将其关联到被修正的节点上，将关联边的权值设为 $+\infty$ ，从而有效地将人工的修正等效传导

到整个样本空间中。如图（2）所示，其中深蓝圆圈代表了虚监督，其关联的圆圈代表了被人工修订的样本（记所有和虚监督关联的样本点集合为 K ），推导得到修正传播可以通过如下的方程实现：




图2 基于增广图的修正传播

$$Y_u^+ = Y_u + \Gamma_{uu}(:, K) \left(\Gamma_{uu}(K, K) \right)^{-1} (Y_s - Y_u(K)) \quad (3)$$

其中， $\Gamma_{uu} = L_{uu}^{-1}$ ，是无标记样本所对应的拉普拉斯矩阵的逆； $\Gamma_{uu}(:, K) \left(\Gamma_{uu}(K, K) \right)^{-1}$ 是对应的修正传播矩阵，对应的是 Γ_{uu} 中被修订的样本。这样，修正传播算法只需要计算一个很小的矩阵的逆（ $\left(\Gamma_{uu}(K, K) \right)^{-1}$ ），算法的效率将得到极大提高。相关研究者应用修正传播算法已经在图像分类^[12]、生物图像分割^[13]等诸多任务中取得了很好结果。类似的方法也可以应用于其他的半监督学习框架中。

2.3 半监督学习的高效算法

计算效率始终是半监督学习中所面临的重要瓶颈之一，由于基于图的半监督学习往往要进行拉普拉斯矩阵的逆运算，其时间复杂度是 $O(N^3)$ ，甚至出现内存溢出现象，难以应用于大规模数据的运算。因此如何提高半监督学习算法的效率，一直是一个研究

的热点。Zhang^[14]在2009年利用Nystrom近似解决相似性矩阵规模较大问题,但这个算法存在不能保证相似性矩阵半正定的问题。Fergus等^[15]提出在标记预测函数使用图拉普拉斯的光滑特征向量,但此算法过分依赖维度可分离的数据密度假设。针对这些问题,Liu等^[17]提出基于锚点的建图方式,以及相应的半监督分类算法框架,有效地解决了对大数据集的分类问题。但是这一方法采用无监督聚类的方法得到锚点,对噪声较为敏感;同时将节点关联为固定数量的锚点,自适应性较差。针对这一问题,Su等^[18]在锚点的构建中引入了稀疏性的约束,可以通过字典学习的方式,自适应学习得到相应的锚点,以及节点和锚点之间的关联关系,从而有效提升了算法的性能。




图3 半监督学习显微图像下的细胞分割^[19]

3.2 文本分析

半监督学习比较典型的应用就是在自然语言处理领域的应用。由于互联网的日益发达,指数级增长的网络资源能进行人工标记的网页微乎其微,给半监督学习提供了广泛的应用场景。He等^[21]提出将基于图的半监督学习和生成模型结合的方法,利用图的传播来估计条件概率,用线性回归估计类先验信息,为基于图的半监督学习和主题模型等生成式模型的结合提供了可能。近年来,Hu等^[22]提出将拉普拉斯

3 典型应用

基于图的半监督学习技术已在众多领域中得到广泛应用,下面仅撷几例说明。

3.1 生物图像分析

在生物图像的分析中,每天大量的生物实验往往很容易得到海量的无类标签的样例,但往往需要使用特殊设备或经过昂贵且用时非常长的实验过程,进行人工标记才能得到有类标签的样本^[6]。因此,如何将半监督学习应用到生物图像分析中改进系统性能,是一个非常有价值的研究方向。相关的研究者在此方面已经进行了大量的探索,并成功将半监督学习算法应用于相差显微镜图像下的细胞分割问题^[19](如图3所示),以及双光子显微镜的脑细胞的分割^[20]中。

平滑约束作为正则项,引入到LDA等贝叶斯主题模型的框架中^[23],从而实现了问题的主题提取和文档分类。

3.3 哈希算法

哈希学习通过将数据表示成二进制码的形式,可以显著减少数据的存储和通信开销,成为大数据学习中的一个研究热点。基于半监督学习的哈希学习算法可以充分利用样本的监督学习和海量的无标记数据,近年来受到了广泛的关注^[24]。基于图半监督学习的方法由于其可以很好表征样本之

间的相似度关系，可以和度量学习进行深度的融合，从而可以得到更加紧致的哈希编码，并且广泛地应用于图像和视频的检索问题中^[25]。

4 结束语

经过多年的发展，基于图的半监督学习获得了快速的发展，在很多方面的技术已经趋于成熟，并逐渐应用于很多实际问题中。但是需要指出的是仍然存在很多有待研究的问题。

首先，目前的半监督学习方法鲁棒性不足。一方面表现在目前的方法在某些情况下无法保证实现“安全”的半监督学习，即在利用了未标记样本后，性能不但没有提升，反而还会有所下降。因此，如何更加安全地利用无标记样本，从理论和技术上仍然有很多问题需要探索^[26]。另一方面，随着互联网和众包技术的发展，人们可以获得相对大量的标记，但是这类标记通常质量较差，还存在大量的噪声，甚至恶意

的误导，如何更加有效地利用这些低质量的标注数据是半监督学习领域又一个重要的研究方向^[27]。

其次，近年来以深度学习为代表的新一代人工智能方法取得一系列重要突破，受到了前所未有的关注，但是这些方法往往依赖大量的高质量训练数据。在训练数据量有限的情况下，深度神经网络的性能往往受到很大局限，一些规模巨大的深度神经网络也容易出现过拟合，使得测试性能远低于训练性能。因此，如何结合深度学习和半监督学习的优势，充分利用人工标定和海量的无标记数据将是未来非常有价值的研究方向。一些初步的半监督深度学习方法的尝试在较为简单的情形中取得了较好的效果^[28]。随着深度学习理论的深入尤其是深度生成模型的发展^[29]，相关的研究者在这方面进行了大量的探索，使得深度学习在半监督学习领域的在图像的生成和分类等诸多应用中，都取得了显著的进展^[30]。

参考文献

- [1] C. Lynch. Big data: How do your data grow. *Nature*, no. 7209 (2008): 28-29.
- [2] 周志华. 基于分歧的半监督学习. *自动化学报* 39, no. 11 (2013): 1871-1878.
- [3] 刘建伟, 刘媛, 罗雄麟. 半监督学习方法. *计算机学报* 38, no. 8 (2015): 1592-1617.
- [4] Liu, Wei, Jun Wang, and Shih-Fu Chang. Robust and scalable graph-based semisupervised learning. *Proceedings of the IEEE* 100, no. 9 (2012): 2624-2638.
- [5] Zhu, Xiaojin, Zoubin Ghahramani, and John D. Lafferty. Semi-supervised learning using gaussian fields and harmonic functions. In *Proceedings of the 20th International conference on Machine learning (ICML-03)*, pp. 912-919. 2003.
- [6] Subramanya, Amarnag, and Partha Pratim Talukdar. Graph-based semi-supervised learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning* 8, no. 4 (2014): 1-125.
- [7] Zhou, Denny, Olivier Bousquet, Thomas N. Lal, Jason Weston, and Bernhard Schölkopf. Learning with local and global consistency. In *Advances in neural information processing systems*, pp. 321-328. 2004.

- [8] Belkin, Mikhail, Partha Niyogi, and Vikas Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of machine learning research* 7, no. Nov (2006): 2399-2434.
- [9] Liu, Wei, and Shih-Fu Chang. Robust multi-class transductive learning with graphs. In *Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE Conference on*, pp. 381-388. IEEE, 2009.
- [10] Zhu, Xiaojin, John Lafferty, and Zoubin Ghahramani. Combining active learning and semi-supervised learning using gaussian fields and harmonic functions. In *ICML 2003 workshop on the continuum from labeled to unlabeled data in machine learning and data mining*, vol. 3. 2003.
- [11] Hang Su, Hua Yang, Shibao Zheng, Sha Wei, Shuang Wu. Towards Active Annotation for Detection of Numerous and Scattered Objects. *Multimedia and Expo, IEEE International Conference on (ICME)*, 2015.
- [12] Hang Su, Zhaozheng Yin, Takeo Kanade, Seungil Huh. Active Sample Selection and Correction Propagation on a Gradually-Augmented Graph. *Computer Vision and Pattern Recognition, IEEE Conference on (CVPR)*, 2015.
- [13] Su, Hang, Zhaozheng Yin, Seungil Huh, Takeo Kanade, and Jun Zhu. Interactive cell segmentation based on active and semi-supervised learning. *IEEE transactions on medical imaging* 35, no. 3 (2016): 762-777.
- [14] K. Zhang, J. T. Kwok, and B. Parvin. Prototype vector machine for large scale semi-supervised learning. in *Proc. Int. Conf. Mach. Learn.*, 2009, pp. 1233-1240.
- [15] Fergus, Rob, Yair Weiss, and Antonio Torralba. Semi-supervised learning in gigantic image collections. In *Advances in neural information processing systems*, pp. 522-530. 2009.
- [16] Wang, M., Fu, W., Hao, S., Tao, D. and Wu, X., 2016. Scalable semi-supervised learning by efficient anchor graph regularization. *IEEE Transactions on Knowledge and Data Engineering*, 28(7), pp.1864-1877.
- [17] Liu, Wei, Junfeng He, and Shih-Fu Chang. Large graph construction for scalable semi-supervised learning. In *Proceedings of the 27th international conference on machine learning (ICML-10)*, pp. 679-686. 2010.
- [18] Su, Hang, Jun Zhu, Zhaozheng Yin, Yinpeng Dong, and Bo Zhang. Efficient and Robust Semi-supervised Learning Over a Sparse-Regularized Graph. In *European Conference on Computer Vision*, pp. 583-598. Springer International Publishing, 2016.
- [19] Hang Su, Zhaozheng Yin, Seungil Huh, Takeo Kanade. Cell segmentation in phase contrast microscopy images via semi-supervised classification over optics-related features. *Medical Image Analysis*, vol. 17, pp. 746-765, Oct. 2013.
- [20] Kun Xu, Hang Su, Jun Zhu, Ji-Song Guan, and Bo Zhang. "Neuron Segmentation Based on CNN With Semi-Supervised Regularization." In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pp. 20-28. 2016.
- [21] He, Jingrui, Jaime G. Carbonell, and Yan Liu. Graph-Based Semi-Supervised Learning as a Generative Model. In *International Joint Conference on Artificial Intelligence (IJCAI)*, vol. 7, pp. 2492-2497. 2007.
- [22] Wenbo Hu, Jun Zhu, Hang Su, Jingwei Zhuo, and Bo Zhang. Semi-supervised Max-margin Topic Models with Manifold Posterior Regularization. In *International Joint Conference on Artificial Intelligence (IJCAI)*, Melbourne, Australia.
- [23] Jun Zhu, Ning Chen, Eric P. Xing. Bayesian inference with posterior regularization and applications to infinite latent SVMs. *Journal of Machine Learning Research*, 2014, 15: 1799.
- [24] Liu W, Wang J, Kumar S, et al. Hashing with graphs. In: *Proceedings of the 28th International Conference on Machine Learning (ICML)*, Washington, 2011, 1-8.
- [25] Zhang, S., Li, J., Jiang, M., & Zhang, B. (2017). Scalable Discrete Supervised Multimedia Hash Learning with Clustering. *IEEE Transactions on Circuits and Systems for Video Technology (IEEE TCSVT)*.
- [26] Li, Yu-Feng, and Zhi-Hua Zhou. Towards making unlabeled data never hurt. *IEEE Transactions on Pattern*

[27] Li, Yu-Feng, James T. Kwok, and Zhi-Hua Zhou. Towards Safe Semi-Supervised Learning for Multivariate Performance Measures. In The AAAI Conference on Artificial Intelligence, pp. 1816-1822. 2016.

[28] Weston J, Ratle F, Mobahi H, et al. Deep learning via semi-supervised embedding. Neural Networks: Tricks of the Trade. Springer Berlin Heidelberg, 2012: 639-655.

[29] Kumar, Abhishek, Prasanna Sattigeri, and P. Thomas Fletcher. Improved Semi-supervised Learning with GANs using Manifold Invariances. In Advances in Neural Information Processing Systems (NIPS 2017).

[30] Li, Chongxuan, Kun Xu, Jun Zhu, and Bo Zhang. Triple Generative Adversarial Nets. In Advances in Neural Information Processing Systems (NIPS 2017).



清华大学计算机科学与技术系助理研究员。CCF 计算机视觉专家委员会委员, CCAI 机器学习专业委员会通讯委员。在 CVPR、IJCAI 等国际会议和期刊发表论文 50 余篇, 多次受邀担任 TPAMI、TIP 等国际期刊的审稿人, 以及 ICML、CVPR 等国际会议的技术委员会委员或审稿人。承担自然科学基金、“973”等多个国家级项目。曾获得 MICCAI “青年学者”、AVSS 的“最佳论文”等重要奖项。主要研究方向为计算机视觉、机器学习。



清华大学计算机科学与技术系在读博士研究生。在 CVPR、IJCAI 等国际会议和期刊发表论文近 10 篇，多次率队获得国际人工智能相关比赛冠军，曾获 CCF 优秀大学生、北京市优秀毕业生和清华大学“钟士模”奖学金。



清华大学计算机科学与技术系在读博士。在 IJCAI、NSR 等国际会议和期刊发表多篇论文，曾获得清华大学“斯伦贝谢”奖学金。



结构特征研究

范长俊，程光权，黄金才，刘忠

国防科技大学

摘要：本文从同质网络和异质网络两个方面，从结构特征设计和结构特征学习两个角度，综述现有的网络数据结构特征的研究现状，指出基于深度学习方法的网络数据结构特征学习相比，传统的人工设计结构特征在问题规模和求解效率上均具有明显的优越性，目前这一类研究也正处于如火如荼的初期阶段，是一个非常有前景的探索课题。

关键词：网络数据；结构特征；同质网络；异质网络；网络表示学习

0 前言

我们生活在一个相互关联的世界，大部分的信息实体都是相互关联或者相互影响的，从而形成许多大规模的相互关联且错综复杂的网络。不失一般性，这里定义其为信息网络。信息网络无处不在，几乎涵盖了人们生活中的方方面面，像社会网络、万维网、研究合作网络、生物网络、高速公路网络、电力能源网络等都是信息网络的实例。很明显，这些信息网络构成了当今信息基础设施的关键单元。对信息网络的研究，包括一般性研究和特殊类（如

社会网络、万维网等）研究，吸引了很多领域学者的关注，如计算机科学、社会学、物理学、经济学、生物学等，在理论和应用上都取得了大量突出的成果。

众所周知，数据特征对于学习算法起着决定作用，特征决定了所有算法的上限，而不同的算法只是离这个上限的距离不同而已。网络数据挖掘作为数据挖掘的一种，基本的研究思路是首先从网络数据中提取有价值的信息，然后把数据表示成特征向量，进而采用机器学习算法完成相关任务。当然网络科学领域对于网络数据挖掘的范

式有所不同，其核心是研究网络拓扑对网络行为、功能的影响，研究途径是根据研究问题构造具有明确物理含义的拓扑指标，运用统计物理等方法开展研究。相比于从实际数据中学习模型的方法，这类方法的研究成果往往更具普适性，但在某一个具体问题上，又不如前者的精度高。网络科学的研究成果可以认为是人工构造的网络拓扑特征，比如模块度、PageRank 度、介数、接近度、传播阈值、同步性、抗毁性等，这些特征因为具有明确的物理含义，并且有着坚实的理论基础，是比较有效的共性特征。当面对一个具体问题时，可以首先加入这些共性的特征，再结合问题特点，人工构造或者自动学习其他特征，从而提高具体问题模型的学习精度。这样就可以充分借鉴网络科学领域的研究成果，更好地解决网络数据挖掘的实际问题。

即便如此，网络科学领域提炼出的共性特征对于具体的实际问题贡献也是有限的，由于特征的选择和设计对算法结果的决定性作用，网络数据挖掘的研究工作最终还是沦为了特征工程，表示学习的兴起将人从繁琐的特征工程中解放出来，当数据表现出网络化的结构时，其表示学习问题就称为网络表示学习问题。

通过网络表示学习把节点表示为低维向量，文献 [1] 提出有如下三个好处：一是可以直接利用得到的节点向量表示作为机器学习算法的输入，避免针对网络数据重新设计新的特征；二是网络中节点的距离、乘积等需要定量计算的概念不容易给出明确的定义，通过把节点表示成向量，可以

在向量空间中直接进行各种运算；三是在大规模网络数据中，节点之间的链接关系可能会非常复杂而不易观察，但是通过在低维向量空间中进行可视化分析展示，可以很直观地观察节点之间的关系。

下面本文从同质网络和异质网络两种网络类型，从结构特征设计和结构特征学习（也称为网络表示学习、网络嵌入等）两个角度分析相关研究情况。

1 同质网络数据结构特征表示

1.1 同质网络数据结构特征设计

和一般数据的机器学习问题一样，网络结构数据的人工特征构造也是一个特征工程，通过精心设计一些拓扑特征指标以捕捉网络数据最基本的结构和重要的模式，或者是针对一个特定领域的网络数据（如技术网络、生物网络）或一个特定的问题（如网络社区挖掘、角色识别、异常检测等）设计与之最相关的拓扑指标，实际上，这也是目前网络科学领域关注的焦点问题。除去特定网络或特定问题的特征构造方法，这里主要介绍网络结构特征构造的一般方法。

文献 [2-5] 中介绍了一些网络化结构数据的特征构造的方法，下面主要从特征类别、特征变换、特征搜索和特征筛选四个方面进行总结。

（1）特征类别。网络结构数据的特征主要分为四种类型，一是一般性的网络结构特征^[6-7]，如度、聚集系数、介数、子图特征（三角元的个数等），以及基于路径或随机游走的特征、模块度等，这些指标往往具有明确的物理含义；二是只基于边

的特征^[8]，这一类特征仅仅基于目标点或目标边（待构造特征的点或边）的邻居边，或者邻居边的邻居边（甚至扩展至 k 步之后）构造的，通过这些邻居边的属性构造目标点的特征；三是只基于点的特征^[9]，这一类特征仅仅基于目标点的邻居点，或者邻居点的邻居点（同样可以扩展至 k 步之后）构造的，通过这些邻居点的属性构造目标点或目标边的特征；四是只基于节点或边的外部属性构造得到（非关系特征，假设可以得到这些外部属性）。以上四种类型的特征在一个具体的应用中可以综合考虑使用。

（2）特征变换，或称之为特征运算。第一步得到的是基本的数据特征，通过特征运算对这些基本特征进行变换，以得到更有效、更丰富的特征。常见的特征运算符包括关系代数（众数、均值、计数等）、集合操作（交、并、补等）、维度约简（SVD、PMF、NMF、ICA、PCA等）、相似度计算（余弦相似度、互信息等）等。

（3）特征搜索和特征筛选。它们步骤的目的是一样的，都是为了在前两步的基础上进一步构造出对解决问题更有效的网络结构数据特征。特征搜索是在前两步得到的特征的基础上进行去冗去噪，以获得最小最具代表性的特征。常见的搜索策略包括三种：穷举策略（exhaustive^[10]），考虑所有可能的特征组合；随机策略（random^[10]），仅仅通过一些采样策略随机选择一部分特征的组合；启发式策略（guided^[11-12]），通过一些启发式的方法来鉴别那些最有效的特征。在每种方法中，选择每个特征的依据有一定的评价准则，这也是特征筛选的

依据。目前有很多方法，包括Pearson系数（和Spearman秩系数）^[13]、信息增益（information gain）^[14]、基尼系数（gini index）^[15]、Kearns-Mansour准则^[16]、最大信息系数（MIC）^[17]、Mallows^[18]、贝叶斯信息准则（BIC）^[19]，还有logarithmic binning^[20]比较适合节点度分布服从幂律分布的网络特征筛选。

1.2 同质网络数据结构特征学习

同质网络的结构特征学习（网络表示学习）研究有一定的研究历史，传统的方法包括矩阵分解、流形嵌入等。但是这些方法，一是对于网络结构的特征表示能力不足；二是可扩展性较差，不能适应大规模网络的表示学习需求。近年来，深度学习模型在一般数据的特征学习上获得了极大进展，包括文本数据、图像数据、语音数据等，这些领域的很多研究成果，如word2vec、CNN、RNN等，对于网络表示学习的研究都有重要的指导意义。其相关工作已经展现了该研究方向的广阔前景。

1.2.1 基于谱方法的两质网络数据结构特征学习

谱方法是指利用输入的网络数据矩阵的谱（包括特征值、特征向量、奇异值和奇异向量等）的一类算法统称。针对网络表示学习，不同的输入矩阵（可能是邻接矩阵、拉普拉斯矩阵等类型）决定不同的算法。

文献[21]提出的LLE是一种非线性降维算法。算法主要思想是，每一个数据点都可以由其邻居点的线性加权组合得到。算法首先输入一个邻接矩阵，然后计算出每个节

点的局部重建权重矩阵, 最后推导出一个特征值分解问题, 进而计算节点的低维表示。

文献 [22] 提出的 Laplacian Eigenmaps 算法的主要思想是相邻的节点在降维后的空间中尽可能接近。该算法可以反映出数据内在的流形结构, 输入也是邻接矩阵。与 LLE 算法不同的是, Laplacian Eigenmaps 算法最终选取拉普拉斯矩阵的最小 k 个非零特征值对应的特征向量, 作为学习到的网络表示。类似的方法包括文献 [1,23]。

1.2.2 基于神经网络模型的同质网络数据结构特征学习

深度学习本质上是一种自动特征学习方法^[24], 其思想在于将原始数据通过非线性模型转变为更高层次的特征表示, 从而获得更抽象的表达。与特征工程中需要人工设计特征不同, 深度学习会自动从数据中学习出特征表示。

受自然语言处理领域中 word2vec 模型

的启示, 针对网络表示学习, 也有一类结合网络上的随机游走和 word2vec 模型的模型, 以 Deepwalk^[25]、LINE^[26] 和 Node2Vec^[27] 为代表。

首先介绍 Deepwalk 模型, 这是第一个将 word2vec 模型应用网络分析的模型, 也开启了这一波网络表示学习的热潮。Word2vec 模型的输入是文本 (包括单词、句子), 作者想到如果在网络上通过随机游走的方式得到不同串节点序列 (类比句子, 每个访问到的节点类比单词), 不同串节点序列组成文本, 直接输入到 word2vec 模型中也能得到每个节点的低维向量表示, 最后发现这些向量在节点标签分类任务上表现很好。图 1 给出 Deepwalk 模型的框架示意。文献 [28] 证明 Deepwalk 算法等价于分解矩阵 M , 其中 M 的第 i 行第 j 列的元素是节点 i 在固定步数内随机游走到节点 j 的次数。同样, word2vec 也被证明等价于分解 PMI 矩阵或者词共现矩阵。




图 1 Deepwalk 模型框架

Deepwalk 仅仅在网络中基于随机游走获得训练数据, 本身并没有一个明确的优化目标函数。文献 [26] 提出的 LINE 算法, 认为网络中存在两种相似度需要保持, 一种是 first-order 相似度, 即两个节点是否直接有边相连及连边的权重; 另一种是

second-order 相似度, 即两个节点的共同邻居集合的相似度。如图 2 所示, 节点 6 和节点 7 拥有较高的 first-order 接近度, 节点 5 和节点 6 拥有较高的 second-order 接近度。LINE 算法对两种接近度分别设计了一个优化目标函数, 然后分别训练出一

个向量表示，最后以两种向量的拼接作为节点最终的向量表示。Deepwalk 算法本质上只考虑 second-order 接近度，实验表明 LINE 在词义类比、文档分类、节点标签预测、可视化等任务上均要优于 Deepwalk 算法。




图 2 LINE 算法中接近度的说明

LINE 算法本质上也可以理解为节点在网络上的随机游走，只不过游走的步数限定为 1 步或 2 步；Deepwalk 算法中节点在网络上的随机游走则没有任何限制，唯一可能影响游走序列的是网络的度分布。然而文献 [29] 提出的 NodeVec 算法认为，网络中节点的拓扑相似性主要有两种，一种是两个节点同属一个“社群”，因为抱团而相似；另一种是两个节点在网络中扮演着相同的拓扑角色，例如同是 hub 节点、中介节点、边缘节点等，因为这种角色的相似而相似。因此节点在网络中通过随机游走寻找其与其相似的其他节点时也要考虑到这两点，对应前一点，节点应尽量在周边随机游走，类似于一种宽度优先搜索 BFS；对应后一点相似性，则应尽量往远处随机游走，类似于一种深度优先搜索 DFS。如图 3(a) 所示。




图 3 Node2Vec 算法示例

为此，文献 [27] 通过引入两个参数提出一种有偏好的网络随机游走策略研究网络表示问题，如图 3(b) 所示，节点从 t 转移到 v 。在 v 点，它有多种转移策略，设任意一种转移的概率为 $\pi_{vx} = \alpha_{pq}(t, x) \cdot w_{vx}$ ，其中

$$\alpha_{pq}(t, x) = \begin{cases} 1/p & \text{if } d_{tx} = 0 \\ 1 & \text{if } d_{tx} = 1 \\ 1/q & \text{if } d_{tx} = 2 \end{cases}$$

式中， d_{tx} 表示节点 t 和节点 x 之间的最短路径（只能为 0、1、2 三个数值）。参数 p 是返回参数（return parameter），数值越小，节点越容易返回已访问的节点。参数 q 是进出参数（in-out parameter），如果 $q > 1$ ，说明节点倾向于游走在 t 附近的节点，类似 BFS 搜索；如果 $q < 1$ ，说明节点倾向于游走到远离 t 的节点，类似 DFS 搜索。

调节两个参数，可以得到不同的节点表示向量，实现不同的目的，如图 3(c) 所示。第一幅图侧重于 BFS 游走策略，所以可以识别网络中不同的模块；第二幅图侧重于 DFS 游走策略，所以可以识别网络中不同拓扑角色的节点（蓝色节点是 hub 节点，黄色节点是叶子节点，红色节点为中间节点）。实验表明，Node2Vec 算法

在网络节点多类别分类预测的任务上的精确度，均要优于 Deepwalk 算法和 LINE 算法。

其他的一些典型的网络表示方法包括 GraRep^[29-30], LINE 算法其实只考虑了节点的二阶相似性，GraRep 则考虑了节点之间的 K 阶相似性，并在多个任务中的表现均比其他算法略胜一筹。

以上算法的隐含或实际目标函数都是保持节点对之间的相似性，如果目标函数是保持网络中社区 (community)^[29-31] 或者模体 (motif)^[32] 的相似性？这方面也有相关的工作。文献 [31] 结合非负矩阵分解和网络社区模块度的概念，设计新的目标函数，通过最优化的方法进行网络的表示学习，如图 4 所示。




图 4 保持社区结构的网络表示学习

事实上，网络表示学习可以看成是一种函数映射，该映射函数将网络中的节点从高维表示（维度为网络节点规模）映射到低维表示（有限维度），以上的方法几乎都是浅层模型（包括 Deepwalk、Node2Vec 也都是不超过三层的神经网络模型）。而众所周知，神经网络模型层数越多，其表达能力越强，现有的图像识别精度最高的神经网络已经达到了 100 多层，那么最近在深层神经网络表示上的研究对于网络表示学习也有很多的迁移应用。

文献 [33] 针对 LINE 算法没有同时学习

保持节点对之间的一阶相似性和二阶相似性，提出基于深度自动编码器的网络表示学习算法 SDNE。首先该算法基于自动编码器 (AutoEncoder) 学习网络中节点对之间的二阶相似性；即基于共同邻居的相似性，同时利用节点的邻接点信息（一阶相似性）来完善第一步得到的节点向量表示。作者将该算法在五个网络数据集（包括三个社会网络数据集、一个文章引用网络和一个语言网络），以及在三个应用（多标签分类、链路预测和可视化）任务上的表现和其他主流算法进行了比较，发现该算法在大部分情况下都要优于其他方法。

文献 [34-36] 将网络的矩阵表示看成一张图，采用卷积神经网络 (CNN) 提取图像特征的方法提取网络的特征；文献 [37] 采用网络上的随机游走得到的节点序列数据，基于循环神经网络模型 (RNN) 学习网络节点的表示；文献 [38] 用 CNN 模型提取药物分子式的特征作为其性质预测的指纹。

当然深度神经网络模型还有很多其他形式，而这些不同形式的神经网络模型是否对网络数据的表示学习有效，还有待进一步的探索。目前也仍然只有卷积神经网络、循环神经网络等模型被用于进行初步的探索，相比于浅层模型而言，更有效的网络表示学习技术对深度神经网络模型给予了更高的期待。

2 异质网络数据结构特征表示

2.1 异质网络数据结构特征设计

异质网络挖掘中的特征构造主要围绕元路径的选择和权重的量化两大主题开展，并且取决于特定任务的理解和分析。例如对于文章合作网络中（如图 5(a) 和 (b) 所示），

这种类型的网络模式 (schema) 表现如图 5(a) 所示, 文章与主题之间有包含、涉及关系, 文章和会议之间有发表关系, 文章和作者之间有写作关系, 文章和文章之间有引用关系。图 5(b) 展示了该网络的一个实例。




图 5 文章合作网络的模式、元路径及实例

图 5(c) 展示了该网络中的两条基本的元路径, 分别是 APA (作者 - 文章 - 作者) 和 APV (作者 - 文章 - 会议); 图 5(d) 是基于这两个元路径的一些实例。显而易见, 在不同的元路径的定义下, 作者之间的相似性也有着不同的含义, 基于 APA 元路径找到的是与目标作者合作最多的作者; 而基于 APVPA 元路径找到的是与目标作者经常发表在同一会议文章的作者。文献 [39] 在 DBLP 数据上的实验结果 (见表 1) 表明, 在 APA 元路径下找到的基本是 Faloutsos 教授的学生或合作者; 而在 APVPA 元路径下找到的基本是与 Faloutsos 从事相同主题研究或者声誉接近的学者。

表 1 不同元路径下与 “Christos Faloutsos” 最相似的前 10 个作者

(a) Path: APA		(b) Path: APVPA	
Rank	Author	Rank	Author
1	Christos Faloutsos	1	Christos Faloutsos
2	Spiros Papadimitriou	2	Jiawei Han
3	Jimeng Sun	3	Rakesh Agrawal
4	Jia-Yu Pan	4	Jian Pei
5	Agma J. M. Traina	5	Charu C. Aggarwal
6	Jure Leskovec	6	H. V. Jagadish
7	Caetano Traina Jr.	7	Raghu Ramakrishnan
8	Hanghang Tong	8	Nick Koudas
9	Deepayan Chakrabarti	9	Surajit Chaudhuri
10	Flip Korn	10	Divesh Srivastava

可见, 不同的元路径携带着不同的语义信息, 因此可以基于元路径构建不同的维度的特征, 作为异质网络中节点对的特征向量, 从而可以引入传统的机器学习模型进行如分类、聚类任务的分析。

文献 [40] 设计了九种基于元路径的拓扑特征来预测文章合作异质网络中目标学者的下一合作者, 这九种基于元路径的拓扑特征同时也提供了文章合作关系产生的内在原因: A-P-A 表示经常合作的人以后也会合作; $A-P \rightarrow P-A$ 表示人倾向于与自己经常引用其文章的人合作; $A-P \leftarrow P-A$ 表示人也喜欢和经常引用自己文章的人合作; A-P-V-P-A 表示两个经常发文章在同一会议 (期刊) 的人也容易产生合作; A-P-T-P-A 表示两个经常研究同一主题的人也容易产生合作; $A-P \rightarrow P \rightarrow P-A$ 表示人也会和那些自己经常引用的文章、经常引用的作者产生合作, $A-P \leftarrow P \leftarrow P-A$ 表示人也会和那些经常引用自己文章的文章的作者产生合作; $A-P \rightarrow P \leftarrow P-A$ 表示两个经常引用相同文章的人容易产生合作; $A-P \leftarrow P \rightarrow P-A$ 表示两个经常被相同文章引用的作者容易产生合作。这几条规则也揭示了科学家之间产生合作的内在动力。

基于构造的这九个特征, 作者训练一个逻辑斯蒂回归模型进行分类预测, 其中对 Jian Pei 的预测结果如表 2 所示。表中粗体表示这一段时间 Jian Pei 实际的合作者, 可

表 2 Jian Pei 在 2003—2009 年最有可能的五个合作者

Rank	Hybrid heterogeneous features	# of shared authors as feature
1	Philip S. Yu	Philip S. Yu
2	Raymond T. Ng	Ming-Syan Chen
3	Osmar R. Zaiane	Divesh Srivastava
4	Ling Feng	Kotagiri Ramamohanarao
5	David Wai-Lok Cheung	Jeffrey Xu Yu

以发现基于元路径特征的模型的精度要比其他的方法要高。

文献 [41] 设计了四个基于元路径的拓扑特征预测文章合作网络中，作者之间何时会发生引用关系：A-P-T-P-A 元路径表示两个研究同一主题的作者容易引用对方的文章；A-P $\leftarrow$ P $\rightarrow$ P-A 表示如果两个作者经常被相同的文章引用，那他们也容易引用对方的文章；A-P-A-P $\rightarrow$ P-A 表示如果一

个作者的合作者经常引用另一个人的文章，则他们两个人也容易产生引用关系；A-P-T-P-A-P $\rightarrow$ P-A 表示如果两个作者研究领域相同，则他们也倾向于引用相同的作者。以这四个拓扑特征为自变量，以引用时间为因变量，作者建立了一个广义线性模型（实验了指数分布、威布尔分布和几何分布三种分布形式），并以“Philip S. Yu”为例分析结果如表 3 所示。

表 3 Philip S. Yu 的引用时间预测结果

a_i	a_j	Ground truth	Median	Mean	25% quant.	75% quant.
Philip S. Yu	Ling Liu	1	2.2386	3.4511	0.8549	4.7370
Philip S. Yu	Christian Jensen	3	2.7840	4.2919	1.0757	5.8911
Philip S. Yu	C. Lee Giles	0	8.3985	12.9474	3.2450	17.7717
Philip S. Yu	Stefano Ceri	0	0.5729	0.8833	0.2214	1.2124
Philip S. Yu	David Maier	9+	2.5675	3.9581	0.9920	5.4329
Philip S. Yu	Tong Zhang	9+	9.5371	14.7028	3.6849	20.1811
Philip S. Yu	Rudi Studer	9+	9.7752	15.0698	3.7769	20.6849

可以发现预测结果的中位数和实际值最接近，也有一些偏差比较大的例子，如 David Maier, 他是数据库领域里一位多产的学者，按道理 Yu 应该会引用他的文章，但实际并没有引用，个中原因有待挖掘。这种方法可以用于为学者推荐应该引用谁的文章。

不同的元路径表示着不同的语义信息，那么针对一次特定的任务如何选择最合适的元路径或其组合？

文献 [42] 提出基于用户指导（user-guided）的元路径选择方法用于相似度搜索任务。首先在线下训练基于不同元路径的排序模型；然后线上部分根据用户的搜索要求（query）和示例，算法匹配到训练好的合适的模型；最终输出用户满意的结果。如图 6 所示，第一个任务是找到和 Christos

Faloutsos 最相似的学者，并举了几个例子，分析例子发现这些都是他的主要合作者或者其学生，因此算法最后输出的也都是类似的学者；而第一个任务同样是找到和 Christos Faloutsos 最相似的学者，但是用户提供的例子都是和该教授声誉相近的数据

Query 1:	find author similar to “Christos Faloutsos” taking “Jimeng Sun”, “Hanghang Tong” as examples
Answer:	Agma J. M. Traina, Spiros Papadimitriou, Jure Leskovec
Query 1’:	find author similar to “Christos Faloutsos” taking “Philip S. Yu”, “Jiawei Han” as examples
Answer:	Hector Garcia-Molina, H. V. Jagadish, Divesh Srivastava
Query 2:	find movie similar to “the Dark Knight” taking “Batman Begins”, “Batman” as examples
Answer:	Batman Returns, Batman Forever, Batman: Mask of the Phantasm
Query 2’:	find movie similar to “the Dark Knight” taking “Hancock”, “The Curious Case of Benjamin Button” as examples
Answer:	Iron Man, Cloverfield, Indiana Jones and the Kingdom of the Crystal Skull

图 6 基于用户指导的相似性搜索

库、数据挖掘领域的专家，因此算法最后输出的也都是这类人；同样分析任务三、四用户提供的例子可以发现，任务三用户是想找到和《蝙蝠侠前传 2：黑暗骑士》相同主题的其他电影，任务四用户是想找到和该电影拍摄时间相近或相同题材的其他电影。基于用户提供的示例，可以明确用户的需求，进而指导异质网络挖掘的基于元路径的拓扑特征选取。

异质网络挖掘中特征设计目前主要是基于元路径开展的，不同的元路径携带着不同的语义信息，定义好合适元路径，便能得到不错的效果。但是目前还有很多工作急需深入，如元路径权重的学习、元路径特征和外部属性特征的结合，以及是否存在元路径以外的特征构造方法等，都是下一步的研究重点。

2.2 异质网络数据结构特征学习

异质网络的特征学习研究目前还处于初步探索阶段，公开发表的研究成果并不多，但从研究的意义和目前的趋势来看，今后一段时间对这一研究必将涌现出诸多成果。现有的一些这方面的工作包括文献[43-46]。

文献[43]将社会媒体网络数据（异质网络）中的图片节点和文本节点统一嵌入到一个表示空间中，该表示方法同时考虑到了节点的内容信息和网络的结构信息，作者采用深度神经网络的方法建模异质节点之间的复杂交互关系，并在 BlogCatalog 和 NUS-WIDE 数据集上进行了异质节点分类、聚类、多模态搜索等任务，发现该方法均要优于传统的方法。

文献[45]利用网络嵌入的方法丰富节点的信息，解决异质网络链路预测问题的稀疏性问题，提出了元路径和网络嵌入结合的拓扑特征构造方法，用于预测学者将会在什么期刊或者会议上发表文章。经实验，该方法要比传统的方法，尤其是在稀疏网络中，链路预测的精度要提高很多。

文献[44]提出了基于元路径指导的异质网络表示学习框架 Esim，用于异质网络中的相同类型节点的相似搜索任务。该方法以用户提供的元路径作为用户的偏好，基本思路是，如果两个节点经常出现在用户提供的元路径的实例中，那么这两个节点的表示向量的余弦相似度应该很高。作者设计了对应的损失函数和学习框架，并采用负采样的方法加速学习的过程。实验表明，有效结合元路径和网络表示学习的 Esim 算法在分类精度上要优于这些传统的算法，从而验证了该想法的可行性；同时，因为本文提出的算法可扩展性强，易于并行实现，适用于大规模的网络数据。

文献[46]提出了一种结合特定任务要求和元路径指导的异质网络表示学习框架，具体解决的是在论文双盲评审下的作者身份识别问题。作者构建了一个包括作者、文章、关键词、发表会议/期刊和发表年份五个不同类型节点的异质网络，设计了两个学习目标。一个目标是匿名文章作者身份的识别，在该目标下文章节点的表示向量为关键词向量、发表地向量、发表年份向量的加权平均。另一个目标是一般的异质网络的表示学习目标，在该目标下节点的表示向量应该要保证节点在原始网络拓

扑中的结构，主要是在元路径上的相似性；即如果两个节点经常在一条元路径上共现，那么说明这两个节点在网络拓扑上是相似的，学习出的向量之间的余弦相似度或点乘积值也应该很大。在这两个优化目标的指导下，学习出的节点向量既可以保证节点在原始网络结构中的相似性，又可以用于匿名文章作者身份识别的任务。在 Aminer 学术网络上的实验结果表明，该组合方法在预测精度上要明显优于只基于一个目标函数的学习方法；同时该方法也容易实现并行化，从而在大规模的数据集上也能够在合理的计算时间内得出结果。

3 结束语

正如深度学习对图像数据、文本数据

的变革一样，其对网络数据的变革同样重大。传统的网络结构特征设计对于一些具体的问题来说依然非常重要，但已不是唯一的解决途径，将表示学习应用于网络结构特征的学习必然是今后网络数据挖掘的新的范式。如何更有效地提高模型对网络数据的结构表示能力，包括对各种类型的网络模型和同质网络、异质网络、多层网络、符号网络等等的表示学习，以及如何更有效地应用网络表示学习解决更多具体的网络数据挖掘问题（监督学习问题包括图分类、图回归等，无监督学习问题包括图聚类、社区发现等，强化学习问题包括图的组合优化问题等）等都是未来的重要研究课题。

参考文献

- [1] M. Chen, Q. Yang, X. Tang, Directed Graph Embedding, in: IJCAI, 2007, pp. 2707-2712.
- [2] R.A. Rossi, N.K. Ahmed, Role discovery in networks, IEEE Transactions on Knowledge and Data Engineering, 27 (2015) 1112-1131.
- [3] K. Henderson, B. Gallagher, L. Li, L. Akoglu, T. Eliassi-Rad, H. Tong, C. Faloutsos, It's who you know: graph mining using recursive structural features, in: Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2011, pp. 663-671.
- [4] R.N. Lichtenwalter, J.T. Lussier, N.V. Chawla, New perspectives and methods in link prediction, in: Proceedings of the 16th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2010, pp. 243-252.
- [5] K. Henderson, B. Gallagher, T. Eliassi-Rad, H. Tong, S. Basu, L. Akoglu, D. Koutra, C. Faloutsos, L. Li, Rolx: structural role extraction & mining in large graphs, in: Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2012, pp. 1231-1239.
- [6] R. Rossi, B. Gallagher, J. Neville, K. Henderson, Role-dynamics: fast mining of large dynamic networks, in: Proceedings of the 21st International Conference on World Wide Web, ACM, 2012, pp. 997-1006.
- [7] M. Rahman, M. Bhuiyan, M.A. Hasan, Graft: An approximate graphlet counting algorithm for large graph analysis, in: Proceedings of the 21st ACM international conference on Information and knowledge management, ACM, 2012, pp. 1467-1471.
- [8] R. Rossi, J. Neville, Time-evolving relational classification and ensemble methods, in: Pacific-Asia Conference on Knowledge Discovery and Data Mining, Springer, 2012, pp. 1-13.
- [9] J. Neville, D. Jensen, L. Friedland, M. Hay, Learning relational probability trees, in: Proceedings of the ninth ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2003, pp. 625-630.
- [10] A. McGovern, N.C. Hiers, M. Collier, D.J. Gagne II, R.A. Brown, Spatiotemporal relational probability trees: An

- introduction, in: Data Mining, 2008. ICDM'08. Eighth IEEE International Conference on, IEEE, 2008, pp. 935-940.
- [11] T. Kamada, S. Kawai, An algorithm for drawing general undirected graphs, Information processing letters, 31 (1989) 7-15.
 - [12] N. Landwehr, K. Kersting, L.D. Raedt, Integrating naive bayes and foil, Journal of Machine Learning Research, 8 (2007) 481-507.
 - [13] S.-H. Cha, Comprehensive survey on distance/similarity measures between probability density functions, City, 1 (2007) 1.
 - [14] Y. Yao, Information-theoretic measures for knowledge discovery and data mining, in: Entropy Measures, Maximum Entropy Principle and Emerging Applications, Springer, 2003, pp. 115-136.
 - [15] I. Guyon, S. Gunn, M. Nikravesh, L.A. Zadeh, Feature extraction: foundations and applications, Springer, 2008.
 - [16] M. Kearns, Y. Mansour, A.Y. Ng, An information-theoretic analysis of hard and soft assignment methods for clustering, in: Learning in graphical models, Springer, 1998, pp. 495-520.
 - [17] D.N. Reshef, Y.A. Reshef, H.K. Finucane, S.R. Grossman, G. McVean, P.J. Turnbaugh, E.S. Lander, M. Mitzenmacher, P.C. Sabeti, Detecting novel associations in large data sets, science, 334 (2011) 1518-1524.
 - [18] C.L. Mallows, Some comments on C p, Technometrics, 15 (1973) 661-675.
 - [19] E.J. Hannan, B.G. Quinn, The determination of the order of an autoregression, Journal of the Royal Statistical Society. Series B (Methodological), (1979) 190-195.
 - [20] S. Milojević, Power law distributions in information science: Making the case for logarithmic binning, Journal of the American Society for Information Science and Technology, 61 (2010) 2417-2425.
 - [21] S.T. Roweis, L.K. Saul, Nonlinear dimensionality reduction by locally linear embedding, Science, 290 (2000) 2323-2326.
 - [22] M. Belkin, P. Niyogi, Laplacian eigenmaps and spectral techniques for embedding and clustering, in: NIPS, 2001, pp. 585-591.
 - [23] L. Tang, H. Liu, Relational learning via latent social dimensions, in: Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2009, pp. 817-826.
 - [24] R.M. Nallapati, A. Ahmed, E.P. Xing, W.W. Cohen, Joint latent topic models for text and citations, in: Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2008, pp. 542-550.
 - [25] J. Chang, D.M. Blei, Relational Topic Models for Document Networks, in: AISTATS, 2009, pp. 81-88.
 - [26] T.M. Le, H.W. Lauw, Probabilistic latent document network embedding, in: 2014 IEEE International Conference on Data Mining, IEEE, 2014, pp. 270-279.
 - [27] T. Iwata, K. Saito, N. Ueda, S. Stromsten, T.L. Griffiths, J.B. Tenenbaum, Parametric embedding for class visualization, Neural Computation, 19 (2007) 2536-2556.
 - [28] B. Perozzi, R. Al-Rfou, S. Skiena, Deepwalk: Online learning of social representations, in: Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining, ACM, 2014, pp. 701-710.
 - [29] G.E. Hinton, Learning distributed representations of concepts, in: Proceedings of the eighth annual conference of the cognitive science society, Amherst, MA, 1986, pp. 12.
 - [30] J. Tang, M. Qu, M. Wang, M. Zhang, J. Yan, Q. Mei, Line: Large-scale information network embedding, in: Proceedings of the 24th International Conference on World Wide Web, ACM, 2015, pp. 1067-1077.
 - [31] A. Grover, J. Leskovec, node2vec: Scalable feature learning for networks, in: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, ACM, 2016, pp. 855-864.
 - [32] Z.G. Kingsley, Selective studies and the principle of relative frequency in language, in, Harvard University Press, Cambridge (Mass.), 1932.
 - [33] J.D. Noh, H. Rieger, Random walks on complex networks, Physical review letters, 92 (2004) 118701.
 - [34] C. Yang, Z. Liu, Comprehend deepwalk as matrix factorization, arXiv preprint arXiv:1501.00358,(2015).
 - [35] S. Cao, W. Lu, Q. Xu, Grarep: Learning graph representations with global structural information, in: Proceedings of the 24th ACM International on Conference on Information and Knowledge Management, ACM, 2015, pp. 891-900.
 - [36] X. Wang, P. Cui, J. Wang, J. Pei, W. Zhu, S. Yang, Community Preserving Network Embedding, in: AAAI,

- [illegible]



国防科技大学系统工程学院博士研究生。主要研究方向为网络数据挖掘、表示学习。



国防科技大学系统工程学院副研究员，硕士生导师。主要研究方向为复杂系统分析与智能指挥控制辅助决策技术等。



国防科技大学系统工程学院研究员，博士生导师。主要研究方向为人工智能与作战任务规划技术等。



国防科技大学系统工程学院教授，博士生导师。主要研究方向为人工智能与作战计划系统技术等。

生物序列的特征化描述方法

何文颖, 邹 权

天津大学

引言

随着新一代高通量测序技术的出现, 产生了大量的生物学数据, 如 DNA、RNA 和蛋白质序列数据, 以及蛋白质二级结构和三级结构数据、蛋白质相互作用数据等。每天都有成千上万的功能未知但序列已知的生物数据, 被源源不断地提交到相应的生物学数据库中。对大量生物数据的管理、分析和信息化需求促进了生物信息学的产生和迅速发展。生物信息学已成为生物学领域的一个重要组成部分, 如图 1 所示。利用生物信息学工具和技术比较基因和基因组数据, 可以帮助人们了解生物学的进化过程。互联网的数据库技术为生物信息学的课题研究提供了数据基础, 几乎所有测定的生物数据都能从各种数据库中下载得到。相对传统的生物学

来说, 生物信息学有其独特的优势, 一方面可以处理海量数据, 节省大量的人力物力; 另一方面, 它可以从数据中挖掘出新的生物学规律, 从而有助于全面深入地了解基因、蛋白的生物学功能以及生物学过程。




图 1 生物信息学是计算机科学、数学和分子生物学之间的桥梁

- (I) 数据库技术为生物信息学的研究提供了数据基础;
- (II) 生物信息学方向之生物序列(位点)预测流程图

蛋白质序列预测在计算生物学和生物信息学领域中起着重要作用。蛋白序列预测从根本上来说是一个二分类问题。蛋白质序列研究的重点有两个方面，一个是如何进行蛋白质序列的有效表示，从本质上加强蛋白质的预测性能；第二个是开发强有力的分类算法，一个好的分类算法能够使得分类精度明显提高。本文主要讨论了基于蛋白序列信息的特征提取方法。

由于生物数据本身的复杂性及不同研究领域存在不同的评价标准，人们很难从数据本身去发现基因和蛋白的功能信息，而且生物语言不能被机器学习算法识别。如何从一条氨基酸序列中提取它的有用信息，并且用适当的数学方法描述或表达这些信息，使之正确反映序列与结构或功能之间的关系，对于蛋白质分类研究至关重要，也是决定分类质量的关键。尽管研究人员提出了许多编码算法来提取生物序列中的隐藏信息，但是，大部分现存的方法忽略了相邻氨基酸的位置信息，尤其是它们在正负样本集中的差异。本文详细介绍和分析了基于序列信息的特征提取方法，主要包括氨基酸组成（AAC）、基于K-联体（ k -mer）频度的特征提取方法，以及伪氨基酸组分（PseAAC）、双边贝叶斯（BPB）和改进的双边贝叶斯（ANBPB）等。研究人员可以根据不同的需求选取相应的特征提取方法。

基于各种应用提出的大量特征提取方法通常是高维的，具有冗余和不相关特征。在样本有限的情况下，用大量的特征来设计分类器，不论是从计算时间还是从分类

性能来看都不合时宜，很难获得一个具有良好泛化能力的预测模型。因此，进行有效的特征选择是蛋白质序列预测中必须要解决的问题，在海量数据背景下尤为重要。

特征提取

氨基酸是组成蛋白质的基本单位。一条蛋白质包含的基本信息是20种氨基酸的组成信息、位置信息和顺序信息。基于氨基酸组成和位置特异性的特征提取算法是最简单、最直观的方法。

令 S 表示蛋白质序列，它由20种氨基酸组成，可以表示为

$$S=R_1R_2R_3R_4R_5R_6\cdots R_L \quad (1)$$

其中， L 表示蛋白质序列的长度； R_1 表示序列 S 第一个位置上的氨基酸； R_2 表示第二个位置上的氨基酸，以此类推。

基于氨基酸组成的特征提取算法

氨基酸含量（AAC）

通常情况下，计算氨基酸含量，即20种氨基酸在一条蛋白质中的出现频率，可获取蛋白质的基本信息。对于蛋白序列 S ，令 f_x 表示20种氨基酸的出现频率。那么，式(1)可以表示成

$$P=[p_1, p_2, \dots, p_{20}]^T \quad (2)$$

其中

$$p_x = \frac{f_x(S)}{\sum_{i=1}^{20} f_i(x)} \quad i, x=1, 2, \dots, 20 \quad (3)$$

本方法实现简单，且不同长度的氨基酸序列生成的特征向量长度相同，方便运算和比较。但该方法没有考虑氨基酸序列内部的顺序信息，丢失了氨基酸的位置信息，

因此, 预测质量将会受到限制。

如何构建能够反映序列模式且能够抓住与预测目标密切相关的关键特征? 随后, 一些将局部序列信息考虑在内的特征方法被提出, 如 k -mer 组成^[1-2]、 k -spaced 氨基酸对组成^[3-4]等。

k -mer 组成 (K-mer)

为了考虑蛋白质序列的局部序列信息, 以固定长度的 k -联体氨基酸片段 (k -mer)^[1,5] 为研究对象, 计算每条序列中的 k -mer 组成。当 $k=1$ 时, 本方法即为氨基酸组成的特征提取方法; 当 $k=2$ 时, 由 20 种氨基酸组成的 2-mer 有 $20^2=400$ 种组合, 即 AA, AC, AD,..., YY。我们可以统计 400 种短序列在 S 中的出现频率, 由此可对 S 构建一个 400 维的特征向量。随着 k 的增长, 构造的特征维数成几何方式增长, 而且会导致稀疏矩阵的产生, 高维特征向量为后续的机器学习算法引入维数灾难, 使得分类性能显著下降。最近的一些研究中通过氨基酸类简约化^[6]、非匹配^[7]和其他特征选择技术^[8]来降低 k -mer 特征提取算法产生的高维问题。

k -空格氨基酸对组成 (CKSAAP)

k -空格氨基酸对^[3-4]是指任意两个氨基酸之间, 被 k 个任意类型的氨基酸隔开。例如, AxxxC 代表丙氨酸和半胱氨酸组成的氨基酸对被三个任意类型的氨基酸所隔开, 这里 $k=3$ 。那么, 对于每个 k 值来说, 都对应一个 400 维的向量表示。以 $k=1$ 为例, 对于样本 S , 其所有的氨基酸按字母表顺序排序为 (AA, AC, AD, AE, ..., YY)₄₀₀, 则特征向量可以表示为

$$\left(\frac{N_{AXA}}{L-k-1}, \frac{N_{AXC}}{L-k-1}, \frac{N_{AXD}}{L-k-1}, \dots, \frac{N_{YXY}}{L-k-1} \right)_{400} \quad (4)$$

其中, 分子中的 N 代表被 k 个任意氨基酸所隔开的此种氨基酸对的数量, 而分母 $L-k-1$ 表示被 k 个任意氨基酸所隔开的所有氨基酸对的总数。

以上的特征提取方法仅考虑了短的局部序列信息, 忽视了重要的长的全局蛋白序列信息。为了解决此类问题, Chou^[9]等提出了伪氨基酸组分 (PseAAC) 的特征提取方法。

伪氨基酸组分 (PseAAC)

自 2001 年伪氨基酸组分^[9]的概念被提出来, 它已经渗透到几乎所有的蛋白生物信息学分析领域, 这一点可以从文献 [10] 部分的引用及最新的综述^[11]中有直观展示。

伪氨基酸组分特征保留了氨基酸含量的特征, 并通过扩展特征向量来表示位置信息。依据文献 [9], 伪氨基酸组分特征向量可表示为

$$P = [p_1, p_2, \dots, p_{20}, p_{20+1}, \dots, p_{20+\lambda}] \quad (5)$$

在 P 中, 前 20 个分量 $p_1, p_2, \dots, p_{20}$ 表示 20 个氨基酸的出现频率, 分量 $p_{20+1}, p_{20+2}, \dots, p_{20+\lambda}$ 表示通过多模式整合的序列信息。通常情况下, 这些补充因素是序列中一系列的阶层信息, 如图 2 所示。

在经典伪氨基酸组分特征提取基础上, 一些新的研究将 PseAAC 与伪二联体或 k -空格氨基酸对进行整合^[12]。由于 PseAAC 特征提取方法在计算蛋白组学的成功, 该概念也扩展到了 DNA 和 RNA 领域。




图2 伪氨基酸组成成分模型的残基关系图

基于氨基酸位置特异性倾向的特征提取算法

位置特异性理论已成功应用于生物信息学的许多领域，如预测羟基化位点^[13]、DNA结合蛋白预测^[14]和增强子预测^[15]等。位置特意向倾向的原理是计算氨基酸在某些位置出现的频率，并从序列中提取统计信息。

双边贝叶斯算法 (BPB)

基于双边贝叶斯^[16]的特征提取方法在

2009年被提出，它对每一个样本充分考虑了来自正负训练样本集的信息^[17-18]，已广泛应用于甲基化位点预测^[16]和增强子预测^[19]等生物信息学研究。

已知正负样本集，可以计算出正负样本集中每个氨基酸在每个位置的频率，分别对应氨基酸位置特异性倾向矩阵 F_P 和 F_N ：

$$F_P = \begin{bmatrix} p_{1,1} & p_{1,2} & \cdots & p_{1,L} \\ p_{2,1} & p_{2,2} & \cdots & p_{2,L} \\ \vdots & \vdots & & \vdots \\ p_{20,1} & p_{20,2} & \cdots & p_{20,L} \end{bmatrix}, F_N = \begin{bmatrix} n_{1,1} & n_{1,2} & \cdots & n_{1,L} \\ n_{2,1} & n_{2,2} & \cdots & n_{2,L} \\ \vdots & \vdots & & \vdots \\ n_{20,1} & n_{20,2} & \cdots & n_{20,L} \end{bmatrix} \quad (6)$$

其中， L 为样本长度； p_{ij} 、 n_{ij} 分别表示正负样本集中第 i 个氨基酸在第 j 个位置出现的频率。

对样本 S ，构造特征向量

$$D_{BPB} = (p_1, p_2, \dots, p_L, n_{L+1}, n_{L+2}, \dots, n_{2L})^T \quad (7)$$

式中， $(p_1, p_2, \dots, p_L)$ 代表样本 S 中每个位置上的氨基酸在正样本集中每个位置出现的频率； $(n_{L+1}, n_{L+2}, \dots, n_{2L})$ 代表样本 S 中每个位置上的氨基酸在负样本集中每个位置出现的频率。

$$p_i = \begin{cases} p_{1,i} & R_i = A \\ p_{2,i} & R_i = C \\ \vdots & \\ p_{20,i} & R_i = Y \end{cases} \quad (8)$$

$$n_{L+i} = \begin{cases} n_{1,i} & R_i = A \\ n_{2,i} & R_i = C \\ \vdots & \\ n_{20,i} & R_i = Y \end{cases} \quad (i=1, 2, \dots, L)$$

从特征的提取过程来看，每个新样本都能获得来自正样本集（正训练集）和负样

本集（负训练集）的位置特异性信息，对机器学习算法来说可以挖掘出更易于识别样本类别的规则。

改进的双边贝叶斯算法 (ANBPB)

ANBPB 算法是对 BPB 算法的修饰算法，已在 O-糖基化位点预测^[17]和羟基化位点预测^[20]上有良好的表现。此方法采用基于正态分布原理来计算不同位置上氨基酸出现的后验概率：

$$P_j = P(X \leq X_{ij}) = \varphi(X'_{ij}) \quad (9)$$

式中， X'_{ij} 表示训练集中每个氨基酸在每个位置出现的频率； X'_{ij} 是 X_{ij} 标准化值； $\varphi(x)$ 标准正态分布函数

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt \quad (10)$$

更多的细节可以参考图 3。




图 3 ANBPB 特征编码算法示意图

BPB 和 ANBPB 特征提取算法之间的主要区别在于对后验概率的估计，这个后验概率表明样本集中每个氨基酸在每个位置上的特异性倾向^[16]。BPB 的后验概率由每个氨基酸在每个位置上出现的频率表示，而 ANBPB 从有限的样本来推断总体样本上的氨基酸位置信息。有关此算法的更多详

细信息参见文献 [16]。

还有许多基于氨基酸位置特异性倾向的特征提取算法，同样可以与机器学习算法有效地结合建立预测模型，并分析生物信息学和系统生物学的各种任务。

工具

最近，Liu 等^[15]建立了 Pse-in-One^[10]和 Pse-in-One2.0 强大的网络服务器，以产生满足用户各方面需求的伪氨基酸、伪 DNA 和伪 RNA 的特征向量。我们认为，基于位置特异性倾向的特征构建算法会成为其他特征提取算法的一个良好补充。

特征选择

特征选择算法依据不同的评价准则可分为过滤式、封装式和嵌入式方法^[21-23]。

过滤式特征选择方法作为一种预处理算法将特征进行排序，在不考虑预测模型的情况下根据排序选择特征子集，如 T-检验^[24]、信息增益 (IG)^[25]和最小冗余最大相关 (MRMR)^[26]等。其中，T-检验评估类间样本均数之间的差异程度；信息增益衡量一个特征对某类的信息增益（熵）。

封装式特征选择方法把分类器作为一个黑盒，根据特征的预测能力来选择特征子集。基于支持向量机的封装方法已经被广泛应用于机器学习领域，SVM-RFE^[27]采用淘汰制递归的消除特征集中的劣势特征。依据特征在目标函数的减少量对特征项排序，递归地消除底部的特征项。

嵌入式特征选择算法作为学习算法的部分嵌入其中，特征选择和训练过程同时

进行。直接由分类模型来判断选择特征还是拒绝特征。随机森林^[28]是一个经典的嵌入算法，用不同的原始数据样本创建一些决策树，使用不同的平均算法来提高准确度。

根据 Chou 的五步走策略^[29]，建立一个有效的生物系统预测模型，需要考虑以下五个基本步骤：① 构建一个有效的基准数据集；② 对样本进行有效的特征表达；③ 开发一个强有力的机器学习算法；④ 通过交叉验证判断模型的预测性能；⑤ 为预测模型建立一个用户友好的 web 服务器。其中，最重要、最困难的就是对样本进行有效的特

征表达，这也成为生物信息学的一个研究重点。

本文对基于序列信息的蛋白质特征提取算法作了简要的说明和比较分析。读者可以根据需要选择相应的算法。除此之外，不同特征的融合可以发挥各种特征提取方式的共同作用进而提高模型的预测能力。针对大数据高维度问题，许多研究表明，更多的信息在机器学习应用中并不总是有效的。特征选择技术可以解决这个问题，它还有很多潜在的优点，比如便于数据可视化及对数据的理解，以及提高训练效率和预测精度，并且增强模型的泛化能力。

参考文献

- [1] Liu B, Wang X, Lin L, Dong Q, Wang X: A discriminative method for protein remote homology detection and fold recognition combining Top-n-grams and latent semantic analysis. *BMC Bioinformatics* 2008, 9:510.
- [2] Zhu PP, Li WC, Zhong ZJ, Deng EZ, Ding H, Chen W, Lin H: Predicting the subcellular localization of mycobacterial proteins by incorporating the optimal tripeptides into the general form of pseudo amino acid composition. *Molecular bioSystems* 2015, 11(2):558-563.
- [3] Hasan MM, Zhou Y, Lu X, Li J, Song J, Zhang Z: Computational identification of protein pupylation sites by using profile-based composition of k-spaced amino acid pairs. *PloS one* 2015, 10(6):e0129635.
- [4] Chen K, Kurgan LA, Ruan J: Prediction of flexible/rigid regions from protein sequences using k-spaced amino acid pairs. *BMC Struct Biol* 2007, 7:25.
- [5] Zhang Y, Wang X, Kang L: A k-mer scheme to predict piRNAs and characterize locust piRNAs. *Bioinformatics* 2011, 27(6):771-776.
- [6] Liu B, Xu J, Lan X, Xu R, Zhou J, Wang X, Chou K-C: iDNA-Prot[dis]: Identifying DNA-Binding Proteins by Incorporating Amino Acid Distance-Pairs and Reduced Alphabet Profile into the General Pseudo Amino Acid Composition. *PLoS ONE* 2014, 9(9):e106691.
- [7] Liu B, Xu J, Zou Q, Xu R, Wang X, Chen Q: Using distances between Top-n-gram and residue pairs for protein remote homology detection. *BMC Bioinformatics* 2014, 15(Suppl 2):S3.
- [8] Lin H, Chen W, Yuan LF, Li ZQ, Ding H: Using over-represented tetrapeptides to predict protein submitochondria locations. *Acta biotheoretica* 2013, 61(2):259-268.
- [9] Chou KC: Prediction of protein cellular attributes using pseudo-amino acid composition. *Proteins* 2001, 43(3):246-255.
- [10] Liu B, Liu F, Wang X, Chen J, Fang L, Chou KC: Pse-in-One: a web server for generating various modes of pseudo components of DNA, RNA, and protein sequences. *Nucleic Acids Res* 2015, 43(W1):W65-71.
- [11] Chen W, Lin H, Chou KC: Pseudo nucleotide composition or PseKNC: an effective formulation for analyzing genomic sequences. *Mol Biosyst* 2015, 11(10):2620-2634.
- [12] Tang H, Chen W, Lin H: Identification of immunoglobulins using Chou's pseudo amino acid composition with

- [illegible]



邹权

天津大学计算机科学与技术学院研究员，博士生导师。主要研究方向为生物信息学、机器学习和字符串并行算法。

面向大规模数据 的高斯过程机器学习模型

研究 进展

贺建军，许小可

大连民族大学

引言

高斯过程模型是源于贝叶斯神经网络而逐渐发展起来的一种机器学习算法建模工具。20世纪90年代中期，Neal^[1]在对贝叶斯神经网络的研究过程中发现，具有一个隐藏层的神经网络当隐藏节点的个数趋于无穷时，该神经网络等价于一个高斯过程。此发现激发了人们直接利用高斯过程处理监督学习问题的兴趣，Rasmussen^[2]在他的博士论文里详细研究了面向回归问题的高斯过程模型；文献[3]系统地研究了基于高斯过程模型的回归和分类算法。随后，许多学者从不同方面展开了研究。经过20年的发展，高斯过程模型目前已经发展成为了一种具有完整理论体系的建模工具，并被用于回归^[2]、分类^[3]、多任务学习^[4]、强化学习^[5]、半监督学习^[6]、排序学习^[7]、多示例多标记学习^[8]、多视角学习^[9]和偏标记学习^[10]等各种

机器学习框架中。

令 D 表示观察数据、 H 表示假设空间，机器学习的目的就是利用数据 D 在假设空间 H 中寻找能对新样本的类别标记进行精确预测的假设 $f \in H$ 。高斯过程模型的基本思想是赋予 f 一个高斯过程先验 $f(x) \sim \text{GP}(0, k(x, x'))$ ，然后利用贝叶斯公式 $p(f|D) = \frac{p(D|f)p(f)}{\int p(D|f)p(f)df}$ 推理得到 f 的后验概率分布 $p(f|D)$ ，从而得到最佳假设。其中， $k(x, x')$ 表示协方差函数； $p(D|f)$ 是似然，表示 f 成立的情况下观察到数据 D 的概率，它实质上反映的就是经验风险。以回归和二分类问题为例，令 $\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^n$ 和 $\mathbf{Y} = [y_1, y_2, \dots, y_n]^T$ 分别表示训练样本的特征向量和类别标记构成的集合，根据高斯过程模型中先验概率的定义，潜变量函数（假设） f 在 $\mathbf{X}$ 上的函数值 $\mathbf{F}_X = [f_1, f_2, \dots, f_n]^T$ 的先验概率是一个多元高斯分布

$p(\mathbf{F}_X|\mathbf{X})=N(\mathbf{F}_X|0,\mathbf{K}_X)$, 其中 $\mathbf{K}_X$ 为 $\mathbf{X}$ 中样本间的协方差矩阵 ($\mathbf{K}_X(i,j)=k(\mathbf{x}_i,\mathbf{x}_j)$); 然后利用贝叶斯公式, $\mathbf{F}_X$ 的后验概率分布可以表示为

$$p(\mathbf{F}_X|\mathbf{X},\mathbf{Y}) = \frac{p(\mathbf{F}_X|\mathbf{X})p(\mathbf{Y}|\mathbf{F}_X)}{\int p(\mathbf{F}_X|\mathbf{X})p(\mathbf{Y}|\mathbf{F}_X)d\mathbf{F}_X}$$

最后根据 $p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})$ 可以计算得到 f 在待预测样本 $\mathbf{x}_*$ 上的函数值的后验概率

$$p(f_*|\mathbf{X},\mathbf{Y}) = \int p(f_*|\mathbf{F}_X)p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})d\mathbf{F}_X$$

从而可以得到 $\mathbf{x}_*$ 的类别标记。对于回归问题, 定义的似然函数通常是一个高斯型函数, 如 $p(\mathbf{Y}|\mathbf{F}_X)=N(\mathbf{Y}|\mathbf{F}_X,\sigma^2\mathbf{I})$ 。因此 $p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})$ 仍然是一个高斯分布, 从而可以得到 $p(f_*|\mathbf{X},\mathbf{Y})$ 的分析表达式

$$p(f_*|\mathbf{X},\mathbf{Y})=N(f_*|\mathbf{K}_{X*}^T(\mathbf{K}_X+\sigma^2\mathbf{I})^{-1}\mathbf{Y},\mathbf{K}_{X*}-\mathbf{K}_{X*}^T(\mathbf{K}_X+\sigma^2\mathbf{I})^{-1}\mathbf{K}_{X*})$$

其中 $\mathbf{K}_{X*}$ 表示 $\mathbf{X}$ 中样本和 $\mathbf{x}_*$ 之间的协方差矩阵, $\mathbf{K}_*=k(\mathbf{x}_*,\mathbf{x}_*)$ 。对于分类问题, 似然函数通常是一个非高斯型函数, 如常用的似然函数 $p(\mathbf{Y}|\mathbf{F}_X)=\prod_{i=1}^n \frac{1}{1+e^{-y_i f_i}}$ 是一个 S 型函数。

因此 $p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})$ 不是一个高斯分布, 需要先计算 $p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})$ 的一个近似表达式 $q(\mathbf{F}_X)$ (通常是一个高斯分布); 然后利用 $q(\mathbf{F}_X)$ 来近似地计算 $p(f_*|\mathbf{X},\mathbf{Y}) \approx \int p(f_*|\mathbf{F}_X)q(\mathbf{F}_X)d\mathbf{F}_X$, 以上就是传统高斯过程模型解决回归或分类问题的基本过程。由于需要计算并存储协方差矩阵 $\mathbf{K}_X$ 及其逆矩阵, 而且当似然函数是非高斯函数时还需要计算后验概率分布 $p(\mathbf{F}_X|\mathbf{X},\mathbf{Y})$ 的近似表达式, 传统高斯过程模型的存储和计算复杂度通常分别是 $O(n^2)$ 和 $O(n^3)$, 因此只能处理训练样本规模比较小的问题。为了降低模型的复杂度, 使其可以处理大规模数据, 近年来, 人们先后提出了诱导变量、协方差函数分解、协方差

矩阵逼近和贝叶斯委员会机器等几种解决方法, 本文将对这些方法进行简要介绍。

诱导变量方法

诱导变量方法的基本思想是从样本集合 $\mathbf{X}$ 中, 选择一个样本数目较少的子集 $\mathbf{U} \subset \mathbf{X}$, 构造一组诱导变量来辅助计算 $\mathbf{F}_X$ 的概率分布, 从而降低模型的复杂度。

由于回归问题的主要计算量来自 $\mathbf{F}_X$ 的先验概率 $p(\mathbf{F}_X|\mathbf{X})$, 因此早期的诱导变量方法主要侧重如何降低 $p(\mathbf{F}_X|\mathbf{X})$ 的计算复杂度。利用乘法法则可以将 $p(\mathbf{F}_X|\mathbf{X})$ 分解为 $p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})$ 和 $p(\mathbf{F}_U|\mathbf{X})$ 的乘积, 即

$$p(\mathbf{F}_X|\mathbf{X})=p(\mathbf{F}_U|\mathbf{X})p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X}),$$

其中 $\mathbf{F}_U$ 表示 f 在 $\mathbf{U}$ 上的函数值。根据条件概率公式, $p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})$ 的表达式可以分析得到, 即

$$p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})=N(\mathbf{F}_X|\mathbf{K}_{XU}\mathbf{K}_U^{-1}\mathbf{F}_U,\boldsymbol{\Sigma}_X)$$

其中 $\mathbf{K}_{XU}$ 和 $\mathbf{K}_U$ 是对应的协方差矩阵、 $\boldsymbol{\Sigma}_X = \mathbf{K}_X - \mathbf{K}_{XU}\mathbf{K}_U^{-1}\mathbf{K}_{XU}^T$ 。由于 $p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})$ 的计算复杂度仍然较高, 因此人们进一步提出在“已知 $\mathbf{F}_U$ 的条件下, $\mathbf{F}_X$ 中的变量之间具有一定的独立性”这个假设条件下来近似地表示 $p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})$, 比较有代表性的有 DTC^[11]、FITC^[12] 和 PITC^[13] 三种。DTC 方法假设 $\mathbf{F}_X$ 中的变量之间的协方差为 0, 因此在该类方法中

$$p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X}) \approx N(\mathbf{F}_X|\mathbf{K}_{XU}\mathbf{K}_U^{-1}\mathbf{F}_U, 0)$$

FITC 方法假设 $\mathbf{F}_X$ 中的各个变量之间是相互独立的, 因此

$$p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X}) \approx N(\mathbf{F}_X|\mathbf{K}_{XU}\mathbf{K}_U^{-1}\mathbf{F}_U, \text{diag}(\boldsymbol{\Sigma}_X))$$

PITC 方法假设 $\mathbf{F}_X$ 的各个变量之间是部分独立的, 因此条件变量 $\mathbf{F}_X|\mathbf{F}_U$ 之间的协方差矩阵是一个分块对角矩阵, $p(\mathbf{F}_X|\mathbf{F}_U, \mathbf{X})$ 可

以表示为 $N(\mathbf{F}_X | \mathbf{K}_{XU} \mathbf{K}_U^{-1} \mathbf{F}_U, \text{blockdiag}(\boldsymbol{\Sigma}_X))$ 。

可以看出, 利用以上几种方法近似计算先验概率 $p(\mathbf{F}_X | \mathbf{X})$ 的复杂度是 $O(nm^2)$, 其中 m 表示诱导样本的个数。由于当 m 的取值通常达到数百时 (远远小于 n), 算法就可以取得较高的精度, 因此采用以上描述的诱导变量方法可以有效降低模型的计算复杂度。但是该类方法也存在很多问题, 例如利用边缘似然函数学习参数的效果将较差, 对于非高斯型似然函数, $\mathbf{F}_X$ 的后验概率分布的计算仍然很困难, 不利于处理回归问题以外的机器学习问题。针对这些问题, 近年来, 人们开始关注直接逼近后验概率分布 $p(\mathbf{F}_X | \mathbf{X}, \mathbf{Y})$ 的诱导变量方法的研究。与传统高斯过程模型中利用贝叶斯公式直接计算 $p(\mathbf{F}_X | \mathbf{X}, \mathbf{Y})$ 的方式不同, 该类方法的基本思想是先计算联合后验概率分布 $p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y})$ 的一个高斯逼近 $q(\mathbf{F}_X, \mathbf{F}_U)$ (或者后验概率分布 $p(\mathbf{F}_U | \mathbf{X}, \mathbf{Y})$ 的高斯逼近 $q(\mathbf{F}_U) = N(\mathbf{F}_U | \boldsymbol{\mu}, \boldsymbol{\Sigma})$); 然后对 $\mathbf{F}_U$ 积分来计算 $p(\mathbf{F}_X | \mathbf{X}, \mathbf{Y})$, 即

$$\begin{aligned} p(\mathbf{F}_X | \mathbf{X}, \mathbf{Y}) &= \int p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y}) d\mathbf{F}_U \\ &\approx \int q(\mathbf{F}_X, \mathbf{F}_U) d\mathbf{F}_U \end{aligned}$$

或者

$$\begin{aligned} p(\mathbf{F}_X | \mathbf{X}, \mathbf{Y}) &= \int p(\mathbf{F}_X | \mathbf{F}_U, \mathbf{X}) p(\mathbf{F}_U | \mathbf{X}, \mathbf{Y}) d\mathbf{F}_U \\ &\approx \int p(\mathbf{F}_X | \mathbf{F}_U, \mathbf{X}) q(\mathbf{F}_U) d\mathbf{F}_U \end{aligned}$$

这类方法的代表性成果是 2009 年 Titsias^[14] 面向回归问题提出的 VAR 算法。该算法先将联合概率分布 $p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y})$ 表示为

$$p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y}) = \frac{p(\mathbf{F}_X | \mathbf{F}_U, \mathbf{X}) p(\mathbf{F}_U | \mathbf{X}) p(\mathbf{Y} | \mathbf{F}_X)}{p(\mathbf{Y} | \mathbf{X})}$$

然后通过最小化 KL 散度 $\text{KL}(q(\mathbf{F}_X, \mathbf{F}_U) \| p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y}))$ 来计算 $q(\mathbf{F}_X, \mathbf{F}_U)$, 并且假设 $q(\mathbf{F}_X, \mathbf{F}_U) = p(\mathbf{F}_X | \mathbf{F}_U) q(\mathbf{F}_U)$, 因此只需通

过 $\min_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} \text{KL}(q(\mathbf{F}_X, \mathbf{F}_U) \| p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y}))$ 计算得到 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 即可。VAR 算法不仅计算复杂度是 $O(nm^2)$, 而且提供了一个可以优化诱导点位置的似然下界, 因此受到了人们广泛的关注。由于 $\min_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} \text{KL}(q(\mathbf{F}_X, \mathbf{F}_U) \| p(\mathbf{F}_X, \mathbf{F}_U | \mathbf{X}, \mathbf{Y}))$ 等价于

$$\begin{aligned} &\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} \iint q(\mathbf{F}_X, \mathbf{F}_U) \log \frac{p(\mathbf{F}_X, \mathbf{F}_U, \mathbf{Y} | \mathbf{X})}{q(\mathbf{F}_X, \mathbf{F}_U)} d\mathbf{F}_X d\mathbf{F}_U \\ &\text{而} \iint q(\mathbf{F}_X, \mathbf{F}_U) \log \frac{p(\mathbf{F}_X, \mathbf{F}_U, \mathbf{Y} | \mathbf{X})}{q(\mathbf{F}_X, \mathbf{F}_U)} d\mathbf{F}_X d\mathbf{F}_U \text{就是} \\ &\text{人们熟知的对数似然下界 (evidence lower} \\ &\text{bound, ELBO), 即} \end{aligned}$$

$$\begin{aligned} &\log p(\mathbf{Y} | \mathbf{X}) \\ &= \log \iint p(\mathbf{F}_X, \mathbf{F}_U, \mathbf{Y} | \mathbf{X}) d\mathbf{F}_X d\mathbf{F}_U \\ &\geq \iint q(\mathbf{F}_X, \mathbf{F}_U) \log \frac{p(\mathbf{F}_X, \mathbf{F}_U, \mathbf{Y} | \mathbf{X})}{q(\mathbf{F}_X, \mathbf{F}_U)} d\mathbf{F}_X d\mathbf{F}_U \end{aligned}$$

因此也可以直接通过最大化对数似然下界来计算 $q(\mathbf{F}_U)$ 。考虑到 VAR 算法不易采用随机梯度法来计算 $q(\mathbf{F}_U)$, Hensman 等^[15] 提出了新的对数似然下界

$$\begin{aligned} &\log p(\mathbf{Y} | \mathbf{X}) \\ &\geq \int \int q(\mathbf{F}_U) p(\mathbf{F}_X | \mathbf{F}_U, \mathbf{X}) \log p(\mathbf{Y} | \mathbf{F}_X) d\mathbf{F}_X d\mathbf{F}_U \\ &\quad - \text{KL}(q(\mathbf{F}_U) \| p(\mathbf{F}_U | \mathbf{X})) \end{aligned}$$

并且将其推广到了分类问题中^[16]。以上几种基于变分推理方法来计算 $q(\mathbf{F}_U)$ 的策略, 虽然在回归或者二分类问题中可以取得较好的效果, 但是不易处理似然函数更为复杂的问题, 为此本课题组提出了一种基于拉普拉斯方法来计算 $q(\mathbf{F}_U)$ 的策略^[17]。首先将 $p(\mathbf{F}_U | \mathbf{X}, \mathbf{Y})$ 表示为

$$p(\mathbf{F}_U | \mathbf{X}, \mathbf{Y}) = \frac{p(\mathbf{Y} | \mathbf{F}_U) p(\mathbf{F}_U | \mathbf{X})}{\int p(\mathbf{Y} | \mathbf{F}_U) p(\mathbf{F}_U | \mathbf{X}) d\mathbf{F}_U}$$

其中 $p(\mathbf{Y} | \mathbf{F}_U) = \int p(\mathbf{Y} | \mathbf{F}_X) p(\mathbf{F}_X | \mathbf{F}_U, \mathbf{X}) d\mathbf{F}_X$; 然后利用拉普拉斯方法来计算高斯逼近 $q(\mathbf{F}_U)$, 即

$$\mu = \operatorname{argmax}_{F_U} \log p(F_U | X, Y)$$

$$\Sigma = -(\nabla \nabla \log p(F_U | X, Y)|_{F_U=\mu})^{-1}$$

该方法不仅在二分类问题上可以取得较高的精度,而且可以处理具有复杂似然函数的问题,目前已经用于处理多示例学习问题和标记学习问题。此外, Hernández-Lobato 等^[18]在表达式

$$p(F_U | X, Y) = \frac{p(Y | F_U) p(F_U | X)}{\int p(Y | F_U) p(F_U | X) dF_U}$$

的基础上,并且在 FITC 条件先验假设 $p(F_X | F_U, X) \approx N(F_X | K_{XU} K_U^{-1} F_U, \operatorname{diag}(\Sigma_X))$ 下,利用 EP 方法得到了 $p(F_U | X, Y)$ 的一个新的逼近 $q(F_U) = \prod_{i=1}^n \tilde{\phi}_i(F_U) p(F_U | X) / Z_q$,并在文献[19]中将其推广到了多分类问题,2017年, Bui 等^[20]将 EP 方法和变分方法统一在同一个框架下,建立了一种基于 Power EP 方法的逼近算法。

协方差函数分解方法

该类方法的策略是先构造一组显式特征映射 $\phi(x)$ 来近似地逼近协方差函数,即 $k(x, y) \approx \phi(x)^T \phi(y)$; 换句话说而言,就是利用由这组显式特征映射确定的低维显式特征空间,近似表示由协方差函数确定的高维(无限维)隐式特征空间;然后在 $\phi(x)$ 确定的显式特征空间中构造一个线性高斯过程模型来建立学习算法。由于线性高斯模型的计算开销比较小,因此可以较好地扩展到大规模数据问题。Bochner 定理^[21]表明,一个连续函数正定的充要条件是该函数可以表示为一个有限非负 Borel 测度的傅里叶变换。对于平稳高斯过程的协方差函数 $k(x, y) = k(x - y)$, 根据 Bochner 定理可

知,只要对 $k(x, y)$ 进行合适的尺度缩放 $\tilde{k}(x, y) = \frac{1}{\sigma^2} k(x, y)$, 就可存在一个概率分布 $s(\omega)$ 使得它们之间存在如下的关系:

$$\tilde{k}(x, y) = \int_{R^d} s(\omega) e^{i\omega^T(x-y)} d\omega = E_{\omega}(\zeta_{\omega}(x) \zeta_{\omega}(y)^*)$$

其中 $\zeta_{\omega}(x) = e^{i\omega^T x}$ 。因此,如果根据概率分布 $s(\omega)$ 对 ω 进行采样,可以利用 $\zeta_{\omega}(x) \zeta_{\omega}(y)^*$ 得到 $\tilde{k}(x, y)$ 的一个无偏估计,即 $\tilde{k}(x, y) \approx \sum_{m=1}^M \zeta_{\omega_m}(x) \zeta_{\omega_m}(y)^*$, 注意到 $s(\omega)$ 和 $\tilde{k}(x, y)$ 都是实值函数,因此可以抛弃 $\zeta_{\omega}(x)$ 的虚部,用 $z_{\omega}(x) = [\cos(\omega^T x) \sin(\omega^T x)]^T$ 来表示 $\tilde{k}(x, y)$, 即 $\tilde{k}(x, y) = E_{\omega}(z_{\omega}(x)^T z_{\omega}(y))$ 。根据以上性质,文献[22]利用蒙特卡洛采样方法,建立了一组随机傅里叶特征映射

$$\phi(x) = \frac{1}{\sqrt{M}} [\cos(\omega_1^T x) \sin(\omega_1^T x) \cdots \cos(\omega_M^T x) \sin(\omega_M^T x)]^T$$

利用该特征映射可以将潜变量函数的高斯先验 $f(x) \sim \text{GP}(0, k(x, x'))$ 近似地表示为 $f(x) \sim \text{GP}(0, \sigma^2 \phi(x)^T \phi(x'))$, 这将等价于一个线性高斯过程模型 $f(x) = w^T \phi(x)$, $w \sim N(0, \sigma^2 I)$, 从而极大地降低了原始模型的复杂度。考虑到随机采样方法需要的采样点数 M 通常较大,文献[21]将 ω_m 作为模型参数建立了一种利用边缘似然对其进行优化选择的算法;文献[23]建立了一种 Fastfood 方法来通过随机矩阵近似生成 ω_m ; 文献[24]在 Fastfood 方法的基础上建立了一种核学习算法。文献[25]将协方差函数看作一个伪微分算子,利用希尔伯特空间逼近方法建立了如下形式的特征映射:

$$k(x, y) \approx \sum_{j=1}^M s(\sqrt{\lambda_j}) \phi_j(x) \phi_j(y) = \phi(x)^T S \phi(y),$$

$$S = \operatorname{diag}(s(\sqrt{\lambda_1}), s(\sqrt{\lambda_2}), \dots, s(\sqrt{\lambda_M}))$$

从而将原始高斯模型转换成了具有如下先验的线性高斯过程模型:

$$f(x)=w^T\phi(x), w\sim N(0, S)$$

最近, Hensman 等^[26]将变分方法与傅里叶特征映射进行结合, 建立了一种变分傅里叶特征映射。

协方差矩阵逼近方法

该类方法的策略是直接利用低维(或者稀疏)矩阵近似地表示协方差矩阵 K_X , 从而降低高斯过程模型的复杂度。在有的实际应用问题中, 训练样本的特征向量来自于一个笛卡尔网格, 对于这样的问题, 文献[27]发现, 当采用张量积核作为高斯过程的协方差函数时, 协方差矩阵可以写成 d 个 $n^{1/d}$ 阶方阵 $\{K_i|1,2,\dots,d\}$ 的克罗内克积的形式, 即 $K_X = \bigotimes_{i=1}^d K_i$, 其中 d 表示特征向量的维数。由于克罗内克积具有 $K_X^{-1} = \bigotimes_{i=1}^d K_i^{-1}$ 、 $(K_X + \sigma I)^{-1} = Q(\Lambda + \sigma I)^{-1}Q^T$ 、 $Q = \bigotimes_{i=1}^d Q_i$ 、 $\Lambda = \bigotimes_{i=1}^d \Lambda_i$ 的性质, 其中 $K_X = Q\Lambda Q^T$ 和 $K_i = Q_i\Lambda_iQ_i^T$ 分别是 K_X 和 K_i 的特征分解, 所以根据以上性质, 高斯回归模型的存储和计算复杂度可以分别降低为 $O(dn^{2/d})$ 和 $O(dn^{(d+1)/d})$ 。随后, 文献[28]将以上克罗内克积表示方法推广到了高斯过程分类模型中, Wilson 等^[29]放松了对训练数据必须采样于一个笛卡尔网格的要求, 使算法可以处理只有一部分数据采样于笛卡尔网格的问题。考虑到训练数据采样于笛卡尔网格是一个比较严苛的条件, 文献[30]借助于诱导变分方法的思想提出了一种矩阵插值的方法, 先假设 K_X 可以近似地表示为 $K_X \approx K_{XU}K_U^{-1}K_{UX}$; 然后将 K_{XU} 表示为一个稀疏的插值权重矩阵 W 和 K_U 的乘积形式 $K_{XU} \approx WK_U$, 利用该矩阵插值方法, 高斯过程模型的存储和计算复杂度可以降低到 $O(n)$ 。

贝叶斯委员会机器

贝叶斯委员会机器^[31-32]的基本思想是把训练集分割成不同的小数据集, 在每个小数据集上训练一个学习器, 然后利用贝叶斯公式把这些子学习器组合得到最终的学习器。令 $\{D_i|i=1,2,\dots,l\}$ 表示对训练集 D 的一个分割, 则利用贝叶斯委员会机器得到的 f_* 的后验概率分布的近似表达式为

$$p(f_*|D, x_*) \approx Z \frac{\prod_{i=1}^l p(f_*|D_i, x_*)}{\prod_{i=2}^l p(f_*|x_*)}$$

其中 Z 是常数。可以看出, 贝叶斯委员会机器本质上是一种集成学习算法, 它也可以用于高斯过程模型以外的其他各种机器学习模型。

结束语

本文对构建面向大规模数据的高斯过程模型的几种主要方法进行了简要介绍, 这些方法各有优缺点。贝叶斯委员会机器虽然比较简单、直观, 但是由于这种将大数据集拆分为小数据集的策略丧失了不同小数据集样本之间的关联关系, 通常并不能取得好的结果, 更适合于与其他方法配合使用。协方差函数分解和协方差矩阵逼近方法, 虽然在有的应用问题上可以取得较好的结果, 但是目前这两类方法都对协方差函数的类型有特定要求, 不适合处理一般性的问题。诱导变量方法由于对协方差函数没有特定要求, 而且可以同时解决诱导变量的选择和后验概率分布的逼近问题, 相比较而言比其他方法更具一般性, 因此也受到了人们更多的关注, 目前已经建立了可以有效解决回归和分类问题的多

种诱导变量算法。由于高斯过程模型已经被用于排序学习、多视角学习等各种机器学习框架中，因此如何将诱导变量方法推广到这些机器学习框架是下一步需要解决的问题，此外建立面向流数据、类不平衡数据的诱导变量方法也是值得

研究的方向。

基金项目：国家自然科学基金项目(61503058, 61374170)；辽宁省自然科学基金项目(201602190)；大连市青年科技之星项目(2016RQ072)。

参考文献

- [1] Neal R M. Bayesian learning for neural networks [J]. Lecture Notes in Statistics. 1996, 118.
- [2] Rasmussen C E. Evaluation of Gaussian processes and other methods for non-linear regression [D]. (PhD Thesis), Toronto: University of Toronto, 1996.
- [3] Gibbs MN. Bayesian Gaussian processes for regression and classification [D]. (PhD Thesis), Cambridge: University of Cambridge, 1997.
- [4] Bonilla E V, Chai K M, Williams C. Multi-task Gaussian process prediction[C]. Advances in neural information processing systems, 2008.
- [5] Engel Y, Mannor S, Meir R. Reinforcement learning with Gaussian processes[C]. Proceedings of the 22nd international conference on Machine learning, 2005:201–208.
- [6] Lawrence N, Jordan M. Semi-supervised learning via Gaussian processes[C]. Advances in Neural Information Processing Systems, 2005.
- [7] Guiver J, Snelson E. Learning to rank with softrank and gaussian processes [C]. Proceedings of the 31st Annual International ACM SIGIR Conference On Research and Development in Information Retrieval, 2008.
- [8] He J, Gu H, Wang Z. Bayesian multi-instance multi-label learning using Gaussian process prior[J]. Machine learning, 2012, 88(1-2): 273-295.
- [9] Liu Q, Sun S. Multi-view Regularized Gaussian Processes[C]. Pacific-Asia Conference on Knowledge Discovery and Data Mining, 2017: 655-667.
- [10] Zhou Y, He J, Gu H. Partial Label Learning via Gaussian Processes[J]. IEEE Transactions on Cybernetics, online, 2017.
- [11] Seeger M, Williams C, Lawrence N. Fast forward selection to speed up sparse Gaussian process regression[C]. Ninth International Workshop on Artificial Intelligence and Statistics, 2003.
- [12] Snelson E, Ghahramani Z. Sparse Gaussian processes using pseudo-inputs[C]. Advances in neural information processing systems, 2006: 1257-1264.
- [13] Quiñero-Candela J, Rasmussen C E. A unifying view of sparse approximate Gaussian process regression[J]. Journal of Machine Learning Research, 2005, 6: 1939-1959.
- [14] Titsias M K. Variational learning of inducing variables in sparse Gaussian processes[C]. International Conference on Artificial Intelligence and Statistics, 2009: 567-574.
- [15] Hensman J, Fusi N, Lawrence N D. Gaussian processes for Big data[C]. Proceedings of the Twenty-Ninth Conference on Uncertainty in Artificial Intelligence, 2013: 282-290.
- [16] Hensman J, Matthews A G, Ghahramani Z. Scalable variational Gaussian process classification[J]. Journal of Machine Learning Research, 2015, 38: 351-360.
- [17] 马彪, 贺建军, 李厚杰. 基于拉普拉斯方法的大规模高斯过程分类算法 [J]. 控制与决策, 2017, 32(7): 1319-1324.
- [18] Hernández-Lobato D, Hernández-Lobato J M. Scalable gaussian process classification via expectation propagation[C]. Proceedings of the 19th International Conference on Artificial Intelligence and Statistics, 2016: 168-176.

- [illegible]



Dr. Yoon is a professor of the Department of Industrial Engineering at Seoul National University. He received his B.S. and M.S. degrees from Seoul National University and his Ph.D. degree from the University of California, Berkeley. He has been a faculty member at Seoul National University since 1995. His research interests include manufacturing systems, supply chain management, and operations research.

许小可

博士，大连民族大学信息与通信工程学院教授，硕士生导师。主要研究方向为社交网络大数据分析机器学习。

面向用户消费行为理解的数据挖掘方法研究

吴乐

合肥工业大学

摘要：海量线上用户消费行为数据为研究者探索理解用户消费习惯，制定数据驱动的商务智能策略带来了全新的机遇及挑战。本文提出融合用户消费行为的多学科交叉研究成果，利用数据挖掘方法，从用户兴趣建模、社交情境下用户消费行为理解及社交服务平台的动态演化建模三个方面展开在线用户消费行为理解研究，并分别在真实数据集上验证了提出模型的有效性。

关键词：数据挖掘；消费行为建模；兴趣发现；社交网络

0 引言

作为社会个体中的一员，人们为了满足个人、家庭和社会生活的需要，无时无刻不处在消费的行为中，如购买基本生活用品、享受电影音乐娱乐、选择电子设备等。消费者行为学作为一门学科在 20 世纪 60 年代中后期应运而生^[1]。具体而言，用户消费行为是指用户在完成消费前的一系列决策过程，如个人需求分析、信息收集、备选方案的评估到最终的决策过程。消费者行为学研究范畴包括市场细分、消费者消费动机及消费过程研究、消费者态度形

成及改变，以及处在社会和文化环境中的消费者等。深入理解用户的消费行为和决策过程，不仅有利于为用户提供更智能的个性化服务，也为商家制定商业战略，提高产品市场占有率，创造更多的市场价值提供了理论和实践指导。

近年来，随着 IT 产业的迅猛发展，特别是（移动）互联网及在线社交媒体的普及，人类真实生活社交方式和消费购物模式与互联网应用不断融合。这些互联网应用使得人类消费行为突破时空限制，人们足不出户就可以在网上寻找、

对比、购买需要的产品及服务；同时在线社交媒体的广泛应用，也使得用户能够与千里之外的朋友保持实时沟通，方便快捷地查看朋友的消费信息。人类的各类消费行为模式逐渐映射到虚拟的网络环境中，同时互联网也深刻影响改变用户的行为特征，产生出一系列亟待解决的消费行为研究课题。

通过从大量数据中挖掘隐藏的有价值信息，数据挖掘成为理解用户消费行为模式的一种行之有效的方法。面向用户消费行为理解的数据挖掘研究，基于（移动）互联网智能服务系统自动收集的用户消费行为数据，挖掘理解用户的消费模式规律，为互联网服务提供商改良现有商业模式，开发新的商业策略，实现差异化营销提供技术支持。同时，对在线用户消费行为理解的研究也是进行智能化个性化用户服务的关键，是互联网服务商提高用户满意度，实现用户粘性的重要举措。事实上，数据挖掘技术已经渗透于在线用户消费行为建模中。例如，用户画像技术全方位立体地展现了在线消费者特征，推荐系统通过用户兴趣建模技术为用户推荐未来可能感兴趣的产品。由于在线用户消费行为的独特性，已有的数据挖掘算法不足以支撑全方面多维度的在线用户的消费行为理解。具体来说，当前研究工作面临的主要挑战包括以下三个方面：① 在线用户消费行为数据源的稀疏动态及多元异构性。在线系统中，由于用户及产品数量巨大，而用户-产品之间交互行动较少，构成了数据源之间的稀疏性。同时，在线用户消费行为的

复杂情境造成了数据源的多元异构性，包括用户-产品交互行为数据的多元性（1~5分评分值，0-1隐反馈评分）和数据源的异构型（用户-产品消费行为、用户-用户社交网络，用户属性信息及用户发布的文本内容等）。② 在线用户消费决策过程的复杂性。从用户角度而言，用户自身的差异性导致不同用户的决策过程不尽相同。同一用户在消费不同类型产品时，决策过程可能存在差异性。例如，用户在购买手机时决策过程比购买电影复杂。进一步，用户复杂性与产品复杂性两者的交叉，构成了在线用户消费行为的复杂性。③ 在线用户消费行为理解的交叉学科性。用户消费行为学起源于各学科的交叉，充分理解在线用户的消费行为也需要交叉学科知识的支持。如何结合多学科知识，设计数据驱动的用户消费行为建模方法也是当前研究的挑战之一。

针对上述挑战，本文提出设计新型的数据挖掘模型理解用户消费行为。具体来说，我们以不同类型的产品为实例，结合用户-产品的交互消费数据、用户-用户之间的社交数据，以及诸如用户属性、用户生成的标签数据等辅助数据，利用用户兴趣建模理论、社交情境下的信息传播模型以及交叉学科领域知识作为理论基础，在此基础上，分别设计出面向精准度和多样性的用户消费兴趣理解及推荐算法、社交情境下的用户消费行为理解，以及社交情境下的用户消费及社交共同演化理解模型。本文的研究内容框架如图1所示。在接下来内容中，我们将对上述三项工作逐一进行概述。




图1 研究内容框架体系

1 基于用户兴趣建模的消费行为理解与推荐算法

用户兴趣是用户消费行为的核心因素。用户兴趣建模是推荐系统的核心问题，其旨在通过分析用户历史消费行为，设计模型挖掘用户潜在消费兴趣，并基于此设计产品推荐算法，增进用户的满意度以及商家收益^[2]。根据用户兴趣建模评价方法的不同，本章将分别介绍面向精确度和面向多样性两类用户兴趣建模方法。

1.1 面向精确度的用户兴趣建模方法

在用户兴趣建模方法中，协同过滤技术（Collaborative Filtering, CF）由于具有适用情景广、算法简单明确、推荐效果较好等优点，近年来受到学术界和工业界的广泛关注。协同过滤技术通过收集用户消费产品的历史数据，如浏览记录、购买记录，以及对商品的评分记录等，利用群体智慧分析用户兴趣，寻找与指定用户具有相似消费兴趣的用户，综合相似用户的历史数据主动向用户进行产品推荐。然而，由于协同过滤技术依赖于用户-产品的消费信息建模，该类算法通常在用户-产品消费记录较少时无法准确建模。这种情况在推荐系统中非常普遍，被称之为“冷启动”问题^[3]。

幸运的是，随着 Web 2.0 技术的发展，用户与互联网之间的交互更加密切，用户既成为网站的浏览者，也是网站内容的制造者。因此，大量的用户内容应运而生，其中标签信息是被用户广泛使用的对网站内容进行开放分类的一种技术，为用户自主创建分类和组织内容提供了便捷。先前研究表明，用户生成的标签信息既可以反映网站内容，也提供了用户的兴趣点^[4]。因此，利用标签信息解决冷启动问题，是一个值得探索的研究方向。

针对上述背景，提出了基于补充标签信息的用户兴趣建模及推荐方法，设计了两阶段的邻居感知的矩阵分解算法框架（Neighborhood-aware Probabilistic Matrix Factorization, NHPMF）^[5]。该框架图如图2所示，其中，第一阶段，使用标签信息获得用户和产品的邻居信息；第二阶段，设计统一的模型将邻居信息融合到矩阵分解过程中，保证“相似的用户（产品）在隐空间上具有相似的表示”；即通过将补充的邻居信息引入传统矩阵分解模型的先验中，使得每个用户（产品）的隐向量尽量和邻居保持相似。最后，在两个不同数据集上验证了方法的有效性。实验结果表明，与传统的协同过滤算法相比，提出的 NHPMF




图2 两阶段的邻居感知的矩阵分解算法框架

框架能更精准预测用户的兴趣爱好。详情参见文献 [5]。

1.2 面向多样性的用户兴趣建模方法

协同过滤技术通过历史用户 - 产品消费记录, 衡量用户和产品之间的相关性 (Relevance), 进而为用户推荐 top-N 的兴趣列表。因此, 这些算法擅于提供精准度高的推荐结果, 匹配用户的主要兴趣爱好。例如, 1.1 节介绍了如何通过额外信息补充用户 - 产品消费矩阵, 预测用户对未知产品的偏好, 最终选择预测评分最高的产品集合作为推荐列表。然而, 当前的协同过滤算法过于关注提高推荐模型的精准度, 导致推荐算法产生的推荐列表大多被限制在一个相对狭窄的热门产品集合中, 从而用户的一些小众偏好却被算法忽略^[6]。因此, 传统推荐算法产生的推荐列表可能比较单调 (推荐列表的各个产品之间比较相似, 缺乏多样性), 难以覆盖用户的全部消费兴趣。

部分学者已经意识到具有多样性的推荐列表的重要意义, 一些先期研究工作提出各种方法提高推荐结果的多样性, 这些工作一般分成如下两个步骤: 首先利用传统的协同过滤算法抽取一个较大的候选集合; 然后利用多样性指标对候选集合重新排序, 获取 top-N 的推荐列表。然而, 这些方法通常要么引入额外信息获取多样性指标, 要么在提高多样性的同时降低了推荐结果的精确度。因此, 如何在通用情况下不借助产品的额外信息, 生成既准确又包含多样性的推荐结果仍然是一个亟待解决的开放性课题。

基于以上背景, 本文提出从一个全新视角理解推荐结果的多样性问题。我们从经典推荐算法中的基于用户邻居的协同过滤算法 (User-based Collaborative Filtering, UCF) 出发, 从算法思想和实验结果分析该算法无法产生多样化推荐结果的原因。UCF 算法首先为每个目标用户选择相关度高的兴趣相似的邻居用户, 进一步根据邻居列表中的流行产品为目标用户生成推荐列表^[7]。而 UCF 算法在邻居集合选择和推荐集合 / 列表生成的两个阶段中, 其考虑的相关度指标仅仅从集合中的单个元素出发, 并没有从全局最优的观念考虑集合中元素之间的关系。(值得注意的是, 该类问题不仅仅出现在 UCF 算法中, 当前主流的协同过滤算法, 如基于产品邻居的推荐算法及矩阵分解算法, 均存在此类问题。)

为解决上述问题, 引入了一个简单的度量指标——覆盖度来衡量集合中所有元素的效用。我们将覆盖度的指标应用于 UCF 的邻居选择和推荐列表生成阶段中, 考虑如何定义兴趣覆盖度概念使得邻居集合覆盖用户兴趣, 以及邻居覆盖度概念使得推荐集合覆盖多样化的邻居。然后提出了一个统一的推荐框架 REC, 使得在邻居集合选择和推荐列表生成过程中不仅考虑传统的相关性 (RElevance) 指标, 而且加入新的覆盖度 (Coverage) 指标来衡量集合元素的效用^[8]。当同时考虑相关性与覆盖度指标时, REC 框架中的邻居选择与推荐列表生成过程的目标函数都是 NP 难问题。我们进一步挖掘目标函数性质, 提出了一种高效的有理论保证的求解方法。由于 REC 在

邻居选择阶段,使得每个邻居用户尽可能地覆盖用户的不同兴趣,得到的邻居集合具有多样性;同时在推荐列表生成过程中,鼓励每个产品覆盖多样化的邻居用户,得到的推荐结果自然具有多样性。实验结果表明,我们提出的算法能够在不损失精度的情况下,显著提高推荐结果的多样性。

2 社交情境下的用户消费建模及预测

随着信息技术的发展,社交网络的兴起为社交情境下的用户消费建模提供了新机遇。与基于用户兴趣建模的消费行为理解不同,在社交网络中,用户与用户之间不再相互独立,用户的自身决策行为也会受到社交情境的影响。如何更真实地为现实社会的消费传播过程建模,也是当前学术界的一个研究热点。针对此问题,我们通过社交网络中用户的手机消费行为为例,结合社会学研究成果,探索社交网络下用户的手机消费行为机理,预测用户未来手机消费行为。进一步,针对传统二元数据(是否购买)表示用户对产品偏好的不足,提出时序产品使用率概念衡量用户对产品的喜好变化,并对用户的时序产品使用率进行建模预测。

2.1 社交情境下的手机消费情况建模

权威市场调研机构 IDC (International Data Corporation) 曾调查 2013 年底全球范围内的智能手机使用量为 18.2 亿,预测在 2017 年,在所有智能设备中(包括台式机、笔记本、平板电脑及智能手机),智能手机的市场占有率将达到 70.5%^[9]。智能手机

市场已经成为各大电子厂商争夺的焦点。现在,手机已成为人们社交方式的重要组成部分。然而,如何收集大规模社交网络中用户的手机消费行为数据,理解社交情境下的用户手机消费仍然是一个空白的研究领域。

幸运的是,近年来随着在线社交媒体和智能手机的普及,越来越多的人通过智能手机与在线社交网络上的朋友分享生活记录。由于大部分用户通过智能移动设备接入在线社交媒体,这些移动社交网络记录了用户的智能手机使用足迹。图 3 则展示了 Weibo 上用户的手机使用实例足迹。当用户在 Weibo 上发布信息时,系统会自动将一条扩展后的信息发送给该用户的粉丝。这条扩展的信息包含发布的微博内容、时间戳(2013 年 7 月 3 日)以及发送该条微博的设备信息(iPhone)。其中,扩展信息中的设备信息为追踪大规模社交网络下用户的手机使用行为提供了数据源。通过跟踪大规模用户长时间的微博信息流,即可自动获取用户及其所在社交网络的手机消费情况。



图 3 Weibo 上用户手机使用实例

然而,即使能够获取社交网络中用户的手机使用情况,理解用户在社交情境下的手机使用还存在以下技术挑战。一方面,

用户的消费决策过程受到多种因素影响,如何融合这些因素更好地进行消费行为建模是一个亟待解决的问题。心理学、社会学及用户行为学等多学科交叉研究结果已确认了三种主要因素对用户决策行为的影响,即个人因素、社交影响力及同质性^[10]。其中,个人因素指代用户受到自身特性或者兴趣驱动,独立地做出消费决定。然而,现实中人类处于社交环境中,其消费决定行为与所处的社交环境存在千丝万缕的联系。社交影响力及同质性就是社交情境下用户行为的指导准则。其中,社交影响力指代用户受到周围社交网络中邻居行为的影响做出决策行为;而同质性描述了社交网络中“人以类聚”的现象,即有着相似兴趣爱好的人相互联系,不约而同地做出相似决定。另一方面,不同的因素会导致完全不同的消费行为结构演化,从而影响生产厂商的营销策略制定。准确地区分和理解各因素在消费行为中的作用,对指导商家的营销策略有着重要意义。

综上所述,本研究工作的挑战在于:如何设计统一模型融合各复杂因素对用户手机消费行为的影响,同时区分各不同因素对消费行为的作用,为商家营销提供数据驱动的定量指导。

针对以上挑战,我们提出一种有监督的机器学习方法建模用户的智能手机消费行为理解与预测^[11]。在前期准备中,通过跟踪在线移动社交网络用户的行为,收集了网络用户的手机使用情况。借鉴消费行为学和营销学理论,根据用户当前智能手机使用状态将用户分为潜在智能手机首次

消费者以及潜在手机品牌更换者两组。我们设计了SHIP(Supervised Homophily-Influence-Personality)模型建模手机消费行为。该模型融合个人因素、社交影响力和同质性三个重要因素对用户消费行为进行建模,并且可以自动学习各因素对消费行为的贡献(具体算法可参见文献[11])。值得一提的是,提出的SHIP模型具有普适性,也可以用于其他产品消费行为建模。我们在具有20万个节点的社交网络中进行算法评估,实验效果表明了所提方法能有效预测用户手机消费行为。实验中得到的一个有趣结论是,用户首次购买手机的品牌容易受到身边朋友的影响,而用户更换手机品牌主要由品牌忠诚度确定。

2.2 社交情境下的产品使用率建模

在2.1节的研究中,我们将用户的手机消费行为分为已经消费产品的用户(标签为1)和暂未消费该产品的用户(标签为0)两类,然后对未消费产品的用户进行后续消费行为预测,寻找下个时间段潜在的消费者。然而在真实世界的消费行为中,除去很多一次性消费的产品(例如书籍、电影),用户通常对某类耐用品产品存在着多种备择选择,用户受到自身和外部因素的影响交替选择具有特定功能的不同产品。例如在手机市场中,用户可能交替使用苹果品牌与三星品牌的手机。相比较于是否购买产品的评估表中,厂商更关心用户对该类产品的品牌忠诚度变化。此时,传统的0-1用户分类标准难以刻画用户的消费规律。针对传统二元用户消费表示不足,本节提出产品使用率的概念,即产品的使

用频率来准确刻画用户对某类产品的喜爱。产品使用率能够在时序时间内衡量用户对产品的忠诚度变化。这里考虑用户较长时间段的产品使用率序列,即充分挖掘用户产品使用率的历史时间序列,进行后续产品使用率预测。

事实上,尽管存在一些相关的时间序列模型(如时间序列分析预测、隐马尔科夫模型),但是本章提出问题的特殊性使得上述传统模型难以直接迁移。首先,用户决策行为是一个十分复杂的过程,内部和外部环境的各种因素,如用户自身属性、其所在的社交网络结构、产品的流行度和大众认可度等,都会对用户的产品使用率造成影响,导致了用户决策结果的不确定性。其次,用户自身的独特性使得不同用户对不同因素的权重不尽相同。例如,一些用户对社交朋友的意见十分信任,而另外一些用户可能更关注与他们自身的需求爱好。基于上面的讨论,如何根据用户有限的消费序列(产品使用率序列信息),整合挖掘平衡这些因素成为本节提出问题的另一个挑战。

针对以上挑战,我们提出从多因素角度考虑用户的产品使用率预测问题^[12]。首先定义了一个因素相关的产品使用率函数,用来整合各种因素对用户产品使用率的影响。其次研究设计了GAM(Generalized Adoption Model)和PAM(Personalized Adoption Model)两类模型求解产品使用率函数,其中GAM模型不区分用户的独特性,假设所有用户受到各因素影响的程度相同;而PAM模型则考虑了用户的独特性,认为各用户不同因素的权重不尽相同。为了处理PAM模型中调

参的问题,进一步将PAM扩展为自动参数学习的贝叶斯的版本(BPAM)。最后,在真实数据集上的两项产品预测率上进行了丰富实验,结果证明了所提方法的有效性。更为详细的问题定义及模型参见文献[12]。

3 用户消费行为与社交行为的联合演化建模

在社交情境下的用户消费平台服务中(通常称之为社交服务平台, Social Networking Service, SNS),在线用户主要进行两种行为,即用户-产品之间的消费行为(如评分、购买、签到、发布帖)及用户-用户建立的社交链接行为(如用户-用户之间建立的双边朋友关系及单边的关注关系)。因此,发现用户消费兴趣及建立新的社交链接是社交服务平台两个广泛研究的预测任务。其中,前文提到的CF算法通过用户的历史消费行为,发现与目标用户具有相似消费兴趣的人,构成了用户消费兴趣发现及产品推荐的基础^[2]。而基于网络节点的近似度算法(Node Proximity, NP),通过挖掘社交网络图的拓扑逻辑结构,为社交链接预测提供了可行性^[13]。通过挖掘用户某一类的历史行为数据预测同类型的后续行为,CF与NP这两类算法在各自领域已被前人广泛研究。然而,社会学研究发现,用户的这两类行为并非相互独立,他们之间的相互影响构成了SNS平台的演变——用户的消费兴趣随时间变化同时社交网络结构也处于变动中。其中,两种被广泛接受的社会学理论揭示了导致用户两种行为相互影响的原因:社交影响力指代

用户受到周围社交网络邻居的影响做出消费决策行为，而同质性描述了社交网络中“人以类聚”的现象，即人们容易在社交网络中寻找与自己具有相似爱好的用户，并与这些用户建立社交链接^[10,14]。

我们在此考虑社交服务平台下用户两类行为的演化研究^[15-16]。准确建模社交服务平台下的用户行为共同演化存在以下技术难点。一方面，用户的两类行为交织在一起构成了社交服务平台的演化，因此难以区分每类用户行为对社交服务平台演化的贡献；另一方面，如何搭建用户两类行为的桥梁，将其中一类知识迁移到另一类行为，实现用户行为演化的共同建模仍然是一个挑战。

为解决上述技术挑战，提出一种概率模型共同建模用户在社交服务平台上的消费行为，以及社交链接行为的演变。根据先前的社会学理论模型假定，每位用户的当前行为同时受到历史消费行为（消费兴趣）及先前社交网络的影响。在该假设下，提出的模型定义了每类用户行为对社交服务平台的作用，然后设计隐因子模型，将用户和产品同时表示为隐向量，其中用户向量随时间变化且共享于用户的两类行为中。为了展示用户的时序行为变化规律，每个用户 a 在时刻 t 的隐消费向量 U_a^t 随时间变化，且同时受到用户前期消费兴趣和社交网络邻居的影响。相应地，用户 a 在 t 时刻的社交行为也由其社交网络和其消费兴趣共同决定。该算法的图模型如图 4 所示。根据算法的图模型，提出了社交平台用户两类行为的共同演化算法。最后，在两个真实数据集上进行了大量实验，实验结果表明所提算法在两类用户行为预测上的有效性。




图 4 提出的社交服务平台联合演化模型

4 结束语

本文针对利用数据挖掘方法理解在线用户的消费行为的基础理论，以及应用性问题进行探索性研究。在数据层面结合用户-产品之间的消费数据、社交网络中用户-用户之间的交互数据及其他辅助数据，通过推荐系统中的用户消费兴趣建模理论、社交网络中的信息传播模型及交叉学科中对用户消费行为的研究，探索了基于用户兴趣建模的消费行为理解与推荐算法、社交情境下的用户行为分析与预测，以及社交服务平台下用户消费行为及社交链接行为的共同演化。

随着移动互联网和在线用户消费的渗透式发展，关于在线用户消费行为的数据挖掘研究方兴未艾。诸多重要问题及方向值得进一步探索研究，例如，移动互联网中的智能传感设备为研究用户消费行为提供了丰富的情境数据。如何结合用户在互联网上的消费行为研究成果，同时融合移动数据丰富的情境日志，更加准确地挖掘用户在不同情境下的消费特征，仍然是一个亟待解决的开放性课题。另一方面，在线消费平台中涉及到用户及在线服务提供商两类人群，如何在理解用户消费行为的基础上转变为主动引导用户消费行为，服务服务产品提供商以获得更大利润？这些开放性问题的都值得研究者们进一步探索研究。

参考文献

- [1] Solomon M R, Dahl D W, White K, et al. Consumer behavior: buying, having, and being[M]. Prentice Hall Upper Saddle River, NJ, 2014.
- [2] Adomavicius, Gediminas, and Alexander Tuzhilin. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions[J]. IEEE Transactions on Knowledge and Data Engineering. 17.6 (2005): 734-749.
- [3] Schein, Andrew I., et al. Methods and metrics for cold-start recommendations[C]//Proceedings of the 25th annual international ACM SIGIR conference on Research and development in information retrieval. pp. 253-260. ACM, 2002.
- [4] Heymann, Paul, Georgia Koutrika, and Hector Garcia-Molina. Can social bookmarking improve web search?[C]//Proceedings of the 2008 International Conference on Web Search and Data Mining. pp. 195-206. ACM, 2008.
- [5] Wu, Le, et al. Leveraging tagging for neighborhood-aware probabilistic matrix factorization[C]//Proceedings of the 21st ACM international conference on Information and knowledge management. pp. 1854-1858. ACM, 2012.
- [6] McNee, Sean M., John Riedl, and Joseph A. Konstan. Being accurate is not enough: how accuracy metrics have hurt recommender systems[C]//CHI'06 extended abstracts on Human factors in computing systems. pp. 1097-1101. ACM, 2006.
- [7] Herlocker, Jonathan L., et al. An algorithmic framework for performing collaborative filtering[C]//Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval. pp. 230-237. ACM, 1999.
- [8] Wu, Le, et al. Relevance meets coverage: A unified framework to generate diversified recommendations[J]. ACM Transactions on Intelligent Systems and Technology (TIST) 7.3 (2016): 39.
- [9] <http://www.idc.com/getdoc.jsp?containerId=prUS24314413>.
- [10] Aral, Sinan, Lev Muchnik, and Arun Sundararajan. Distinguishing influence-based contagion from homophily-driven diffusion in dynamic networks[J]. Proceedings of the National Academy of Sciences 106.51 (2009): 21544-21549.
- [11] Wu, Le, et al. Predicting Smartphone Adoption in Social Networks[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining. pp. 472-485. Springer, 2015.
- [12] Wu, Le, et al. Product adoption rate prediction: A multi-factor view[C]//Proceedings of the 2015 SIAM International Conference on Data Mining. pp. 154-162. Society for Industrial and Applied Mathematics, 2015.
- [13] Liben Nowell, D. and Kleinberg, J. The link prediction problem for social networks[J]. Journal of the Association for Information Science and Technology, 2007,58(7), pp.1019-1031.
- [14] McPherson, Miller, Lynn Smith-Lovin, and James M. Cook. Birds of a feather: Homophily in social networks[J]. Annual review of sociology 27.1 (2001): 415-444.
- [15] Wu, Le, et al. Modeling users' preferences and social links in social networking services: A joint-evolving perspective[C]//Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence. pp. 279-286, AAAI, 2016.
- [16] Wu, Le, et al. Modeling the Evolution of Users' Preferences and Social Links in Social Networking Services[J]. IEEE Transactions on Knowledge and Data Engineering. 29.6 (2017): 1240-1253.



吴乐

中国科学技术大学博士毕业，师从陈恩红教授；现为合肥工业大学计算机与信息学院讲师。在计算机领域 TKDE、TWEB、TIST 等顶级期刊和 IJCAI、AAAI、KDD、SDM、ICDM、CIKM、PAKDD 等顶级国际会议上发表论文 20 余篇。以第一作者获得数据挖掘三大国际会议之一的 SDM 2015 最佳论文提名奖。主要研究方向为数据挖掘、推荐系统、社交网络及用户行为建模。

个性化推荐的可解释性研究

张永锋

美国麻省州立大学

摘要：个性化推荐技术已经成为互联网应用的基础技术之一，广泛应用于电子商务、搜索引擎、社会网络、新闻阅读等互联网服务中，是用户获得信息的重要途径之一。本文以个性化推荐的可解释性为主题，在数据、模型和经济效益三个层面上展开了探讨。在数据上，个性化推荐的打分矩阵可以等价描述为用户物品二部图上的社区发现结构；在模型上，个性化算法可以给出与推荐模型紧密相关的个性化推荐理由；在经济效益上，个性化推荐可以作为互联网商品服务资源分配的基本手段，实现互联网社会福利的最大化，从而提高互联网经济系统的效益。

关键词：个性化推荐；协同过滤；情感分析；可解释性；计算经济学；人工智能

0 引言

互联网的快速发展开启了人类活动线上化的进程，越来越多传统上只能在线下完成的任务变得可以方便快捷地在互联网上完成。已经深入人们日常生活中的电子商务就是这一进程的典型代表，例如阿里巴巴、京东商城、亚马逊网络商城等电子商务网站的普及，使得人们不必走出家门即可购买自己所需要的商品，并且可以在更多的备选商品中进行挑选。伴随着各种

互联网应用的迅速发展，个性化推荐系统成为网络应用中不可缺少的重要组成部分，并在各种场景下以不同的方式影响着人们网络生活的方方面面。

随着人类线下活动的逐步线上化，互联网不再仅仅是一个信息流通和传播的平台，而是逐渐成为了一个完整的在线经济和社会系统，大量的社会生产生活 and 消费商贸活动以在线交易的方式在互联网上完成，而个性化推荐系统及其相关技术在这一过

程中发挥着资源配置的作用。例如在电子商务网站中,个性化推荐将商家待销售的商品与具有相应需求的用户进行匹配,从而提高整个在线经济系统资源配置的效率。

不仅是在电子商务系统中,在线租房和房地产业务中的房屋推荐,通过综合考虑地理位置和价格等信息,对用户需求进行精确定位,从而提高住房利用率和降低房产空置率;在线自由职业平台中的工作任务推荐系统更是综合考虑自由职业者的技术能力和预期报酬,以及雇主的需求,通过精确的职业匹配令雇佣双方各得其所,使高效的在线劳务市场成为可能。除了显式的个性化推荐系统之外,隐式的推荐系统也大量存在于网络之中。例如在线叫车服务系统对用户需求和付费意愿进行预测,并对道路交通状况进行实时建模,从而为用户自动匹配最合适的司机,在满足双方出行需求的同时进行路线优化、缓解交通负担。在个性化推荐系统的信息匹配和资源配置过程中,恰当地融合经济效益及风险控制等因素的考量,对互联网经济安全和网络环境的稳定可控具有重要作用。例如,在网络借贷服务的理财产品推荐中,对理财产品的风险评估和用户风险承受能力的评估是产品匹配,以及面向用户的推荐过程中所要考虑的重要因素,向不同用户推荐和展示合理的产品是网络金融服务,实现风险可控的重要手段。

本文从数据、模型,以及经济学意义三个方面对个性化推荐的可解释性进行研究,主要贡献分为以下三点:①数据的可解释性。提出了基于双边块对角矩阵的局部化

矩阵分解框架,并将其应用于矩阵分解的并行化。②模型的可解释性。提出了基于短语级情感分析的显式变量分解模型及其基于时间序列分析的动态化建模。③推荐的经济学解释。提出基于互联网系统总福利最大化的个性化推荐框架,并给出典型应用场景中的具体实现。

在实际的个性化推荐系统中,数据、模型的可解释性以及推荐的经济学解释具有依次递进的内在联系。数据准备和预处理是个性化推荐系统的基础,而用户物品评分稀疏矩阵是个性化推荐实际系统中最常见和最基本的数据输入形式之一。数据的可解释性研究试图将原始的稀疏矩阵转化为双边块对角结构,从而将杂乱无章的原始矩阵和用户物品打分解释为内在的用户物品社区结构,这一方面降低数据稀疏性,另一方面将具有相似兴趣的用户及其历史评分聚在一起,从而提高协同过滤算法的预测效果。

在数据的基础上,个性化推荐模型试图对数据进行分析并对用户的个性化偏好进行建模,从而给出个性化推荐结果。基于隐变量的协同过滤技术是目前应用最为广泛的个性化推荐模型之一,而隐变量模型将数据映射到一组未知的变量上,从而难以解释原有数据中用户的具体偏好,也难以据此为推荐结果给出合理的解释。模型的可解释性研究则试图通过引入属性词显式变量构建用户在属性词上的偏好矩阵,从而使得协同过滤算法在模型层面可解释(变量拥有具体的实际意义);另一方面通过在给出推荐结果的同时也给出推荐理由

由,使得推荐结果对用户而言直观可理解。

在数据和模型的基础上,个性化推荐算法实际上以推荐的方式隐形地控制着系统中物品与用户之间的匹配方式,从而影响推荐算法所在经济系统(如电子商务网站)中的资源分配结果。因此,个性化推荐系统在最上层是经济系统资源分配的手段,并进一步影响经济系统最终所实现的社会效益(系统总福利)。基于这一本质,本文在数据和模型的技术层面之上,对个性化推荐的经济意义进行解释,并提出基于总福利最大化的推荐(资源分配)算法,从而在提高推荐系统用户体验的同时,也提高整个经济系统的社会效益。

1 数据的可解释性

协同过滤作为个性化推荐的主要技术已经得到广泛的关注和应用,但是目前仍然少有关对用户物品评分矩阵的内在结构的理解和研究,并且在此基础上协同过滤也面临着几大重要问题:一是矩阵的稀疏性,这往往会对评分预测算法的精度带来负面影响;二是由规模庞大的输入矩阵所带来的算法可扩展性问题;三是算法缺乏对矩阵中来自不同兴趣社群的用户的区分,这一方面不利于对特殊用户群兴趣的发掘,另一方面降低了协同过滤算法发现和利用兴趣相似的用户物品群组提高预测精度的能力。

实际上,用户物品评分矩阵和二部图具有数学上的等价关系,如图1所示。图1(a)表示一个用户物品评分矩阵,其中矩阵的每一行对应一个用户、每一列对应一个物品,矩阵中的每一个非零值(记为 $\times$ 符号)

表示相应的用户对相应物品的打分;该矩阵可以等价地表示为一个用户物品二部图,如图1(b)所示,其中原矩阵的每一行(用户)表示为一个 R 节点,每一列(物品)表示为一个 C 节点,原矩阵中的非零值对应于二部图中的一条边。图1(c)表示由原始矩阵得到的一个双边块对角矩阵(Bordered Block Diagonal Form, BBDF),其中原始矩阵的第4行、第9行,以及第7列被排列到了矩阵的下边和右边(双边),而剩下的部分可以被排列为两个块对角子矩阵;进一步其中第一个子矩阵中的第3行、第2列和第9列又可以被迭代地排列到矩阵的双边,该过程可以如此迭代执行。该过程对应于原始二部图上的一个点分割过程图聚类,如图1(d)所示,当去掉二部图中的节点 R_4 、 R_9 和 C_7 时,二部图可以被分割为两个子图,而当在其中第一个子图中进一步去掉节点 R_3 、 C_2 和 C_9 时,该子图又可以被分割为两个子图,如此过程可以迭代执行。




图1 用户-物品评分矩阵与用户-物品二部图的关系示意图;矩阵的双边块对角结构等价于二部图聚类算法

基于矩阵的双边块对角型,一方面可以充分利用在矩阵预测领域取得显著效果的

各种协同过滤算法；另一方面可以充分利用二部图社区发现算法所发掘的用户兴趣社区关系，从而一举两得。需要指出的是，由于本质上仍然是在用户物品评分矩阵上进行协同过滤，因此双边块对角矩阵上的矩阵运算不仅限于某种特定的协同过滤算法，而是适用于各种常见的协同过滤算法，例如基于用户/物品的协同过滤，以及各种矩阵分解算法等。

利用矩阵的双边块对角型，本文提出了局部化矩阵分解框架（Localized Matrix Factorization）。局部化矩阵分解框架首先将原始稀疏矩阵转化为一个多层双边块对角矩阵，进一步从中抽取和拼接子矩阵构建一个对角块矩阵，并最终利用对角块矩阵上的预测结果来对原始矩阵给出打分预测。该框架拥有如下的优势：首先，局部化矩阵分解从原始矩阵中抽取密度较高的子矩阵（局部化），通过利用矩阵内的相似用户群组结构并降低数据稀疏性来提高预测精度；其次，该框架的局部性使得我们在原始矩阵得到更新（新增、修改或删除数据点）时，不需要重新对整个庞大的原始矩阵进行重新分解，而只需要在变化的子矩阵上重新分解即可，从而提高算法在实际应用中的可扩展性；最后，由于子矩阵各自的分解过程互不影响，使得算法可以很容易的并行化，从而提高矩阵分解的效率。

2 模型的可解释性

在用户物品评分矩阵这一基本输入的基础上，基于矩阵分解的隐变量模型在实际系统中得到了广泛的应用。然而隐变量实际意义的缺乏，使得模型学习得到的用

户偏好向量与物品属性向量难以有直观的解释，而这进一步影响了推荐结果的可解释性。为了解决这一问题，本文提出在模型层面具有可解释性的个性化推荐，从而在为用户提供个性化推荐的同时，告诉用户系统为什么会给出这样的推荐。

推荐的可解释性及推荐理由的构建对推荐系统具有重要作用，向用户恰当地解释为何一个物品被推荐出来，首先有助于提高推荐系统对用户的透明度和可信性；其次可以提高推荐结果的可辨性和说服力；最后可以帮助用户更快地做出正确的决定，从而提高用户与系统交互的效率。目前，学术界和产业界已经对推荐理由的构建进行了研究和实际使用，而目前常见的推荐理由多是基于统计的非个性化推荐理由，例如在亚马逊等购物网站中常见的“购买了该产品的用户也购买了”等。

另一方面，基于矩阵分解的隐变量模型（如图2所示），由于其较高的打分预测精度和模型可扩展性而受到学术界和产业界的广泛关注和使用时，目前已经成为多数实际推荐系统的基础算法。然而基于矩阵分解隐变量模型的推荐算法具有几个方面的重要问题，首先，由于变量的隐性，很难理解用户是如何将自己对产品各方面的态度和看法融合成一个单一的数值化打分的；其次，这进一步使得我们难以为用户给出契合特定偏好的和需求的推荐结果；最后，变量的隐性使得我们难以向用户解释为何一个物品被推荐了出来，甚至更难解释为什么其他物品没有被推荐出来，这使用户在实际系统中倾向于认为被推荐物

品仅仅是为了满足商业利益的广告。可解释性的缺乏降低了系统的可信度和说服力，也降低了系统满足用户需求的潜在能力。




图 2 基于矩阵分解的隐变量模型示意，其中原始矩阵被分解为两个因子矩阵的乘积

本文提出了显式变量分解模型 (Explicit Factor Model, EFM)，以在获得高预测精度的同时给出可解释的推荐结果^[1]。图 3 给出了基于显式变量分解模型的可解释性推荐基本流程。首先利用短语级情感分析技术从特定领域（如手机）的大规模用户评论中构建情感词典，即“属性词-情感词-情感极性”的三元组集合，并将其中的属性词作为显式特征空间。进而利用每个用户的历史评论构建用户属性关注度矩阵，以及利用每个产品的历史评论构建产品属性好评度矩阵，并结合原始的用户物品评分矩阵，构建基于多矩阵分解的显式变量分解模型来获得预测及个性化推荐。在图 3 的例子中，系统推断出用户对内存、耳机和




图 3 基于短语级情感分析构建情感词典，并从中获得属性词集合作为特征空间，从而给出可解释的推荐

颜色等属性词比较感兴趣，则会向用户提供在这些属性上表现优秀的产品作为推荐。

具体而言，本文首先利用大规模评论语料构建情感词典 L，为此设计和开发了短语级情感分析工具包，其中包括基于统计自然语言处理的属性观点词对挖掘系统^[2]，以及基于迭代优化的情感极性自动标注算法^[3]。短语级情感词典的构建主要包括如下三个步骤：首先基于语法和词法分析从大规模评论语料中抽取属性词集合 F；其次抽取观点词集合 O，并基于语法规则对评论中的每一个属性词匹配相对应的情感词，从而构建属性情感词对；最后基于标签扩散的方法对属性观点词对进行极性标注，得到每一个词对的情感得分 S，并最终得到情感词典 L 中的各个情感词条 F-O-S。

给定情感词典 L 和一条文本评论，该工作将该评论结构化为一个属性情感对 F-S' 的集合，其中 S' 是在这条评论中用户在属性词 F 上所表达的情感极性。为了更直观地描述该过程，图 4 给出一个示例。在图中所示的用户物品行为矩阵中，阴影部分表示相应用户对相应物品的评论，包括一个数值化的打分和一条文本。自此基础上，算法首先判断该文本所命中的情感词条，在本例中，包括（屏幕，出色，+1）和（耳机，好，+1）两个词条；进一步，判断每一个词条是否被否定词极性反转，发现第二个词条的进行被否定词“不”反转，对于被反转的情感词，算法对其原有的情感极性取相反数作为用户表达的真实情感。在此基础上最终得到用户在每一个属性词上表达的最终情感，并得到该文本评论的

结构化表示,在图4的例子中,包含(屏幕, +1)和(耳机, -1)两个部分。




图4 算法从评论中抽取“属性词-情感词-情感极性”词条,考察每一个词条是否被否定词反转,并计算出用户在每一个属性词上所表达的最终情感极性

由于不同的用户对产品不同属性的关注程度不同,他们在历史评论中对不同属性提及的频率也各不相同,一般而言,用户对自己所关心的属性往往提及频率更高。因此,算法构造用户属性关注度矩阵 X , 矩阵中的每一个元素表示相应的用户对属性的关心程度。类似地,算法构建物品属性好评度矩阵 Y , 其中矩阵的每一个元素描述相应的物品在属性上的表现,它是所有用户对该物品在该属性上评论极性的平均值。

矩阵 X 和 Y 中的非零值表示已经在历史评论文本中观测到的用户、物品、属性词关系,接下来算法将这些信息整合为多矩阵分解模型,从而在获得高预测精度和推荐效果的同时提高模型的可解释性。与用户物品评分矩阵 A 上直接的分解模型相似,算法对矩阵 X 和矩阵 Y 进行分解,即根据矩阵中已经观测到的非零值构建用户、物品和属性的表示,从而对矩阵中未观测到的值(以零值表示)进行预测和估计,模型的总体优化目标如下:

$$\begin{aligned} & \underset{U_1, U_2, V, H_1, H_2}{\text{minimize}} \{ \|PQ^T - A\|_F^2 + \lambda_x \|U_1 V^T - X\|_F^2 \\ & + \lambda_y \|U_2 V^T - Y\|_F^2 + \lambda_u (\|U_1\|_F^2 + \|U_2\|_F^2) \\ & + \lambda_h (\|H_1\|_F^2 + \|H_2\|_F^2) + \lambda_v \|V\|_F^2 \} \\ & \text{s. t. } U_1 \in R_+^{m \times r}, U_2 \in R_+^{n \times r}, V \in R_+^{p \times r} \\ & H_1 \in R_+^{m \times r'}, H_2 \in R_+^{n \times r'}, P = [U_1, H_1] \\ & Q = [U_2, H_2] \end{aligned}$$

图5给出了隐变量和显式变量在模型中的关系,以及矩阵 X 和 Y 对于矩阵 A 所起的作用。




图5 显式变量分解模型中产品属性词、矩阵 X 、矩阵 Y 、矩阵 A , 以及分解因子矩阵之间的关系示意图

给定算法的优化结果,模型可以对矩阵 X 、矩阵 Y , 以及矩阵 A 中的缺失值进行预测和估计,分别为 $\tilde{X} = U_1 V^T, \tilde{Y} = U_2 V^T$, 以及 $A = U_1 U_2^T + H_1 H_2^T$ 。基于这些信息,算法可以为用户提供个性化推荐列表并进行推荐理由的构建。对于不同的用户而言,决定用户在特定物品上的喜好因素是不同的,用户往往对其最为关心的几个属性进行主要的考量,并由此决定对物品的整体态度,而非对全部的上百个属性进行一一考虑。因此,当算法为用户 i 提供推荐时,考虑其最为关心的前 k 个产品属性而非全部上百个属性,并按照如下的相关性指标对物品排序:

$$R_{ij} = \alpha \frac{\sum_{c \in C_i} \tilde{X}_{ic} \cdot \tilde{Y}_{jc}}{kN} + (1 - \alpha) \tilde{A}_{ij}$$

传统矩阵分解隐变量模型难以为推荐结果给出直观的推荐理由，从而让系统人员和用户难以理解为什么一个物品得到推荐。而该工作基于物品属性词的显式变量分解模型，让用户很容易地理解每一个产品属性在生成推荐列表时的作用。在本工作中，算法为用户提供最直接的属性级个性化推荐理由，从而为用户提供产品的直观属性。对于被推荐物品，属性级个性化推荐理由的构建模板如下：

您可能对 [属性] 感兴趣，而该产品在 [属性] 上表现不错。

对于每一个用户，以及一个被推荐的物品，算法在该用户历史上所提到的物品属性中，选择那个在物品属性好评度矩阵中预测打分最高的属性来构造推荐理由。

3 个性化推荐的经济学解释

互联网经济系统及各种网络应用的一个基本功能是在线服务分配 (Online Service Allocation, OSA)，即将网络服务生产者 (Producer) 所提供的线上物品 (Goods) 分配给合适的网络服务消费者 (Consumer)，其中的线上物品包括各种可能的在线消费品，例如电子商务网站中实实在在的产品、互联网金融网站中的资金、在线人力资源网站中的工作项目等。由于消费者往往具有选择消费或者不消费、以及具体消费哪种物品的自由，因此这样的在线服务分配过程往往并不是强制的发生，而是通过个性化推荐或搜索的方式来实现的。搜索引擎 (如百度、谷歌或亚马逊购物搜索等) 在用户 (大概) 清楚自己的需求时通过搜索和排序来发挥作用，而

个性化推荐 (如产品推荐、好友推荐等) 则在用户没有显式地提供自己的查询需求时发挥作用。

目前的推荐和检索解决方案，往往在设计之初就集中于满足供需双方其中一方的利益而没有将整个互联网经济系统作为整体进行考虑，从而忽略甚至牺牲了另一方面的潜在收益。例如，最为广泛使用的基于协同过滤的个性化推荐算法试图基于用户的兴趣偏好而尽可能地最大化用户满意度。尽管消费者满意度的提升可以通过提高点击率而潜在地提高生产者的福利，但是并没有明确的保证使得我们可以通过一个单方面的优化问题而提高整个系统双方面的收益。

本章就以该问题为核心，对个性化推荐在互联网经济系统中深刻的经济学意义进行分析，并借助经济学家对经济系统的深刻认识，解读个性化推荐在网络服务分配过程中的作用。具体而言，提出互联网总福利最大化 (Total Surplus Maximization, TSM) 框架，从而将生产者福利和消费者福利的整体最大化理念融入到个性化推荐系统的设计中^[4]。通过网络总福利最大化，系统为生产者和消费者提供更大的蛋糕 (总福利) 进行分享，而不是在既有的总福利中进行争夺。

在现代主流经济学中，经济福利 (Surplus) 往往用来表示经济系统的运行总效率，它主要包括三个紧密相关的概念，即消费者福利 (Consumer Surplus) $CS = \int_0^q (U'(q) - P) dq = U(q_c) - Pq_c$ 、生产者福利

(Producer Surplus) $PS = \int_0^{q_c} (P - C'(q))dq = Pq_c - C(q_c)$ 和社会总福利 (Total/Social Surplus) $TS = CS + PS = U(q_c) - C(p_c)$ 。其中消费者福利为商品对消费者的效用减去其付出的价格, 生产者福利为生产者从消费者那里获得的价格减去其成本, 而总福利为系统中生产者和消费者所获福利之和。

考虑如下的问题: 如何对给定的网络商品在消费者 (网络用户) 之间进行分配, 以最大化网络经济系统的总福利。假设系统中存在 m 个消费者 $\{u_1, u_2, \dots, u_m\}$ 和 n 个物品 $\{g_1, g_2, \dots, g_n\}$ 。这里的“物品”有可能是电子商务网站中的商品、在线众包网站中的工作, 或者 P2P 借贷网站中的贷款理财产品等。这些商品由 r 个生产者 $\{p_1, p_2, \dots, p_r\}$ 提供, 其中每一个物品背后有一个确定的生产者, 而每个生产者有可能提供多种物品。再接下来, 用 $1 \leq i \leq m$ 、 $1 \leq j \leq n$ 和 $1 \leq k \leq r$ 来表示消费者、物品和生产者, 并令 $M = [M_1, M_2, \dots, M_n]$ 表示商品数量向量, 其中 $M_j \geq 0$ 为系统中物品 g_j 可以被其生产者所提供的最大数量。在线服务分配任务试图寻找一个分配矩阵 (Allocation Matrix) $Q = [Q_{ij}]_{(m \times n)}$, 其中 $Q_{ij} \geq 0$ 为商品 g_j 分配给消费者 u_i 的数量。

为了寻找这样的分配矩阵, 算法首先估计每一个商品对每一个用户的个性化效用函数。即便对于同样数量的同一种产品或服务, 不同的消费者因其喜好的不同也可能获得不同的效用。例如在电子商务网站中, 一个单反镜头可能对于一位已经购买了单反相机的消费者而言具有较高的效用, 而对于一位没有单反相机的消费者而言,

则可能几乎没有效用。效用的这一“个性化”本质是服务分配得以有实际作用的根本驱动力, 如果所有用户对同一产品的效用是完全一样的, 则不同的分配方式对最终系统的福利没有什么影响。正是因为个性化效用的不同, 使得我们可以设计合适的分配方案让产品找到效用最高的消费者, 从而提高经济系统的福利和效用。在本工作中, 算法采用消费者到商品级别的个性化效用函数 $U_{ij}(q) = a_{ij} \ln(1+q)$ 。

在此基础上, 算法通过优化如下总福利的期望来寻找最优的分配矩阵 Q :

$$\begin{aligned} & \underset{\Theta(Q)}{\text{maximize}} \sum_i \sum_j \int (U_{ij}(Q_{ij}) - C_j(Q_{ij})) p(Q_{ij}) dQ_{ij} \\ & \text{s. t.} \quad \mathbf{1}^T \int Q p(Q) dQ \leq M, \quad Q_{ij} \in \mathcal{S} \end{aligned}$$

其中, $p(Q_{ij})$ 为分配矩阵 Q 中每一个元素 Q_{ij} 的密度函数, 矩阵 Q 的密度函数为 $p(Q) = [p(Q_{ij})]_{(m \times n)}$, 并且在矩阵 Q 上的积分也是元素级别的。另外, $\Theta(Q)$ 为所有 Q_{ij} 分布的参数。该模型的最终输出为分配矩阵 Q 的最优密度函数 $p(Q)$, 在此基础上, 可以将概率密度函数的期望值 $\bar{Q} = \int Q p(Q) dQ$ 作为最终的分配矩阵, 并用来进行个性化推荐。

4 结束语

随着互联网应用的不断丰富和网络智能的不断发展, 个性化推荐系统已经成为各种互联网应用和平台中必不可少的组成部分, 例如电子商务网站中的商品推荐、社交网络中的好友推荐、在线门户网站中的新闻推荐等。个性化推荐技术是网络系统用于理解和分析用户的个性化需求并做出响应的基础性技术, 在

实验结果显示,本文模型在线下真实数据集评测和线上真实用户评测两个方面均取得较好的效果,在提高用户(消费者)对推荐系统的体验的同时也提高经济系统的总福利,从而提高推荐系统的经济效益。

- [1] Zhang Y, Lai G, Zhang M, et al. Explicit Factor Models for Explainable Recommendation based on Phrase-level Sentiment Analysis[C]//Proceedings of the 37th Annual International ACM SIGIR Conference on Research and Development on Information Retrieval. ACM, 2014.
- [2] Tan Y, Zhang Y, Zhang M, et al. A unified framework for emotional elements extraction based on finite state matching machine [C]//Natural Language Processing and Chinese Computing. Springer, 2013: 60-71.
- [3] Zhang Y, Zhang H, Zhang M, et al. Do users rate or review? Boost phrase-level sentiment labeling with review-level sentiment classification [C]// Proceedings of the 37th international ACM SIGIR conference on Research & development in information retrieval. ACM, 2014. 1027-1030.
- [4] Zhang Y, Zhao Q, Zhang Y, et al. Economic Recommendation with Surplus Maximization [C]// Proceedings of the 25th International World Wide Web Conference. 2016.



◆◆◆◆◆ 简 讯 ◆◆◆◆◆

12月8日，由中国人工智能学会承办的2017世界智能制造大会——制造业+人工智能技术论坛顺利召开，来自全球知名专家、学者、业界精英汇集于此，展开一场制造业+人工智能技术主题论坛，带领参会听众共同开启全新视角，展示中国制造向中国“智造”迈进的重要转变。

近日，中国人工智能学会与罗兰贝格联合发布《中国人工智能创新应用白皮书》。该报告详细梳理了人工智能的发展历史、人工智能商业应用现状，以及应用场景案例。报告指出，中国人工智能企业在当下人工智能第三次浪潮中的发展势头良好，处于全球优势领先地位；金融、汽车、零售和医疗将会是受其影响最大、最具成熟发展基础与市场应用潜力的传统产业，制造、教育、通信行业也值得关注。对于各行业的企业而言，布局人工智能应用，时机就在当下。

妙小程 硅谷AI时空之旅

少儿编程国际挑战赛

暨2018年 冬令营



少儿学编程，就用妙小程！

妙小程是上海耕子教育科技有限公司联合硅谷人工智能专家，专为中国孩子设计开发的PAD / PC端编程工具，作为中国少儿编程在线教育平台，主要向6-18岁青少年提供由硅谷专家设计，对标加州大学计算机科学专业的编程课程，涵盖了启蒙、中级、高考、竞赛和高端的五大阶段课程。

活动收获

- | | |
|----------|----------|
| 1、前沿科技启蒙 | 6、解决问题能力 |
| 2、开阔眼界 | 7、团队协作 |
| 3、语言锻炼 | 8、动手能力 |
| 4、自我反馈能力 | 9、自理能力 |
| 5、激发求知欲 | 10、收获友情 |

行程安排

行程中，一般安排上午游览美景或探访知名科技公司；下午参观科技馆、博物馆、图书馆，学员学习“妙小程”人工智能编程课程

模块1：“妙小程”团队破冰拓展

模块2：“妙小程”探究上下五千年计算史

模块3：“妙小程”硅谷教授AI未来讲堂

模块4：“妙小程”分组项目编程课程

模块5：“妙小程”实验室编程课程

模块6：“妙小程”机器人编程课程

模块7：“妙小程”国际营编程课程

行程亮点

- 7大模块：“妙小程”人工智能编程七大课程模块，层层深入AI与编程世界
- 3所美国著名研究型大学：加州伯克利、斯坦福、卡内基梅隆。校园、实验室参访，探寻顶级学府氛围
- 3所世界知名科技公司：谷歌、英特尔、苹果。领略时代前沿
- 4所科技博物馆参观，徜徉未来世界
- 5座硅谷名城：旧金山、圣何塞、山景城、奥克兰、帕罗奥托，当地著名旅游景点游览，领略美国风光
- 1场比赛：第一届“妙小程”杯国际编程挑战赛，团队协作并肩作战
- 1所美国小学参访，走入美国课堂
- 1项贯穿始终的神秘挑战！最好的到最后一刻才会揭晓哦！

活动安排

活动时间：2018年 1月27日-2月4日

适合人群：9岁以上适龄儿童（编程零基础或者有基础皆可）

师生配比：中美两地带队老师 1+1配比，5人配一位带队老师

项目费用包含：签证服务、课程费用、景点门票、保险费用、经济舱机票、全球高端商务酒店7夜住宿

项目费用不包含：办理护照的费用、个人零花钱、行李超重托运费等个人花费（家长如要参加可自费或者付费由妙小程办理）

活动价格：请添加妙小程客服号：miaocode-omo 咨询详情

妙小程客服微信



客服微信号
miaocode-omo



咨询客服



缴费报名



准备材料



取得签证



行前家长会



顺利出发

网址：<http://www.miaocode.com>

电话：17721133714

地址：上海市徐汇区田林路130号20号楼

*因具体安排、课程设计等原因，最终行程可能微调。“妙小程”保有对硅谷冬令营的最终解释权。

快来一起学编程！

Hi!



妙小程微信公众号



12期
2017年 第7卷