

基于影响函数的图分类模型任务优化方法

康 洁¹ 蒲天乐¹ 黄魁华^{1*} 范长俊¹ 刘世旋¹

摘 要 图分类在分子化学、生物领域、社交网络等方面有着广泛的应用。目前图分类主要分为基于相似度计算方法和基于图神经网络方法。基于相似度计算方法在处理复杂图形结构和非线性特征时效果不佳,而基于图神经网络方法需要大量计算资源和数据,训练和超参数调优难度较大,并且可解释性较差。文章提出了基于影响函数的数据增强方法,该方法只需要进行两轮训练,即可提高训练数据的使用效率,同时提高了模型的可解释性和分类问题的可靠性。文章的主要贡献包括使用影响函数引导的方式实现数据增强、确定与预测结果相关的关键训练点,提高模型的可解释性,以及进行了大量实验验证所提出方法的有效性。

关键词 图分类模型, 影响函数, 交叉验证, 数据增强

Optimization Method for Graph Classification Tasks Based on Influence Function

KANG Jie¹ PU Tian-Le¹ HUANG Kui-Hua^{1*} FAN Chang-Jun¹ LIU Shi-Xuan¹

Abstract Graph classification has been widely used in fields such as molecular chemistry, biology, and social networks. Currently, graph classification methods are mainly divided into two types: those based on similarity calculation methods and those based on graph neural network methods. Methods based on similarity calculation are ineffective in handling complex graphic structures and nonlinear features, while methods based on graph neural networks require a large amount of computing resources and data. Training and hyperparameter optimization are difficult, and they may not be explainable. Therefore, this paper proposes a data augmentation method based on the influence function. This method only requires two rounds of training to improve the efficiency of training data usage, while also improving the interpretability of the model and the reliability of the classification problem. The main contributions of this paper include using the influence function-guided approach to achieve data augmentation, determining key training points related to prediction results to improve model interpretability, and conducting a large number of experimental verifications to validate the effectiveness of the proposed method.

Key words graph classification model, influence function, similar to cross-validation, data augmentation

1 介绍

图分类是指对图结构数据进行分类的任务。在图分类问题中,每个样本都是一个图,由节点和边组成,而每个节点和边都具有特定的属性或者标签。目标是根据给定的图结构,将其分为不同的预定义类别。在分子化学领域,图分类可用于分类已知化合物,并为未知化合物预测分子结构和属性,这有望用于开发新的药物或改进现有药物的效力^[1]。在生物领域,可以将不同形状的蛋白质归为不同的类别,为更深入了解它们的结构和功能打下基础^[2]。在社交网络中,用图分类技术将用户分为朋友、家

庭成员、同事等不同的群体,能够有助于社交网络分析以及社交媒体营销等领域的研究。将信息和病毒传播过程建模为一个图,并使用机器学习算法对该图进行分类,以判断信息是否为假信息、病毒是否传播^[3,4]。

目前存在两种主要的图分类方法^[5]:一种是基于相似度计算方法,另一种是基于图神经网络方法。基于相似度计算的方法通常是通过计算图之间的一些相似性度量来判断它们是否属于同一类别。这些相似性度量包括图的特征向量、距离度量、图匹配等,可以使用传统的机器学习算法,如支持向量机、决策树、随机森林等进行分类。但是,基于相似度计算的方法无法处理复杂的图形结构和非线性特征,

* 通讯作者

1. 国防科技大学大数据与决策实验室

1. Laboratory for big data and decision, National University of Defense Technology

对于大规模和较为复杂的数据集分类效果不如基于图神经网络的方法。方法设计可能充满主观性,无法保证分类精度的可靠性。基于图神经网络的方法,则是利用深度学习网络在端到端的训练过程中,同时处理节点特征和图结构,从而实现对图的分类。这类方法能够从端到端地优化输出结果,并且在图结构具有复杂性和动态性的情况下表现更加优越。但是基于图神经网络的方法需要大量的数据和计算资源,模型训练和超参数调优难度较大。相比于传统的方法,使用黑盒式图神经网络的模型可能无法进行解释,对于一些敏感性的分类问题存在可靠性不高的风险。

针对以上存在的问题,本文提出了基于影响函数的数据增强方法。该方法仅需进行两轮训练,就能提高训练数据的使用效率。另外,该方法是模型无关的,可以与任意已经训练好的模型结合使用,在模型训练和超参数调优上难度小。当数据中有噪声时,模型性能会大大降低^[6]。本文通过影响函数的计算研究单个训练样本数据对模型性能的影响,增加了黑盒图神经网络的可解释性,提高图分类问题的可靠性。该方法从训练数据中筛选出对模型性能有正向影响的样本来形成新的训练数据集,以此来重新训练模型。如何筛选对模型有良好正向影响的样本呢?为了解决这个问题,论文将影响函数从图像领域引入图数据领域中,通过计算影响函数得到训练样本对模型性能的影响,进一步解决这个问题。大量实验证明,论文提出的方法能够进一步提高 GNN 模型的性能,如 GCN^[7], GIN^[8], GAT^[9]等。在本文提出的方法中,第一轮训练得到的模型仅用于选择出对模型性能影响较大的训练数据,以重构训练集。第二轮将重新训练最终模型。

具体地,本文的主要贡献包括以下三点:

第一,使用影响函数引导的方式实现对模型训练数据的增强,进而提高图分类模型的分类效果;

第二,可以确定与预测结果相关的关键训练点,从而提高数据处理过程的可解释性;

第三,将提出的方法与 GCN、GIN、GAT 模型结合,验证了所提方法的有效性。

2 相关工作

基于相似度计算的图分类方法通过图核或图匹配计算图之间的相似度,从而进行分类。例如,R-卷积核^[10]通过将图分解成各个组件并对其进行比较来计算它们的相似度。而基于图神经网络的图

分类方法通常先通过卷积进行多次特征变换,然后进行池化操作,从而将图缩小。该过程可以重复多次,最终得到整张图的表示并进行分类。GCN^[7], GAT^[9], GIN^[8]是比较常见的图分类方法。还有一种方法是把非欧图数据转化为网格结构,然后进行卷积。Niepert 等^[11]首先提出了 PSCN 模型,该模型将非欧图数据转换为欧式数据,并利用节点选择方法解决不同图数据中节点数量不同的问题。

本文提出的基于影响函数的数据增强方法属于基于图神经网络的图分类方法。本文将影响函数方法从图像领域引入图数据领域,用于优化图分类模型。Hampel^[12]最早提出了影响函数,用于计算更改训练样本的权重对模型参数的影响,但在机器学习中应用较少。Koh P W 等^[13]推导并近似计算影响函数的公式,证明其在不可微非凸模型上有较好的近似效果,并提出在不重复训练的前提下使用影响函数来引导图像的对抗攻击,为影响函数进入机器学习打开了大门。后来又使用影响函数研究大量训练数据被移除对模型性能的影响^[14]。Wang Z 等^[15]提出了未加权影响数据子采样 (UIDS) 方法,并证明该方法获得的子集模型可以优于全集模型。Seetharaman S 等^[16]提出了一种基于影响函数的方法防御在线学习的数据投毒攻击,以最小化投毒数据引起的退化。Wang T 等提出 DataDrop 方法^[17],通过影响函数研究单个训练样本对模型泛化能力的影响,通过丢弃不利的样本进一步提高泛化精度。

在图数据领域,Fang M^[18]使用影响函数对基于图的 top-N 推荐系统实施数据中毒攻击。该攻击不再优化所有正常用户的虚假评级,而是利用一个具有影响力的用户子集来解决此问题。Chen Z 等^[19]用影响函数从节点表示的角度来引导 SGN/GCN 的对抗攻击和提高模型性能,以应用于节点分类任务。

本文使用影响函数对训练数据进行增强进而优化模型提高模型的分类效果可以与任意图分类模型结合使用,提高模型性能。Wang T 等提出的 DataDrop 方法^[17]应用于图像领域,该论文通过计算每个训练样本对于所有验证集的影响函数值之和,来判断是否删除该训练样本。该方法只考虑训练点对总体验证集的影响,而未考虑每个验证集的影响。该方法应用于图神经网络领域,在进行数据删除处理后,发现删除的数据较多,严重影响了模型性能。本文把影响函数由图像领域引入图数据领域,并计算每个训练样本对每个验证样本的影响值。选取对验证样本影响较大的训练样本,生成新的训练样本数据,用于模型的重新训练。

3 方法

3.1 符号定义

$Z = (z_1, \dots, z_n)$ 表示 n 个训练样本的集合, 其中 $z_i = (G_i, y_i)$, 其中 G_i 表示第 i 个图, y_i 表示图 G_i 的标签。 $f_{\hat{\theta}}(\cdot)$ 表示参数为 $\hat{\theta}$ 的模型, $L(z, \theta)$ 表示样本 z 在模型参数为 θ 下的损失函数。 ε 表示单个训练样本在整个损失函数中权重的变化。 $r \in [0, 1]$ 为针对每个验证样本选取训练数据的比率。新的训练样本为 $Z' = (z'_1, \dots, z'_n)$, 重新训练得到的模型参数为 θ' , 重新训练得到的模型为 $f_{\hat{\theta}'}(\cdot)$ 。 num 是数据划分中, 数据中训练集和验证集的个数。

3.2 影响函数介绍

根据影响函数在图像领域的应用^[13], 本文可以推导出图分类模型中单个训练样本对于单个验证样本预测性能的影响函数为式 (1):

$$I_{up, loss}(z, z_{val}) = \left. \frac{dL(z_{val}, \hat{\theta}_{\varepsilon, z})}{d\varepsilon} \right|_{\varepsilon=0} = -\nabla_{\theta} L(z_{val}, \hat{\theta})^T H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z, \hat{\theta}) \quad (1)$$

式中, $\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n L(z_i, \theta)$ 是经验风险最小时的

模型参数, 模型训练的目标是学习得到参数 $\hat{\theta}$ 使模型的损失函数最小。损失函数可以是均方误差损失函数、对数损失函数、交叉熵损失函数、KL 散度损失函数等。

$H_{\hat{\theta}} = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta}^2 L(z_i, \hat{\theta})$ 是海森矩阵 (Hessian Matrix), 假设其是正定的。 z, z_{val} 分别是训练样本点和验证样本点。影响函数 $I_{loss}(z, z_{val})$ 可以被写成 $I_{loss}(z, z_{val}) = -s_{val} \nabla_{\theta} L(z, \hat{\theta})$, 其中 $s_{val} = \nabla_{\theta} L(z_{val}, \hat{\theta})^T H_{\hat{\theta}}^{-1}$ 可以使用海森向量乘积 (Hessian-vector products, HVPs) 近似计算, 提高计算的效率^[20-22]。

3.3 数据抽样介绍

验证集和测试集数据分布相似, 使用验证集引导生成的新训练集可以有效预测测试集数据。通过计算 $I_{loss}(z, z_{val})$ 可以得到每个训练样本对验证样本 z_{val} 的影响函数值, 负值代表对减少损失函数的值有正向促进作用; 反之, 亦然。对这些值进行反向排序, 针对 z_{val} 选取影响函数值排序的 r 对应的训练样本, 每个验证样本都如此操作。训练数据的更新如图 1 所示。




图 1 每折训练数据更新流程图

选取后的训练样本合并构成新的训练样本 $Z' = (z'_1, \dots, z'_n)$ 。通过第二轮训练得到模型参数, 得式 (2):

$$\hat{\theta}' = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n L(z'_i, \theta), z'_i \in Z' \quad (2)$$

得到新的模型为 $f_{\hat{\theta}'}(\cdot)$ 。本文针对每个验证样本来选取训练样本点, 而 DataDrop^[17] 方法是针对所有的验证样本来选择删除的训练样本, 本论文的方法更加细致有效。

新训练样本的样本量比原本少, 本文用对多个验证样本的预测有正向促进作用的训练样本作为补充, 得到与原数据相同的新训练样本。这种补充方式可以使对模型性能正向影响的样本得到更多的注意力。

3.4 类交叉验证的介绍

在进行训练之前, 需要合理地对数据进行划分, 以便更充分地利用数据。本文假设验证集和测试集具有相同的数据分布, 利用验证集来计算影响函数以指导训练集的选择。先进行十折交叉验证划分, 生成十个不同的训练集和测试集。再对得到的每个训练集进行 num 次随机划分, 得到 num 组的训练集和验证集 (图 1), 这种方法被称为类交叉验证。相比于十折交叉验证, 类交叉验证增加了训练集的 num 次的二次划分, 使得根据验证集构建新的训练集更具有泛化性。如果 $num=1$, 也就是说, 对训练集只进行一次次级划分, 得到一个训练集和一个验证集。使用第一轮训练得到的模型对验证集计算每个训练集的影响函数值。然后, 基于这个影响函数值从原始训练集中选择新的训练集进行第二轮训练。也就是说, 只能从这一个训练集中选择数据作为新

的训练集,无法从验证集中选取数据,造成验证集数据的浪费。同样,训练集数据也无法成为验证集数据,这样就无法对训练集的某些数据计算影响函数值,无法引导新的训练集的选择。如果对训练集和验证集进行多次随机划分,则验证集数据有机会成为训练集数据,反之亦然。这样选择出来的新训练集更具有泛化性。

3.5 可解释性

本文方法可直接计算图数据中的每个训练样本对模型训练的正负影响,并量化影响程度。通过计算影响函数,本文可以追踪到提高模型预测性能的训练样本,从而确定与预测结果相关的关键训练点,从而提高模型的可解释性,帮助我们理解模型是如何从训练数据中学习到特定的预测结果的。式(1)表达的含义为训练集样本权重更改较小的值,对验证集损失函数值的影响。所以通过这个公式计算得到的影响函数值,能够表示训练集对于该验证集样本预测的影响。通过计算影响函数,可以找到模型性能和训练数据之间的关系,可以有效可解释地对训练数据进行处理。在本文中,通过影响函数值的明确指引,可以有效可解释地选取正向影响的图作为新的训练数据集。影响函数带来的可解释也可运用到理解模型行为、调试模型、检测数据集错误以及创建视觉上无法区分的训练集攻击^[13]。

4 实验

为了验证基于影响函数的数据增强方法的有效性,论文进行了大量的实验,使用本文提出的方法与GCN^[7]、GIN^[8]、GAT^[9]这三种图神经网络模型结合,进行图分类任务。使用类交叉验证方法划分数据集,评估模型的性能。所有的实验都部署在pytorch上。

在一轮训练之后,通过影响函数抽样出对模型性能影响较大的训练样本,抽样之后得到的新的训练集中样本数量减少。针对这个问题,补充对多个验证集产生正向影响的训练样本,构成新的训练集。

4.1 实验准备

实验中数据集、对比模型、实验设置详细介绍如下。

4.1.1 数据集

为了更真实地模拟图分类任务在社交网络中的应用,论文在真实的社交网络上进行图分类任务。

MIT^[23]是麻省理工学院学生之间的交互时间图。

两个基于SocioPatterns项目的数据集为Highschool和Infectious。Highschool是接触网络图,代表着在七天内每20s学生之间的互动。Infectious^[24]代表了展览参观者之间的面对面对接触。Tumblr是Memetracker数据集^[25]的子集,它包含Tumblr用户之间的引用关系。DBLPs是使用DBLP数据库^[4]的子集来生成时间相关的共同作者图,边是联合出版的年份。为了获得用于监督图分类的数据集,Lutz Oettershagen等^[4]对以上数据集从每个顶点开始BFS运行,生成子图。具体图数据的信息如表1所示。

表1 数据集的统计信息和属性

数据集	图数	平均节点数	平均边数	图的类别
MIT	97	20	1469.15	2
Highschool	180	52.32	544.81	2
Infectious	200	50	459.72	2
Tumblr	373	53.11	71.63	2
DBLP	755	52.87	99.78	2

4.1.2 对比模型

本文提出的方法是模型无关的,可以与任意的图分类方法进行结合,提高图分类的性能。本文在GCN^[7]、GIN^[8]、GAT^[9]这三个常见的图分类模型上添加基于影响函数的数据增强抽样方法,比较添加前后的差别。添加该方法之后在表中写作GCN++、GIN++、GAT++。

4.1.3 实验设置

第一轮训练中,数据集通过十折交叉验证划分为训练集和测试集,可使用GCN^[7]、GIN^[8]、GAT^[9]等作为基础网络模型进行训练。第二轮训练中,对数据进行类交叉验证划分,具体如下:首先,对数据进行十折交叉验证划分,得到十折训练集和测试集。其次,每折中的训练集再次划分为训练集和验证集,本文设置划分比为8:1。每折训练集再次划分可以重复num次,本文num设置为2。最后得到的十折数据,每折数据中只有一个测试集,训练集和验证集有num组。根据划分后的数据集以及第一轮训练好的模型计算影响函数值,挑选新的训练样本进行重新训练。

对于GCN^[7]、GIN^[8]、GAT^[9]和GCN++,GIN++,GAT++默认训练500轮。为了消除数据集划分对实验结果的影响,使用十折交叉验证来评估模型性能,在训练的时候从第120轮开始记录模型的性能,返回最好的训练轮次和实验结果。构建GCN^[7]、GIN^[8]、GAT^[9]模型时,GCNConv、GINConv、GATConv网络层设置为3层,隐藏层维度设

置为 64，并且 GAT 中注意力头的数量为 4。使用 Adam 优化器，学习率从 0.01 开始，每 50 个轮次减少一半，直到达到 500 轮。第一轮和第二轮模型结构和参数设置相同，以保证模型性能的提高与调参无关，只与方法有关。

4.2 实验结果分析

以 GCN^[7]、GIN^[8]、GAT^[9] 为基线 GCN++、GIN++、GAT++在五个数据集上获得的准确度和 F1-score，如表 2 所示（粗体为最佳结果）。

表 2 GCN、GIN、GAT 作为基线的准确率和 F1-score 以及这三个网络模型加上基于影响函数数据增强方法后的准确率和 F1-score

数据集	MIT		Highschool		Infectious		Tumblr		DBLP	
	准确率	F1	准确率	F1	准确率	F1	准确率	F1	准确率	F1
GCN	0.4944	0.4354	0.6667	0.6557	0.82	0.8177	0.8259	0.8246	0.9218	0.9217
GCN++	0.6011	0.576	0.6678	0.6728	0.83	0.8285	0.8314	0.831	0.9311	0.931
GIN	0.5467	0.4753	0.6833	0.6778	0.81	0.8075	0.8286	0.8282	0.9125	0.9124
GIN++	0.6011	0.5399	0.6889	0.6826	0.83	0.827	0.8366	0.8359	0.9205	0.9204
GAT	0.5767	0.5254	0.6722	0.6578	0.78	0.7674	0.6326	0.5985	0.8024	0.794
GAT++	0.6511	0.5799	0.6722	0.644	0.78	0.7708	0.6644	0.6215	0.8094	0.8068

表 2 中的结果表明，GCN++和 GIN++在所有五个数据集上的表现都优于比较模型。GAT++虽然在 Highschool 和 Infectious 这两个数据集上与 GAT 表现相同，但在其他数据集上都比 GAT 表现好。与 GCN 基线相比，GCN++在 MIT、Infectious 和 DBLP 数据集上分别获得了 21.6%、1.2% 和 1% 的相对准确度

提升，如图 2 所示。本文提出的算法在 MIT 数据集上效果最好，GCN++、GIN++、GAT++分别提升 21.6%、10%、12.9%。通过计算图的密度发现，MIT 数据集的平均图密度为 7.7324，其他数据集的图密度还不到 1，推测该算法对密度较大的图，性能提升较多。




图 2 GCN 和 GCN++在 MIT 数据集上性能对比图

5 讨论

这个实验过程采用两轮训练方法进行模型训练和验证。其中第一轮采用了传统的十折交叉验证方法，将数据划分成十折用于训练和测试。第二轮则采用了类交叉验证方法，先对数据进行十次划分，每次得到训练集和测试集，再将训练集上的数据进行多次划分，得到多组训练集和验证集的组合。接下来，根据第一轮训练得到的模型对每个验证集预

测影响函数值，从中挑选出对每个验证集预测有帮助的训练样本，并将其作为新的训练数据集用于第二轮训练。这个过程能够将第一轮的训练信息与第二轮的影响函数计算相结合，有效提高模型的预测性能，并保证了训练和验证的准确性和全面性。总体而言，这个过程可以更好地训练和测试模型，并获得更精确的预测性能评估结果。

实验结果表明，将该方法与其他图分类模型结合后，可以有效提高模型的性能，尤其在图密度较大的图数据上性能提升更为明显。此外，该方法还

带有可解释性,可以准确地判断哪些图数据是不良数据,为模型性能的进一步提升提供了有价值的信息。值得注意的是,数据集的划分对模型性能影响较大,可能是由于验证集和测试集数据分布不一致所导致。因此,在未来的研究中,需要更有效地解决验证集和测试集数据分布不一致的问题,以进一步提高模型的性能和可靠性。

6 结束语

本文提出了通过基于影响函数的数据增强法提高图分类模型预测性能,并在实验中验证了该方法的有效性和可解释性。发现该方法在图密度较大的数据上作用较大。研究还发现数据集划分对模型性能有较大影响,未来需要处理验证集和测试集数据分布不一致的问题。总体来说,该研究为图分类问题的解决提供了有益参考。

参考文献

- SMALTER A M, HUAN J, LUSHINGTON G H. Graph Wavelet Alignment Kernels for Drug Virtual Screening [J]. *Journal of bioinformatics and computational biology*, 2009, 7 3: 473-497.
- BORGWARDT K M, KRIEGEL H-P. Graph Kernels For Disease Outcome Prediction From Protein-Protein Interaction Networks [J]. *Pacific Symposium on Biocomputing Pacific Symposium on Biocomputing*, 2006: 4-15.
- GUPTA K, POTIKA K. Fake News Analysis and Graph Classification on a COVID-19 Twitter Dataset [J]. 2021 IEEE Seventh International Conference on Big Data Computing Service and Applications (BigDataService), 2021: 60-68.
- OETTERSHAGEN L, KRIEGEL N M, MORRIS C, et al. Temporal Graph Kernels for Classifying Dissemination Processes [J]. *ArXiv*, 2019.
- 王兆慧, 沈华伟, 曹婧, 等. 图分类研究综述 [J]. *软件学报*, 2022, 33 (1): 171-192.
- CHRISTIAN S, WOJCIECH Z, ILYA S. Intriguing properties of neural networks [Z]. 2014.
- ZHANG H, LU G, ZHAN M, et al. Semi-Supervised Classification of Graph Convolutional Networks with Laplacian Rank Constraints [J]. *Neural Processing Letters*, 2022, 54 (4): 2645-2656.
- KEYULU X, WEIHUA H, JURE L, et al. How Powerful are Graph Neural Networks? [J]. *Statistics*, 2018.
- VELICKOVIC P, CUCURULL G, CASANOVA A, et al. Graph Attention Networks [J]. *ArXiv*, 2017.
- GAERTNER T, FLACH P A, WROBEL S. On Graph Kernels [C] // *Hardness Results and Efficient Alternatives. proceedings of the Annual Conference Computational Learning Theory*. 2003 .
- MCKAY B D, PIPERNO A. Practical graph isomorphism, II (Article) [J]. *Journal of Symbolic Computation*, 2014, 60: 94-112.
- FRANK R H. The Influence Curve and Its Role in Robust Estimation [J]. *Journal of the American Statistical Association*, 1974, 69 (346): 383.
- KOH P W, LIANG P. Understanding Black-box Predictions via Influence Functions [J]. *ArXiv*, 2017.
- KOH P W, ANG K-S, TEO H H K, et al. On the Accuracy of Influence Functions for Measuring Group Effects [C] // *proceedings of the Neural Information Processing Systems*. 2019.
- WANG Z, ZHU H, DONG Z, et al. Less is better: Vn-weighted data Subsampling vja influence function [C] // *Proceedings of the AAAI Conference on Artificial Intelligence*. 2022: 6340-6347.
- SANJAY S, SHUBHAM M, ROSNI V, et al. Influence Based Defense Against Data Poisoning Attacks in Online Learning [C] // *2022 14th International Conference on COMMunication Systems & NETWORKS (COMSNETS)*. TCS Research, Pune, India University of Zurich, Zurich, Switzerland. 2022.
- WANG T, HUAN J, LI B. Data Dropout: Optimizing Training Data for Convolutional Neural Networks [J]. 2018 IEEE 30th International Conference on Tools with Artificial Intelligence (ICTAI), 2018: 39-46.
- FANG M, GONG N Z, [IV]. Influence function based data Poisoning attacks to top-n recommender system [C] // *Proceedings of The Web Conference 2020*. 2020: 3019-3025.
- CHEN Z, LI P, LIU H, et al. Characterizing the Influence of Graph Elements [J]. *ArXiv*, 2022.
- PEARLMUTTER B A. Fast Exact Multiplication by the Hessian [J]. *Neural Computation*, 1994, 6: 147-160.
- MARTENS J. Deep learning via Hessian-free optimization [C] // *proceedings of the International Conference on Machine Learning*. 2010 .
- AGARWAL N, BULLINS B, HAZAN E. Second Order Stochastic Optimization in Linear Time [J]. *ArXiv*, 2016.
- EAGLE N, PENTLAND A S. Reality mining: sensing complex social systems [J]. *Personal and Ubiquitous Computing*, 2006, 10: 255-268.
- ISELLA L, STEHLÉ J, BARRAT A, et al. What's in a crowd? Analysis of face-to-face behavioral networks [J]. *Journal of theoretical biology*, 2010, 271 (1): 166-180.
- LESKOVEC J, BACKSTROM L, KLEINBERG J M. Meme-tracking and the dynamics of the news cycle [C]. *knowledge Discovery and Data Mining*, 2009.