

人工智能时代下的复杂网络

刘家臻¹ 王寰东¹ 丁璟韬¹ 颜欢¹ 徐丰力¹ 范长俊^{2,*} 李勇^{1,*} 刘忠^{2,*}

(1. 清华大学 电子工程系, 北京 100084; 2. 国防科技大学 系统工程学院, 长沙 410073)

摘要 人工智能(AI)在21世纪取得了革命性的突破, AI方法驱动的复杂网络研究新范式, 将为复杂网络的描述、理解、预测与优化提供一条全新的路径。通过分析复杂网络科学研究面临的挑战和AI算法的深层联系, 探讨了AI在不同领域的复杂网络的应用, 从基础设施网络、生态和生物网络、社交网络等不同类型网络展望了AI驱动下的复杂网络未来研究发展方向。

关键词 复杂网络, 人工智能, 机器学习, 数据科学

引用格式 刘家臻, 王寰东, 丁璟韬, 等. 人工智能时代下的复杂网络[J]. 指挥与控制学报, 2024, 10(3): 255-263

DOI 10.3969/j.issn.2096-0204.2024.03.0255

Complex Network Science in the Era of Artificial Intelligence

LIU Jiazhen¹ WANG Huandong¹ DING Jingtao¹ YAN Huan¹ XU Fengli¹ FAN Changjun^{2,*} LI Yong^{1,*} LIU Zhong^{2,*}

(1. Department of Electronic Engineering, Tsinghua University, Beijing 100084, China;

2. School of Systems Engineering, National University of Defense Technology, Changsha 410073, China)

Abstract Artificial intelligence(AI) has made revolutionary breakthroughs in this century. The new paradigm of complex network research driven by AI methods provides a new path for the description, understanding, prediction and optimization of complex networks. By analyzing the current challenges faced by complex network scientific research and the deep connection of AI algorithms, the application of AI in complex networks in different fields is discussed. Finally, the future research development of complex network driven by AI is prospected from different types of networks such as infrastructure networks, ecological and biological networks, and social networks.

Key words complex network, artificial intelligence, machine learning, data science

Citation LIU J Z, WANG H D, DING J T, et al. Complex network science in the era of artificial intelligence[J]. Journal of Command and Control, 2024, 10(3): 255-263

复杂网络往往用于抽象刻画现实世界中的各种复杂性系统中的网络连接, 将系统中的个体抽象为节点, 而将个体间的关系抽象为边。理解复杂系统从微观无序到宏观有序的转变和演化机制, 正是复杂网络科学研究的核心目标。近10年来, 随着对复杂网络基本规律的理解愈发深入, 如何利用这些规律预测和控制复杂网络的行为成为了新的热点。

复杂网络科学研究的源头大致可追溯到两个重要的数理学科, 分别为图论和统计物理^[1-10]。从20世纪90年代开始, 一些研究发现图论与统计物理的有机结合, 能够更好地对现实世界的复杂系统进行描述和理解, 这催生了复杂网络科学。而其中的代表性研究为小世界模型和无标度网络模型^[11-12]。这些模型蕴含了以下思想, 即动力学驱动不平凡拓扑结构的涌现。这种思想深刻地影响了21世纪第一个10年的网络科学研究, 诞生了许多具有代表性的工作, 其中包括: 复杂网络的重整化群方法^[13-14]、级联动力学

理论^[15]、网络社区检测^[16]、网络中的玻色-爱因斯坦凝聚等^[17]。

然而随着复杂网络科学的蓬勃发展, 一些具有挑战性的关键问题也逐渐浮出水面, 主要分为以下3个方面:

1) 真实复杂网络的动力学机理不清晰。真实拓扑结构和个体上的动力学往往非常复杂并存在强耦合^[15, 18], 传统理论模型动力学交互函数与实际场景存在偏差, 此偏差由于系统的高度非线性被进一步放大。因此, 如何更好地刻画真实世界复杂网络中的动力学机理, 并提高实际预测精度, 成为复杂网络科学中的重要问题。

2) 复杂网络中的高阶拓扑特性难刻画。现阶段大多数关于网络的研究都集中在具有成对连接的网络上。然而, 许多系统中的互动经常发生在一个网络的3个或多个实体之间。为了研究这种情况, 研究人员越来越多地研究网络中的“高阶”结构。高阶网络的研究不可避免地要对单(复)流型进行结合, 这也引出了新的研究视角, 即如何将代数几何和微分几何方法来表征高阶拓扑。

3) 高维复杂网络难优化。高维复杂网络上的优

收稿日期 2023-10-08

录用日期 2024-04-28

*通信作者邮箱 fanchangjun@nudt.edu.cn, liyong07@tsinghua.edu.cn, liuzhong@nudt.edu.cn

化问题是复杂网络最重要的难题之一^[19-20]。传统的运筹学优化方法通过近似计算高维的连续时间的微分方程求解,而通过近似方法降低计算复杂度往往意味着与理论最优解的偏离。

对于上述关键问题,一种潜在的解决思路是通过人工智能(artificial intelligence, AI)方法来解决。这个研究领域在 21 世纪第二个 10 年里取得了革命性进步,实现了一系列里程碑式的研究突破。例如,深度学习神经网络在图像分类竞赛中战胜了传统方法;同时成功地解决了蛋白质结构预测这一长期以来困扰科学家的难题;大型语言模型涌现出上下文学习、指令遵循、逐步推理等小规模模型无法实现的能力;以生成式对抗算法、扩散模型为代表的生成式 AI 算法,在图像、语言、时空数据生成等领域都取得了令人炫目的成果。

与传统数理方法相比, AI 方法有以下优点: 1) 数据驱动方法不依赖于数理模型假设,能够真实地反映数据中所蕴含的复杂信息;2) AI 方法能够全方位,多目标地刻画复杂网络的几何性质,克服了传统理论模型只能刻画有限的拓扑特征的局限性;3) 以强化学习为代表的 AI 算法,仅需要知道复杂网络的基本拓扑特征,无需知道对应的优化方程组的具体信息即可对目标进行优化。在这样的背景下,复杂网络科学与 AI 的结合,预示 AI 驱动的新范式有可能突破领域瓶颈,加速复杂网络科学的发展。

1 AI 与复杂网络内在联系

复杂网络中的挑战问题与 AI 领域所重点解决的问题,具有更为深层的内在联系。如图 1 所示,复杂网路中最为基本的表征问题、推断问题、优化问题,涵盖了理解复杂网络到预测复杂网络、最后到干预复杂网络的整个流程,可以对应至 AI 领域的已经被广泛研究的经典问题,其包括图表征学习问题、时序图建模与预测问题、图强化学习问题。数学形式化描述表明其本质上是同一个问题。因此,本章中将探讨复杂网络中的表征、推断、优化问题,分别与图表征学习、时序图建模与预测、图强化学习问题之间的深层关系,解释 AI 技术在解决对应的复杂网络基本问题上的巨大潜力,并对相关文献整理至表 1。

1.1 复杂网络表征与图表征学习

在复杂网络中,无论是传统基于图论中邻接表的图表征,还是基于流行学习等网络的几何空间嵌入方法的图表征,其所关注的核心问题都是如何在一个固定维度的、可计算的表征空间中,找到网络中每个节点在表征空间中的位置的映射,并且基于



图 1 复杂网络中的基本问题与机器学习中的相关问题的内在对应关系

Fig. 1 The correspondence between basic problems in complex networks and related issues in machine learning

表 1 复杂网络中的基本问题对应的数理方法与机器学习方法的总结

Table 1 Summary of mathematical methods and machine learning methods corresponding to basic problems in complex networks

类别	统计物理 / 图论方法	AI 相关方法
网络表征	随机过程 谱分析	图表征学习 符号回归 高阶拓扑 (几何)深度学习
网络推断	基本函数库 代理网络	自编码器 + 神经网络 神经常微分方程 逆强化学习
网络优化	线性假设 + 平均场	(图)强化学习 生成式模型

该映射能够有效地建模、复现复杂网络特定的性质。例如, PAPADOPOULOS 等提出的经典模型中^[21],就在双曲空间中描述了复杂网络的几何结构,其将通过蒙特卡洛马尔科夫方法估计了复杂网络中的每个节点在双曲空间中的坐标,并以相似性和流行性为复杂网络生长过程中竞争的两股核心力量,解释了复杂网络几何结构形成的内在原因。BENSON 等考虑了复杂网络中模体等高阶结构,提出了基于模体的谱分析图表征技术以及相应的聚类技术,揭露了复杂网络中依赖于高阶作用形成的组织结构^[22]。然而,传统复杂网络表征方法的重要局限,是其依赖于专家知识建立的表征模型,其往往不能全方位描述复杂网络的多维复杂特性。

另一方面, AI 领域研究已经被广泛研究的图表征学习同样旨在获取图节点的低维表征向量。不同的是图表征学习所关注的方面更加多样化,多样的 AI 算法被开发来建模图数据中的节点属性、低阶拓扑结构、高阶拓扑结构等多方面的特征,并用来支撑

节点分类、链接预测等多样的下游任务。从数学形式上,图表征学习可以被定义如下:

$$\begin{aligned} & \min_f L(E, A) \\ & \text{s.t. } \mathbf{e}_i = f(v_i, V, A) \quad \forall v_i \in V \end{aligned} \quad (1)$$

其中, $G=(V, A)$ 为所关注的复杂网络; V 为网络节点的集合; A 为网络中边的集合; $\mathbf{e}_i$ 为表征空间中节点 v_i 所对应的向量, $E=[\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n]$ 为所有节点的表征; f 为特定的图表征机器学习算法; L 是用以优化的目标函数。显而易见的是, 复杂网络表征与图表征学习所重点解决的问题不谋而合。具体而言, f 的获取分别由专家基于经验建立模型与基于神经网络迭代训练实现; 而对于针对优化目标 $L(\cdot)$, 传统复杂网络表征问题中其被替换成了衡量图表征结果是否具有某特定的性质的统计度量^[22]。

因为所关注的问题在本质上具有一致性, 所以, AI 技术在帮助解决复杂网络表征问题上具有巨大潜力, 并且已经取得一定的成功。例如, MUSCOLONI 等运用机器学习方法, 有效解决双曲空间中的网络几何问题^[23]。CHAMI 等进一步提出了利用图神经网络方法将复杂网络节点嵌入双曲空间的方法^[24]。总体而言, 通过合理的设计优化目标函数 L , 现有的保护特定性质或规律的复杂网络表征问题, 都可以转化为图表征学习问题。因此, 未来 AI 算法, 有望实现全方位描述复杂网络的多维复杂特性的表征方法。

1.2 复杂网络推断与时序图建模与预测

正如前文讨论, 真实复杂网络的动力学机理往往是不明晰的。尤其是生态系统中物种相互依存构成的复杂网络、城市多层基础设施相互耦合构成的复杂网络等涉及多样异质结点、多层作用关系的复杂网络中, 往往仅能知道部分的、残缺的网络动力学机理, 而复杂网络中大量的节点演化和交互的动力学机理是未知的, 导致无法对复杂网络总体演化趋势有效的理解和建模。因此, 需要对复杂网络中的机制、机理乃至残缺的拓扑等进行有效的推断, 从而使得基于推断得到的结果, 能够准确复现复杂网络未来的演化趋势。GAO 等提出了一种基于基本函数库的方法, 对复杂网络动力学方程中的节点自演化机制函数 F 和交互演化机制函数 G 进行自动化的推断^[25]。PRASSE 等进一步证明了网络拓扑未知的情况下, 使用估计的代理网络拓扑, 复杂网络节点的演化趋势也能被准确预测^[26]。纵使取得了相当的成功, 现有工作往往依赖于相当数量的假设, 因而导致动力学交互函数与实际场景存在偏差, 此偏差由于系统的高度非线性被进一步放大, 尚且是一个有待解决的开放问题。

在 AI 领域, 时序图建模与预测早已被广泛地研究。其旨在分析和预测图数据随时间的变化, 它涵盖了时间序列数据与图结构之间的关系, 包括节点属性和连接的动态演化。从数学形式上, 图表征学习定义如下:

$$\begin{aligned} & \min_{g, A_t, \hat{X}_t} \left\| \hat{X}_{t+1:t+\tau} - X_{t+1:t+\tau} \right\| + \left\| \hat{A}_{t+1:t+\tau} - A_{t+1:t+\tau} \right\| \\ & \text{s.t. } [\hat{X}_{t+1}, \hat{A}_{t+1}] = g(X_t, A_t) \end{aligned} \quad (2)$$

其中, $X=[x_1, x_2, \dots]$ 为所有节点状态组成的向量; g 为复杂网络状态演化的机理函数; $\|\cdot\|$ 表示衡量节点属性状态与连接一致性的度量。现有的复杂网络推断问题都可以概括在上述时序图建模与预测的框架下。对于文献[25], 推断的目标仅为 g , 且复杂网络拓扑 A_t 在全程不发生改变。类似地, 在文献[26]中 A_t 依然为静态, 但是其是未知的推断目标, 而 g 在这个工作研究的复杂网络推断问题中是已知的。

时序图建模与预测问题从数学形式描述上与已有的复杂网络推断问题具有一致性。而时序图建模与预测的 AI 算法的优势是, 其在解决问题的过程中, 并不依赖于其他假设。因此, 其在给出一个不依赖于过强假设、且能使用与广泛的复杂网络的解决方案上具有巨大的潜力。AI 算法在这方面已经取得了一些进展, 例如 MURPHY 等已成功利用图神经网络预测复杂网络上的传播动力学演化^[27], VLACHAS 等也是用自编码器结合循环神经网络的方法, 有效预测了多个复杂系统的演化动态^[28]。总体而言, 使用深度学习推断复杂网络的动力学极具研究价值, 能够帮助解决复杂网络动力学未知情况下的态势演化的理解与预测的问题。

1.3 复杂网络优化与图强化学习

复杂网络优化问题旨在解决如何干预网络的行为, 但由于复杂网络灾难性的维度, 对其优化与干预的计算面临巨大的复杂度。经典的复杂网络计算方法中往往采用平均场^[29]等近似方法减少计算任务的复杂度。GAO 等提出了通过选取一个最小数量的干预节点, 从而实现复杂网络的控制, 通过降低优化干预问题的搜寻空间, 从而提升运算效率^[30]。近似计算、缩减搜寻空间的方法虽然提升了复杂网络优化的求解时间效率, 但也极大地限制了复杂网络优化的性能。

另一方面, 图强化学习作为一个在 AI 领域已被广泛关注和研究的学术问题, 其同样旨在解决如何在图结构的数据上进行干预, 以实现特定的控制目标, 如干预信息传播或优化网络性能。从数学形式上, 图强化学习可以被定义如下:

$$\begin{aligned} & \min_h U(X_{t+1:t+\tau}, A_{t+1:t+\tau}) \\ \text{s.t. } & \begin{cases} a_t = h(X_t, A_t) \\ [X_{t+1}, A_{t+1}] = g(X_t, A_t, a_t) \end{cases} \end{aligned} \tag{3}$$

其中, a_t 是外部干预的决策; h 是基于当前网络状态进行干预的策略函数; $U(\cdot)$ 为评价干预优化最终效果的度量函数。不同于复杂网络推断问题, 这里的复杂网络机理函数 g 是给定的, 其可以通过单独求解一个时序图建模与预测问题给出。类似地, 现有的复杂网络控制问题, 也可以被上述数学形式描述的问题所囊括。例如文献[30]中, $U(\cdot)$ 为系统状态是否达到目标状态与整个过程的能量成本的综合度量。同时, 不同于图强化学习基于求解高维 Bellman 方程从而获取 h , 文献[30]中通过线性假设等约束结合数学推导直接给出 h 的闭式解。总体而言, 图强化学习与复杂网络优化本质上是同一问题。且在 AI 算法的赋能下, 已有一些方法被提出来成功解决复杂网络的优化控制问题。FAN 等利用图强化学习方法找到复杂网络中的关键节点, 使得通过将其删除后最大程度地降低复杂网络的连接性^[31]。进一步, 现有工作利用深度强化学习, 有效找到了伊辛模型所描述的复杂网络的基态^[32]。已有工作的成功表明图强化学习在解决复杂网络控制方面的有效性, 其能够有效避免现有复杂网络优化工作需要近似、限制策略空间等手段, 以数据驱动的方法实现更好的复杂网络优化, 从而解决现实世界中复杂网络科学相关的实际问题。

2 AI 在复杂网络研究中的应用

复杂网络研究主要包括机制理解、预测模拟与控制优化 3 个方向。机制理解是为了揭示复杂网络宏观性质背后的微观基本规律, 如网络结构、动态过程、生成机制等; 在此基础上构建的模型通过模拟网络的行为, 预测在特定条件下的行为; 进一步为复杂网络的控制与优化提供指导, 而面向真实世界应用的网络控制优化实践又可能揭示新的机制。接下来将讨论以上 3 个阶段中结合 AI 技术的代表性工作, 并将相关文献整理至表 2。

2.1 复杂网络中的机制理解问题

复杂网络研究的一个核心目标是理解复杂系统从微观无序到宏观有序的转变和演化规律, 个体间通过一系列关系连接成具有复杂拓扑结构的网络, 两两个体(或者多于两个个体)间非线性相互作用看似无规律, 但在不断增大的网络节点规模和异质性的共同作用下, 涌现出系统层面上的有序集体行为。现实世界中的复杂网络横跨自然生命系统和人类社会

表 2 复杂网络相关研究中机器学习方法的应用现状汇总
Table 2 Summary of the current application status of machine learning methods in complex network-related research

类别	表征学习	时序预测	强化学习	生成模型
机制推断	符号回归 高阶拓扑	高阶拓扑 时序分析	逆强化 学习	
预测与模拟	自编码器 (几何)深度 学习	神经网络 神经常微分 方程		
控制与优化			(图)强化 学习	扩散 模型

系统, 传统研究遵循的“提出假设-演绎推理”模式在机理不清晰的条件下无法适用; 而数据驱动的 AI 方法具备从数据中自动归纳提炼出复杂网络动力学过程、拓扑结构和演化生长过程机制规律的能力。具体而言, 基于真实数据以无监督或者有监督的方式训练图神经网络, 表征复杂网络的节点状态及相互作用(边), 从而在宏观层面保持同真实数据观测一致的网络性质; 进一步结合符号回归技术, 对真实数据拟合的节点状态和交互函数(即参数化的图神经网络)进行符号模型的学习^[33], 可以提炼出描述节点状态和相互作用演化的符号公式, 兼具高可解释性和拟合精度; 由于符号搜索的状态空间巨大, 因此, 采用深度强化学习技术可以大幅加速这一问题的求解过程^[34]。

在复杂网络动力学推理方面, GAO 等提出了基于基函数组合学习的两阶段动力学自动推理方法^[25], 可以在真实世界的噪声数据及结构缺失条件下实现可靠的动力学推理, 自动推断出复杂网络的节点及交互作用的演化动力学函数; 对于无法用基函数线性组合表示的复杂交互场景, 近期的一项研究使用简约性指导的图神经网络对数据进行拟合, 使用神经网络参数表征复杂交互作用, 并使用符号回归方法提炼出简约的符号化动力学方程, 该方法应用在真实世界的行人移动数据中, 成功地学习到类牛顿力学的行人移动、交互机制^[35]。

除了复杂网络上的动力学过程, 利用观测到的网络动态演化数据, 推断隐藏的网络结构同样是一个由来已久的研究问题^[34-35]。对于复杂网络中的高阶拓扑推断(单纯形、超图等), 对动力学过程存在重大影响, 但难以从理论角度求解。WANG 等设计了基于统计推断方法的框架, 在社会传染和伊辛模型两种形式的动力学下, 该纯数据驱动的方法实现从观测到的时间序列数据(无结构信息)中恢复出包含二体

和三体相互作用的 2-单纯复形网络^[36];SAMTORO 等提出了一个框架来表征多元时间序列中高阶依赖性的时间演化,通过建模高阶共波动模式,该方法可以从基于节点的多元时间序列数据(大脑功能活动、金融市场和流行病数据)中动态重建高阶交互^[37]。

复杂网络的生成机制研究往往采用网络科学的工具方法提出机制模型,来解释现实世界中广泛存在的真实网络,如经典的无标度网络模型和小世界网络模型,但随着更多新型人机交互复杂网络的出现,其背后的生成机制变得愈发复杂,亟需借助 AI 方法从真实数据中挖掘模式,一种可行的方法是采用基于智能体建模的思路,将每一个节点建模为智能体,通过设计恰当的奖励函数驱动智能体之间交互,最终涌现出与数据匹配的真实网络结构,这样一个过程即实现了复杂网络生成机制的学习。YUAN 等提出了一种社交网络形成模型,该模型用一个向量表征每个智能体的特征,并使用博弈论方法来对智能体间社交关系形成的效用进行建模,通过对真实网络数据的拟合,得到的智能体特征向量既可以表征智能体间的异质性,同时可用于解释网络的形成机制^[38]。在网络演化过程状态数据可观测的条件下,可以考虑将智能体的链接建立行为建模为马尔科夫决策过程,使用逆强化学习方法从数据中学习驱动链接形成的奖励函数,并从中提炼出网络形成机制^[39]。

2.2 复杂网络中的预测与模拟问题

复杂网络往往在不同尺度下的预测问题也有所侧重,微观层面关注与个体相互作用关联的链路预测问题,宏观层面关注网络集体行为的预测。基于复杂网络拓扑结构与演化动力学的建模,可以进一步研究网络动态行为的模拟问题。

在个体行为预测这一微观层面,网络科学中的基础预测问题,是通过已有网络结构预测真实存在但尚未观测到的网络链路,传统研究从复杂网络的生长机制出发,提出了一系列基于资源分配、局部路径等结构信息的机制模型,这类方法虽然在观测有限(小样本)、节点信息缺乏的场景相比机器学习方法具备优势,但是在特征丰富的链路预测问题中存在预测精度不足的问题^[40]。因此,有必要设计综合机制模型和 AI 模型的知识与数据协同驱动新方法,兼具知识驱动方法的网络生长规律抓取能力和数据驱动方法的高预测精度。自然系统中的复杂网络拓扑往往具备一定的对称性,因此,可以考虑结合几何深度学习来提升预测的效果。PINEDA 等提出一个基于几何深度学习的图神经网络框架,可以实现生命系统动力学特性的准确估计^[41]。

在网络集体行为预测这一宏观层面,例如:社交

网络的信息传播规模^[42]、疫情传播的爆发^[43]等,由于宏观性质的涌现来源于微观动力学与网络结构的耦合,仅建模拓扑结构影响因素的图神经网络方法也难以有效预测,需要进一步结合动力学过程。因此,图神经网络与神经微分方程的结合成为一种可行的选择,并在近期一项基于微生物组成预测代谢组图的研究中采用^[44]。传统网络科学方法致力于寻找可在不同网络中泛化通用的普适规律,通过在深度学习算法中嵌入这一知识约束,可以实现更加可靠的性质预测。例如最近有研究基于不同动态系统在临界点附近普遍存在的标准形式和标度行为信息,设计了规律指导的临界点早期预警深度学习算法^[45]。对于复杂网络中诸如韧性^[46-47]、稳定性^[48]、可控性^[49]等网络结构与动力学耦合涌现出的宏观性质,一个具有前景的研究方向是,综合利用上述考虑网络拓扑、动态演化与核心机制规律的 AI 方法,以实现准确可靠的预测。

在复杂网络的状态演化模拟问题中,如第 2.1 节所讨论的,使用 AI 方法进行复杂网络模拟具有速度快、无需完整的系统先验参数两大突出优势。

在模拟加速这一方面,AI 方法的优势主要源于具备从数据中学习高维方程的替代模型和基于表征学习降维的能力。前者的代表性工作是分子动力学模拟的加速^[50],利用量子力学模型(物理模型)提供训练数据,深度神经网络(数据驱动方法)对高维势函数进行拟合,在保证精度的同时实现计算速度的指数级别提升。后者主要通过深度学习映射的低维度表征空间实现原始高维系统的模拟,例如 1.2 节介绍的基于自编码器的复杂系统多尺度模拟工作^[28];但是数据驱动的 AI 方法也存在易过拟合、长程模拟泛化效果差的问题,因此,需要考虑结合发现系统本征维度的方法,对神经网络进行相应的约束^[51];LI 等的工作受此启发,提出了一种基于时滞自动编码器框架的本征维度驱动学习方法^[52],该方法能够自适应地识别适当的时间尺度,来同时分离复杂网络演化过程中的慢速和快速变量,实现高精度、可解释性强的长程模拟。

另一方面,数据驱动的 AI 方法无需完整的系统先验参数,发表于 2020 年的一项代表性工作利用图神经网络实现了先验参数未知条件下,复杂图结构物理机制(分子间的相互作用)的模拟仿真^[53]。然而在实际环境中,环境变化或者网络结构自身的变化均会对其演化动力学的参数产生影响,而仅依赖数据的 AI 方法在新参数下会存在泛化能力不足的问题,因此,近期研究热点关注如何能够基于收集自不同参数动力学系统的有限样本快速学习适配模型,主要有模型无关的元学习方法^[54]、解纠缠表征学习方法^[55]等。

2.3 复杂网络中的控制与优化问题

基于对复杂网络节点及相互作用的有效表征、动态过程的精确模拟,设计 AI 方法干预复杂网络的节点状态和拓扑结构,从而实现控制与优化,对于解决现实世界中的复杂应用问题极具实用价值。

复杂网络的控制问题旨在设计反馈策略来引导网络的动态行为朝着某种期望的演化方向发展,理想情况下是通过影响相对较少的微观自由度^[56]。此类控制问题的复杂性体现在网络中节点连接模式的异质性和节点行为的非线性,这些都对传统控制论方法在复杂网络上的可用性提出了挑战。以强化学习为代表的 AI 方法能够克服高维问题求解的维数灾难,基于真实数据训练得到可用性强的模型;然而 AI 方法本身存在的黑盒不可解释性、求解质量的不稳定性,又与控制问题强调的安全稳定存在天然矛盾。因此,基于数据驱动的复杂网络控制方法研究关注对于未知系统从数据中学习系统动力学方程,进而结合传统基于优化的控制方法解决网络控制问题。BAGGIO 等开发了一个数据驱动的复杂网络控制框架,可以在不了解网络动态的情况下以最佳方式控制复杂网络,值得注意的是,其通过随机输入刺激未知网络的方式,来构建训练最优控制策略的有限数据集,并且在存在噪声和非线性动力学的电网、大脑网络数据中验证了方法的可行性^[57]。然而面向超大规模的真实世界复杂网络实际应用问题,例如疫苗分配、社交网络影响力最大化等,如何设计鲁棒高效的 AI 控制方法仍旧极具挑战^[58]。以生成式 AI 为核心的决策基础模型提供了解决这一问题的潜在思路^[59]。

另一方面,现实世界中的很多自然或者人工复杂网络均可以通过改变节点属性或拓扑的方式实现性质的优化,对应的应用方向有药物、蛋白质设计以及城市结构优化(如道路网络、地块使用图等)。例如将城市空间规划问题建模为复杂网络上的顺序决策问题,具备快速生成适应不同情况和需求的候选方案的潜力。

3 AI 驱动下的复杂网络研究发展方向

上述研究表明, AI 技术在复杂网络研究中发挥着至关重要的作用,为深入理解复杂网络提供了强有力的工具。借助 AI 技术能更全面地探究复杂网络的关键性质,揭示网络中微观节点以及整体网络行为变化所蕴含的复杂作用机理和演化规律。实际应用会面临诸如城市基础设施网络、社交网络、生态网络和生物网络等多种不同类型的网络。由于这些网络

有着独特的结构和特性,因此,采用的研究方法也会有所不同。在此背景下, AI 驱动下的复杂网络研究应针对不同类型的网络展开,并重点探讨其在机制理解、模拟预测和优化控制等方面的发展潜力。

在城市基础设施网络研究中,需要利用各种 AI 技术来加深对这些网络内在机制的理解,提高模拟预测的准确性,以及实现网络的优化控制。例如,图神经网络可以揭示网络的空间同质性和各个城市间的复杂依存关系,深入理解网络的微观结构和宏观行为,加深城市依存动力学机制的理解。从模拟预测的方面,运用易感-感染-恢复模型和渗流理论,可以准确描述和预测网络中的动态行为,拓扑结构变化和临界模式特征。然后,从优化控制的视角,通过引入强化学习和其他先进控制策略,可以识别网络的脆弱点,优化网络性能,减轻城市基础设施的级联风险。而且,在分析单一网络和多网络耦合的基础上,这些 AI 技术可以更全面地评估网络的脆弱性、探索网络拓扑的演化过程,并最终实现对城市基础设施网络的高效规划和管理。

生态网络描述了生物群落内各物种之间的相互作用,这种作用涉及捕食、寄生以及合作等多种形式。在机制理解方面,在深化对生态网络交互关系和演化机制的理解时,可以采用卷积神经网络和递归神经网络等深度学习技术,来揭示生物群落中复杂的交互模式和共同演化。在模拟预测方面,联合利用深度学习模型和动力学理论模型,可以模拟和预测生态网络的演变和物种间的互动,揭露哪些物种形成了强连接或弱连接,以及这些连接如何影响网络的稳定性和演化。这不仅有助于预测未来生态网络的状态,还能深入理解物种之间的关联模式。

生物网络则描述了生物系统内包括基因、蛋白质、细胞和分子在内的各类实体,在机制理解方面,卷积神经网络、图神经网络和其他深度学习技术的进一步发展和应用,将更为精确和深入地揭示生物网络结构和功能之间的复杂关系。例如,表征学习可通过捕获和解释这些关系,将生物实体或网络结构映射到低维向量,来编码其中蕴含的丰富信息。在模拟预测方面,通过融合深度学习和动力学模型,可以预测未来生物网络的结构以及未知的生物实体功能,还有助于发现和理解网络中潜在的生物学规律和模式。在优化控制方面,强化学习为生物医学领域带来革命性的改变,推动更为有效和个性化的治疗方法和药物设计的发展。

与其他类型网络不同,社交网络不受地理位置的约束,构建了一种跨越地域界限的虚拟网络。首先,在理解社交网络机制方面,采用深度学习方法来获取网络中的多维信息和表征,揭示其背后的社

交机制和动力学规律。其次,在模拟预测方面,可以利用流行学习和其他先进的机器学习方法,对社交网络中的非线性、高动态性和竞争性特征进行精确建模和预测。通过对关键节点的优化控制来改善网络的结构和性能,减少网络中的脆弱性和风险。随着 AI 技术的不断发展,通过创新知识和 AI 协同驱动的研究方法,将已有的知识嵌入到 AI 模型中,以提升模型的可靠性和完备性,这将有助于促进复杂网络多个方面的研究。

References

- [1] ERDOS P, RENYI A. On the evolution of random graphs[J]. Transactions of the American Mathematical Society, 1984, 286: 257.
- [2] COHEN R, BEN-AVRAHAM D, HAVLIN S. Percolation critical exponents in scale-free networks[J]. Physical Review E, 2002, 66(3): 036113.
- [3] COHEN R, EREZ K, BEN-AVRAHAM D, et al. Breakdown of the internet under intentional attack[J]. Physical Review Letters, 2001, 86(16): 3682.
- [4] COHEN R, HAVLIN S, BEN-AVRAHAM D. Efficient immunization strategies for computer networks and populations [J]. Physical Review Letters, 2003, 91(24): 247901.
- [5] SCHWARTZ N, COHEN R, BEN-AVRAHAM D, et al. Percolation in directed scale-free networks[J]. Physical Review E, 2002, 66(1): 015104.
- [6] ISING E. Beitrag zur theorie des ferromagnetismus[J]. Zeitschrift Für Physik, 1925, 31(1): 253-258.
- [7] ONSAGER L. Crystal statistics. I. a two-dimensional model with an order-disorder transition[J]. Physical Review, 1944, 65(3-4): 117.
- [8] PRIGOGINE I, LEFEVER R. Symmetry breaking instabilities in dissipative systems II[J]. The Journal of Chemical Physics, 1968, 48(4): 1695-700.
- [9] HAKEN H. Cooperative phenomena in systems far from thermal equilibrium and in nonphysical systems[J]. Reviews of Modern Physics, 1975, 47(1): 67.
- [10] PARISI G. Infinite number of order parameters for spin-glasses[J]. Physical Review Letters, 1979, 43(23): 1754.
- [11] BARABASI A L, ALBERT R. Emergence of scaling in random networks[J]. Science, 1999, 286(5439): 509-512.
- [12] WATTS D J, STROGATZ S H. Collective dynamics of 'small-world' networks[J]. Nature, 1998, 393(6684): 440-442.
- [13] SONG C, HAVLIN S, MAKSE H A. Self-similarity of complex networks[J]. Nature, 2005, 433(7024): 392-395.
- [14] SONG C, HAVLIN S, MAKSE H A. Origins of fractality in the growth of complex networks[J]. Nature Physics, 2006, 2(4): 275-281.
- [15] MOTTER A E. Cascade control and defense in complex networks[J]. Physical Review Letters, 2004, 93(9): 098701.
- [16] GIRVAN M, NEWMAN M E. Community structure in social and biological networks[J]. Proceedings of the National Academy of Sciences, 2002, 99(12): 7821-7826.
- [17] BIANCONI G, BARABASI A L. Bose-Einstein condensation in complex networks[J]. Physical Review Letters, 2001, 86(24): 5632.
- [18] GAO T T, YAN G. Autonomous inference of complex network dynamics from incomplete and noisy data[J]. Nature Computational Science, 2022, 2(3): 160-168.
- [19] 王飞跃. 复杂性与智能化: 从 Church-Turing Thesis 到 AlphaGo Thesis 及其展望(1) [J]. 指挥与控制学报, 2016, 2(1): 1-4.
WANG F Y. Complexity and intelligence: from Church-Turing Thesis to AlphaGo Thesis and its prospects(1)[J]. Journal of Command and Control, 2016, 2(1): 1-4. (in Chinese)
- [20] 王飞跃. 复杂性与智能化: 从 Church-Turing Thesis 到 AlphaGo Thesis 及其展望(2) [J]. 指挥与控制学报, 2016, 2(2): 89-92.
WANG F Y. Complexity and intelligence: from Church-Turing Thesis to AlphaGo Thesis and its prospects(2)[J]. Journal of Command and Control, 2016, 2(2): 89-92. (in Chinese)
- [21] PAPADOPOULOS F, KITSACK M, SERRANO M Á, et al. Popularity versus similarity in growing networks[J]. Nature, 2012, 489(7417): 537-540.
- [22] BENSON A R, GLEICH D F, LESKOVEC J. Higher-order organization of complex networks[J]. Science, 2016, 353(6295): 163-166.
- [23] MUSCOLONI A, THOMAS J M, CIUCCI S, et al. Machine

- learning meets complex networks via coalescent embedding in the hyperbolic space[J]. *Nature Communications*, 2017, 8(1): 1615.
- [24] CHAMI I, YING Z, RE C, et al. Hyperbolic graph convolutional neural networks[R]. Vancouver: *Advances in Neural Information Processing Systems*, 2019.
- [25] GAO T T, YAN G. Autonomous inference of complex network dynamics from incomplete and noisy data[J]. *Nature Computational Science*, 2022, 2(3): 160–168.
- [26] PRASSE B, VAN MIEGHEM P. Predicting network dynamics without requiring the knowledge of the interaction graph[J]. *Proceedings of the National Academy of Sciences*, 2022, 119(44): e2205517119.
- [27] MURPHY C, LAURENCE E, ALLARD A. Deep learning of contagion dynamics on complex networks[J]. *Nature Communications*, 2021, 12(1): 4720.
- [28] VLACHAS P R, ARAMPATZIS G, UHLER C, et al. Multi-scale simulations of complex systems by learning their effective dynamics[J]. *Nature Machine Intelligence*, 2022, 4(4): 359–366.
- [29] VESPIGNANI A. Modelling dynamical processes in complex socio-technical systems[J]. *Nature Physics*, 2012, 8(1): 32–39.
- [30] GAO J, LIU Y Y, D'SOUZA R M, et al. Target control of complex networks[J]. *Nature Communications*, 2014, 5(1): 5415.
- [31] FAN C, ZENG L, SUN Y, et al. Finding key players in complex networks through deep reinforcement learning[J]. *Nature Machine Intelligence*, 2020, 2(6): 317–324.
- [32] FAN C, SHEN M, NUSSINOV Z, et al. Searching for spin glass ground states through deep reinforcement learning[J]. *Nature Communications*, 2023, 14(1): 725.
- [33] CRANMER M, SANCHEZ G A, BATTAGLIA P, et al. Discovering symbolic models from deep learning with inductive biases[R]. Vancouver: *Advances in Neural Information Processing Systems*, 2020.
- [34] SUN F, LIU Y, WANG J X, et al. Symbolic physics learner: Discovering governing equations via Monte Carlo tree search [EB/OL]. (2022-05-26)[2024-05-31]. <https://arxiv.org/abs/2205.13134>.
- [35] SHI H, DING J, CAO Y, et al. Learning symbolic models for graph-structured physical mechanism[R]. Kigali: In the *Eleventh International Conference on Learning Representations*, 2023.
- [36] WANG H, MA C, CHEN H S, et al. Full reconstruction of simplicial complexes from binary contagion and Ising data [J]. *Nature Communications*, 2022, 13(1): 3043.
- [37] SAMTORO A, BATTISTON F, PETRI G, et al. Higher-order organization of multivariate time series[J]. *Nature Physics*, 2023, 19(2): 221–229.
- [38] YUAN Y, ALABDULKAREEM A, PENTLAND A S. An interpretable approach for social network formation among heterogeneous agents[J]. *Nature Communications*, 2018, 9(1): 4704.
- [39] TRIVEDI R, YANG J, ZHA H. Graphopt: learning optimization models of graph formation[R]. Addis Ababa: *International Conference on Machine Learning*, 2020.
- [40] ZHOU T. Progresses and challenges in link prediction[J]. *I-science*, 2021, 24(11): 103217.
- [41] PINEDA J, MIDTVEDT B, BACHIMANCHI H, et al. Geometric deep learning reveals the spatiotemporal features of microscopic motion[J]. *Nature Machine Intelligence*, 2023, 5(1): 71–82.
- [42] MARTIN T, HOFMAN J M, SHARMA A, et al. Exploring limits to prediction in complex social systems[R]. Montreal: *Proceedings of the 25th International Conference on World Wide Web*, 2016.
- [43] SCARPINO SV, PETRI G. On the predictability of infectious disease outbreaks[J]. *Nature Communications*, 2019, 10(1): 898.
- [44] WANG T, WANG X W, LEE-SARWAR, et al. . Predicting metabolomic profiles from microbial composition through neural ordinary differential equations[J]. *Nature Machine Intelligence*, 2023, 5(3): 284–293.
- [45] BURY T M, SUJITH R I, PAVITHRAN I, et al. Deep learning for early warning signals of tipping points[J]. *Proceedings of the National Academy of Sciences*, 2021, 118(39): e2106140118.
- [46] 崔琼, 李建华, 冉湔丹, 等. 基于任务能力的指挥信息系统超网络弹性度量 [J]. *指挥与控制学报*, 2017, 3(2): 137–143.

- CUI Q, LI J H, RAN H D, et al. Super network elasticity measurement of command information system based on mission capabilities[J]. Journal of Command and Control, 2017, 3(2): 137–143. (in Chinese)
- [47] GAO J, BARZEL B, BARABASI A L. Universal resilience patterns in complex networks[J]. Nature, 2016, 530(7590): 307–312.
- [48] MENCK P J, HEITZIG J, MARWAN N, et al. How basin stability complements the linear–stability paradigm[J]. Nature Physics, 2013, 9(2): 89–92.
- [49] LIU Y Y, SLOTINE J J, BARABASI A L. Controllability of complex networks[J]. Nature, 2011, 473(7346): 167–173.
- [50] ZHANG L, HAN J, WANG H, et al. Deep potential molecular dynamics: a scalable model with the accuracy of quantum mechanics[J]. Physical Review Letters, 2018, 120(14): 143001.
- [51] FLORYAN D, GRAHAM M D. Data–driven discovery of intrinsic dynamics[J]. Nature Machine Intelligence, 2022, 4(12): 1113–1120.
- [52] LI R, WANG H, LI Y. Learning slow and fast system dynamics via automatic separation of time scales[R]. New York: Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2023.
- [53] SANCHEZ–GONZALEZ A, GODWIN J, PFAFF T, et al. Learning to simulate complex physics with graph networks[R]. Vienna: International Conference on Machine Learning, 2020.
- [54] LI Q, WANG T, ROYCHOWDHURY V, et al. Metalearning generalizable dynamics from trajectories[J]. Physical Review Letters, 2023, 131(6): 067301.
- [55] HUANG Z, SUN Y, WANG W. Generalizing graph ODE for learning complex system dynamics across environments[R]. New York: Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2023: 798–809.
- [56] D’SOUZA R M, DI BERNARDO M, LIU Y Y. Controlling complex networks with complex nodes[J]. Nature Reviews Physics, 2023, 5(4): 250–262.
- [57] BAGGIO G, BASSETT DS, PASQUALETTI F. Data–driven control of complex networks[J]. Nature Communications, 2021, 12(1): 1429.
- [58] MEIROM E, MARON H, MANNOR S, et al. Controlling graph dynamics with reinforcement learning and graph neural networks[R]. Vienna: International Conference on Machine Learning, 2021.
- [59] YANG S, NACHUM O, DU Y, et al. Foundation models for decision making: problems, methods, and opportunities[EB/OL]. (2023–03–07)[2024–05–31]. <https://arxiv.org/abs/2303.04129>.