

任务级兵棋智能决策技术框架设计与关键问题分析

张驭龙^{1,2} 范长俊¹ 冯旻赫¹ 张龙飞¹ 刘忠^{1,*}

(1. 国防科技大学系统工程学院, 长沙 410073; 2. 解放军31002部队, 北京 100000)

摘要 在梳理总结当前兵棋智能决策方法研究现状的基础上, 明确指出了开展任务级兵棋智能决策研究的8项难点, 从博弈活动中智能体定位、信息流转与知识流转等问题出发, 设计给出了任务级兵棋智能博弈框架、智能策略生成优化框架以及多智能体策略协同演进框架, 进而分析了高维度下长时序的态势信息数据综合、异步策略分布式学习优化、基于语义模板的任务指令生成、多智能体训练营博弈调度等4项关键问题, 并给出了基本解决方案, 点明了开展任务级兵棋智能决策研究的技术要点与基本路线, 为后续任务级兵棋智能体设计提供了有益参考。

关键词 兵棋, 博弈, 决策, 智能, 强化学习

引用格式 张驭龙, 范长俊, 冯旻赫, 等. 任务级兵棋智能决策技术框架设计与关键问题分析 [J]. 指挥与控制学报, 2024, 10(1): 19–25

DOI 10.3969/j.issn.2096-0204.2024.01.0019

Technical Framework Design and Key Issues Analysis in Task-level Wargame Intelligent Decision Making

ZHANG Yulong^{1,2} FAN Changjun¹ FENG Yanghe¹ ZHANG Longfei¹ LIU Zhong^{1,*}

(1. School of Systems Engineering, National University of Defense Technology, Changsha 410073, China; 2. Unit 31002 of PLA, Beijing 100000, China)

Abstract The research status of current intelligent decision-making method in wargame is sorted out and summarized, eight difficulties for carrying out the task-level intelligent decision-making method in wargame are specified. The intelligent gaming framework, the intelligent strategy generating and optimizing framework, and the multi-agent intelligent strategy co-evolutionary framework of task-level wargame are designed based on agent positioning, information flow and knowledge transfer and other issues. Such four key issues as situation information data integration, asynchronous strategy distributed learning optimization, task order generation based on semantic template, multi-agent training camp gaming schedule in high-dimension long time sequence are analyzed. The basic resolution scheme is provided, the technical points and basic lines for carrying out the intelligent decision-making research of task-level wargame are pointed out, which provides the beneficial reference for the agent design of the subsequent task-level wargame.

Key words wargame, gaming, decision-making, intelligent, reinforcement learning

Citation ZHANG Y L, FAN C J, FENG Y H, et al. Technical framework design and key issues analysis in task-level wargame intelligent decision making[J]. Journal of Command and Control, 2024, 10(1): 19–25

以 Deepmind 团队成功研发 AlphaGo 击败人类顶级围棋选手为标志, 国际互联网科技巨头^[1-3]纷纷将研究目标对准了难度更高的竞技类游戏。其中, AlphaStar^[1]首次在大中型即时战略游戏“星际争霸 II”达到“宗师”水平, 超过 99.8% 的人类玩家, 将基于强化学习的智能博弈研究带入了全新阶段。竞技游戏智能博弈高速发展的同时, 兵棋推演智能博弈技术也蓬勃发展^[4-14]。

以近年成功举办的全国兵棋推演大赛智能专项赛及“战颅”等系统为标志, 国内针对兵棋博弈技术也走出了六角格“推演棋盘”, 走入了全景式“虚拟战场”。与之相应地, 智能决策技术的研究重点, 正在

从传统战术级兵棋的行动规划向战役战术级兵棋的任务规划拓展; 兵棋智能算法承担的角色正在从“虚拟战斗员”向“虚拟指挥员”转变; 兵棋博弈策略的生成路径正在从“人机独立形成”向“人机融合优化”迈进。因此, 开展任务级兵棋智能决策问题研究, 亟需在充分掌握当下智能博弈技术特性的基础上, 明确任务级兵棋智能博弈问题的难点, 据此提出“人在环中”的任务级兵棋智能决策框架, 并针对其中关键问题给出解决的方法思路。

1 任务级兵棋智能决策难点分析

开展任务级兵棋智能决策研究, 必须在深入掌握竞技游戏类决策问题难点的基础上, 基于当前技术能力现状, 准确定位任务级兵棋博弈问题研究难点。综合当下国内外竞技游戏与兵棋智能博弈实践,

可将任务级兵棋智能决策难点总结为 8 点:

1) 不完全信息博弈过程更强调谋略对抗。与棋类博弈不同,兵棋与星际争霸等即时战略游戏均存在“战争迷雾”,玩家只能观测到己方活动单元附近敌方单元信息,且兵棋对抗更强调对现有兵力的调度运用,更突出如“隐真示假”“欲擒故纵”等具有战争艺术思维的谋略对抗。

2) 状态空间更突出数据分析。从状态空间大小出发,星际争霸($10^{5\,000}$)与兵棋($10^{2\,000}$)在规模上均远超围棋(10^{172}),因而训练难度极大。与此同时,二者态势数据还存在结构差异,星际争霸状态空间主要以图像、实体属性、统计量等 3 类信息形式描述,然而多数任务级兵棋仿真引擎推送的数据更接近实战态势数据,其态势主要以实体属性、统计量等数据类信息来表示,缺少了形象化的空间结构信息,因而对智能体态势分析提出更高要求。

3) 动作空间更注重结构化控制。与棋类游戏相比,星际争霸需要确定动作指令的主谓宾语内容。任务级兵棋的动作空间在维度上虽与星际争霸差异不大,但在任务指令结构上增加了条令设置等内容,且存在武器挂载等任务预规划问题,使得动作空间结构复杂性进一步提高。

4) 博弈实体规模更大。与星际争霸博弈具有实体数额上限(200)不同,基于任务级兵棋的一次中等规模的战役背景下的对抗想定中,实体数目一般在数千以上,极大地增加了实体间的协同控制难度,因而对智能体算法提出了更高的要求。

5) 决策持续时间更长。星际争霸一次对抗持续时间一般在 30 min~1 h 以上,玩家需要作出数以千计的决策。而任务级兵棋一次推演仿真时长一般在 1.5~3 h 左右,相较于星际争霸,任务级兵棋玩家需要作出数倍决策才能最终确定胜负,因而训练数据更加稀疏。

6) 多方策略博弈更多元。与双人对弈的棋类游戏相比,星际争霸可进行多方对抗,而任务级兵棋是进一步支持敌我友民多方力量对抗合作的仿真,在此基础上的策略博弈更为复杂。

7) 循环策略博弈更多样。与星际争霸相同,任务级兵棋的策略集中不存在特定最优策略,其中,不同策略在训练过程中相互克制,最终形成一个闭环的策略压制关系。因此,二者在训练过程中,无法简单地使用自博弈方法。同时,由于任务级兵棋中想定场景更为多样、实体种类更为多样、优化问题更为多样,造成任务级兵棋的循环策略博弈的闭环分析难度更大。

8) 人类专家数据更稀缺。星际争霸属于国际范围内流行的竞技博弈游戏,服务端有数十万盘专业

玩家数据可供智能体进行模仿学习。而任务级兵棋专业性强、普及度低,不具备使用大量人类专家数据对智能体进行训练的条件,因而更强调算法对现有专业知识抽取与运用。

从以上 8 个难点可以看出,面向棋类与竞技游戏类的智能博弈方法并不能完全满足任务级兵棋智能决策的需要,应开展针对性研究,提出面向任务级兵棋的智能决策框架。

2 任务级兵棋智能决策框架设计

开展任务级兵棋智能决策研究,应找到智能体在任务级兵棋博弈中的定位,找准智能体与兵棋仿真平台、人类专家间的关系,找出明确信息流转路径与知识流转路径。基于以上考虑,本章给出了任务级兵棋智能博弈框架、智能策略生成优化框架,以及多智能体策略协同演进框架。

2.1 任务级兵棋智能博弈框架

任务级兵棋智能博弈框架如图 1 所示,主要以“墨子”联合作战推演系统为例说明智能体完整博弈决策过程,主要包含以下 3 个步骤:

Step 1 态势信息分析。指将兵棋仿真引擎推送的整体态势数据按 3 类信息整编处理。

1) 地图信息:即主屏幕中的态势地图,主要描述了当前态势下敌我双方各实体的空间位置;2) 实体信息:主要包括当前实体的航速航向等运动信息、经纬高等位置信息、作战任务条令与电磁管控条令信息、武器挂载与油耗余量信息等,主要描述当前各实体的状态特征;3) 全局统计信息:主要包括作战时间进程、敌我双方各类实体损耗数、各类弹药消耗数、评分值等,主要描述了当前战场全局的整体进度与敌我双方的力量对比。

以上 3 类信息进行综合处理后,直接作为智能体对当前状态的观测值,以支撑智能体决策。

Step 2 任务指令生成。智能体依据当前状态的观测值,依据自身策略生成所属实体需要执行的任务要素,主要包括:1) 任务类型;2) 任务地域;3) 任务执行主体;4) 任务目标对象;5) 任务条令;6) 任务决策时延,共计 6 类信息要素。最终转化为任务指令并发送至兵棋仿真引擎。

Step 3 环境实时推演。兵棋仿真引擎接收智能体的任务指令后,进行实时推演,形成新的态势供智能体分析,并进入下一轮决策循环。

基于以上 3 个步骤进行循环迭代,实现智能体在任务级兵棋中的决策,从而产生大量仿真数据。在此数据基础上,智能体不断更新自身神经网络参数,




图1 任务级兵棋智能博弈框架

Fig. 1 The framework of intelligent gaming in task-level wargame

实现策略的不断优化。

2.2 任务级兵棋智能策略生成优化框架

任务级兵棋智能策略生成优化框架如图2所示,其中,绿色代表网络输入,蓝色代表网络模型,红色代表网络输出,黄色代表执行动作。该框架主体参照A3C算法框架设计,由观测信息处理、价值网络与行动网络3个模块组成。

1) 观测信息处理模块,主要作用是压缩当前时刻地图、实体以及全局统计3类信息,并最终得出综合多帧态势的时序化状态信息。实现方法是针对地图类、实体类、全局统计类信息,分别使用残差网络(ResNet)、Transformer模型^[19]、全连接网络(fully connected network, FC Net)进行编码,经离散连接(scatter connection)与拼接操作后形成单帧态势信息,再由长短期记忆网络(long short term memory, LSTM)^[16-17]处理转化为时段内集成隐层态势编码(integrated hidden layer situational encoder)供值网络评估与行动网络决策使用。

2) 值网络模块,主要作用是评估当前状态价值,以供行动网络学习优化。其结构相对简单,主要依据集成隐层态势编码与基础比对特征值,经全连接网络计算得出状态价值。需要指出,此处基础比对特征值是指当前状态下一个或多个统计值向量与历史数据均值向量之差,如当前智能体拥有的主力装备数目与历史赛事中均值的差值。

3) 行动网络模块,主要作用是生成任务指令。该模块采用了多头输出结构,不同任务要素参考了不同信息,并使用了不同神经网络。其中,确定任务的类型主要使用了具有残差连接的全连接网络与门控

线性单元(gated linear unit, GLU)^[18];确定任务的决策时延与条令主要使用了结构简单的全连接网络;确定任务的执行主体使用了可解决组合优化问题的指针网络(pointer network)^[19];确定任务的目标使用了适于找寻关注点的自注意力机制(self-attention);确定任务的地域则使用了适于图像处理的反卷积残差网络(deconv ResNet)。

以上框架,只适用于训练单一策略的智能体,无法应对循环策略的学习。因而,还需进一步引入相对完善的多智能体训练机制,使其不仅能快速收敛于一个相对完善的策略,更能“记住”每个特定策略的应对方法,从而破解智能体循环策略训练难题。

2.3 任务级兵棋多智能体策略协同演进框架

任务级兵棋多智能体策略协同演进框架如图3所示,完整地展现了任务级兵棋智能决策中知识流动过程,主要分为5个阶段:

1) 专家知识规则化。人类专家依据特定场景,结合自身经验知识,设计多个风格不同且水平较高的规则智能体,将专家知识转化为可复用的程序,用于后续智能学习。

2) 规则知识参数化。针对不同风格的规则智能体设置初始特定开拓者(initializing specific exploiter, ISE)智能体进行有监督学习,将规则智能体中的知识提炼到特定网络之中,固化为网络参数^[20-22]。与此同时,专家还针对相关策略进行标注,依托规则引导的策略搜索(rule guided policy search, RGPS)方法引导不同决策风格的特定开拓者快速收敛。

3) 网络参数初始化。用本次博弈训练的主智




图2 任务级兵棋智能策略生成优化框架

Fig. 2 The optimization framework of intelligent strategy generating in task-level wargame




图3 任务级兵棋多智能体策略协同演进框架

Fig. 3 The framework of multi-agent strategy evolution in task-level wargame

能体与不同决策网络的特定开拓者智能体展开对抗,使其训练伊始即可应对多种不同风格策略,并通过博弈不断提升稳定^[23-25],形成性能相对较高的

初始化参数。

4) 初始参数最优化。在初始化参数版本主智能体的基础上进行自博弈,基于训练营机制(training

league)生成针对特定策略的特定开拓者、博弈水平相对较高策略的演化开拓者、博弈水平相对较低策略的自适应演化开拓者对主智能体进行训练,并使用训练营开拓者不断查找训练营中的策略漏洞。从而保证训练营策略集不断丰富,促进主智能体策略的持续演进,实现博弈知识的自我发现,达到并超越人类专家的水平,并生成最终参数版本的主智能体。

5) 参数知识抽象化。使用最终参数版本的主智能体再次与人类专家进行博弈,基于智能算法优异表现展开定性分析,辅助人类专家修正自身策略盲点,启发人类专家进一步改进完善自身策略,实现将智能体知识转化为人类的抽象思维。

任务级兵棋多智能体策略协同演进框架揭示了智能决策研究的根本目标,即打通人类专家与智能算法间的知识循环,最终提升人类专家对相关问题的认知理解能力。

3 任务级兵棋智能决策关键问题与基本方法

在基本掌握任务级兵棋智能决策框架的基础上,可进一步总结梳理出以下 4 点关键技术问题与基本解决方案。

3.1 高维度长时段态势信息数据综合问题

高维度指任务级兵棋态势实体多、状态空间维度大的特点,要求智能体须具备信息降维分析能力;长时段指任务级兵棋决策需要时间跨度大,要求智能体须具备长时段的态势信息分析能力。文献[1, 3, 8] 中相关成果,可以得出基于自编码器架构的解决方案,如图 2 中观测信息处理模块所示。针对高维信息压缩问题,首先利用 Transformer 模型自编码生成各实体信息编码,利用离散连接(scatter connection)

将实体编码集成到地图数据后,经残差网络得出集成地图编码(integrated map encoder),再将其与全连接网络得出的全局统计信息编码(statistics encoder)进行拼接,形成压缩后的低维单帧态势信息;针对长时段态势信息压缩问题,直接使用面向非定长时序问题的 LSTM 循环处理单帧态势信息,得出能够综合反映一段时间内态势信息的集成隐层态势编码,完成高维度长时段态势信息数据综合处理。

3.2 异步策略分布式学习优化问题

要高效地开展任务级兵棋智能体训练,必须使用分布式强化学习架构,其核心是在于解决好基于回放寄存器(replay memory)的异步策略(off-policy)更新问题与定长采样下 LSTM 的初始化问题。其中,异步策略的更新问题可以直接使用 V-trace 方法解决,保证目标策略与源策略重要性比值始终大于或等于均值,促进智能体收敛。而定长采样下 LSTM 的初始化问题也可以直接使用文献[11]中的循环状态存储(stored state)与参数预热(burn-in)方法,确保在可接受的 Q 值偏差(Q -value discrepancy)范围内实现对分布式定长采样数据的学习。

3.3 基于语义模板的任务指令生成问题

实现任务级兵棋智能决策,必须实现基于特定语义模板的任务指令控制,基本方法可参考文献[13]中的 Sequential DQN 方法为基础进行分层处理。

如图 4 所示,Sequential DQN 将决策过程分为上下两层,上层 MDP 将整条任务指令视作一个动作,反馈为环境反馈 r_t ,下层 MDP 将任务指令中每个要素决策视作一个子动作,之间反馈设为 0。令上层整条任务指令的 Q 值与下层最后一项值相等:




图 4 Sequential DQN 中的马尔可夫决策过程结构示意图

Fig. 4 The structure schematic diagram of Markov decision-making process in Sequential DQN

$$Q^U(s_i, a_i) = Q^L(u_{N-1}^s, a_i^N) \quad (1)$$

通过自举法不断修正下层子动作的 Q 值, 从而实现特定态势下对任务条令各信息要素值的评估, 指导各任务信息要素的选择, 结合图 2 中行动网络模块, 即可生成结构化的任务指令。

3.4 多智能体训练营博弈调度问题

任务级兵棋中存在大量循环策略, 易造成单智能体策略在多个循环策略之间不断变化无法提升。参考文献[1, 3, 14]有关成果, 可使用多智能体训练营(training league)的方法。如图 3 所示, 多智能体训练营的核心方法是维护一个基于胜率的支付矩阵, 所有智能体对阵主智能体达到一定胜率后, 即将其策略参数存入训练营中。完成网络初始参数最优化阶段后, 训练营参照胜率支付矩阵, 一方面按要求选拔特定策略开拓器、演化开拓器(胜率 50%~70%以内)、自适应演化开拓器(胜率 20%~50%以内)与主智能体对战; 另一方面选拔训练营开拓器与训练营全部智能体进行对战, 不断更新主智能体与开拓器策略, 逐步构建丰富完备的训练营策略集, 并最终实现主智能体策略的持续演进。

4 结论

本文在充分梳理当下兵棋智能决策研究现状的基础上^[26-29], 分析了开展任务级兵棋智能博弈研究的 8 项难点, 进而提出了任务级兵棋智能博弈框架、智能策略生成优化框架, 以及多智能体策略协同演进框架, 指出了当下应重点关注的高维度长时段态势信息数据综合、异步策略分布式学习优化、基于语义模板的任务指令生成、多智能体训练营博弈调度等 4 项关键技术问题, 并给出了基本解决方案, 点明了开展任务级兵棋智能决策研究的技术要点与基本路线, 为后续任务级兵棋智能体设计提供了有益参考。

References

- [1] VINYALS O, BABUSCHKIN I, CZARNECKI W M, et al. Grandmaster level in starcraft II using multi-agent reinforcement learning[J]. Nature, 2019, 575(7782): 350-354.
- [2] BERNER C, BROCKMAN G, CHAN B, et al. Dota 2 with large scale deep reinforcement learning[EB/OL]. (2019-12-13)[2021-08-04]. <https://arxiv.org/pdf/1912.06680.pdf>.
- [3] HAN L, XIONG J, SUN P, et al. TStarBot-X: an open-sourced and comprehensive study for efficient league training in StarCraft II full game[EB/OL]. (2021-04-30)[2021-08-04]. <https://arxiv.org/abs/2011.13729.pdf>.
- [4] 陈希亮, 张永亮. 基于深度强化学习的陆军分队战术决策问题研究 [J]. 军事运筹与系统工程, 2017, 31(3): 20-27. CHEN X L, ZHANG Y L. Study on tactical decision-making problem of army detachment based on deep reinforcement learning[J]. Military Operations Research and Systems Engineering, 2017, 31(3): 20-27. (in Chinese)
- [5] 曹雷. 基于深度强化学习的智能博弈对抗关键技术 [J]. 指挥信息系统与技术, 2019, 10(5): 1-7. CAO L. Key technologies of intelligent game confrontation based on deep reinforcement learning[J]. Command information system and technology, 2019, 10(5): 1-7. (in Chinese)
- [6] 崔文华, 李东, 唐宇波, 等. 基于深度强化学习的兵棋推演决策方法框架 [J]. 国防科技, 2020, 41(2): 113-121. CUI W H, LI D, TANG Y B, et al. Deep reinforcement learning based decision-making method framework of military decision-making[J]. National Defense Science and Technology, 2020, 41(2): 113-121. (in Chinese)
- [7] MNH V, BADIA A P, MIRZA M, et al. Asynchronous methods for deep reinforcement learning[C]// International Conference on Machine Learning. PMLR, 2016: 1928-1937.
- [8] HAUSKNECHT M, STONE P. Deep recurrent Q-learning for partially observable MDPs[C]// 2015 AAAI Fall Symposium Series, 2015: 1523-1536.
- [9] ESPEHOLT L, SOYER H, MUNOS R, et al. IMPALA: scalable distributed Deep-RL with importance weighted actor-learner architectures[C]// International Conference on Machine Learning. PMLR, 2018: 1407-1416.
- [10] ESPEHOLT L, MARINIER R, STANCZYK P, et al. SEED RL: scalable and efficient Deep-RL with accelerated central inference[EB/OL]. (2019-10-15)[2021-08-04]. <https://arxiv.org/abs/1910.06591>.
- [11] KAPITUROWSKI S, OSTROVSKI G, QUAN J, et al. Recurrent experience replay in distributed reinforcement learning [C]// International Conference on Learning Representations, 2018: 1257-1269.
- [12] HORGAN D, QUAN J, BUDDEN D, et al. Distributed prioritized experience replay[C]// International Conference on Learning Representations, 2018: 1539-1551.
- [13] METZ L, IBARZ J, JAITLY N, et al. Discrete sequential

- prediction of continuous actions for deep RL[C]// International Conference on Learning Representations, 2018: 697–709.
- [14] JADERBERG M, CZARNECKI W M, DUNNING I, et al. Human-level performance in 3D multiplayer games with population-based reinforcement learning[J]. Science, 2019, 364(6443): 859–865.
- [15] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// Conference on Neural Information Processing Systems, 2017: 30–37.
- [16] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735–1780.
- [17] MIKOLOV T, KARAFIAT M, BURGET L, et al. Recurrent neural network based language model[C]// Eleventh Annual Conference of the International Speech Communication Association, 2010: 1045–1048.
- [18] DAUPHIN Y N, FAN A, AULI M, et al. Language modeling with gated convolutional networks[C]// International Conference on Machine Learning. PMLR, 2017: 933–941.
- [19] VINYALS O, FORTUNATO M, JAITLY N. Pointer networks [C]// Conference on Neural Information Processing Systems, 2015: 28–39.
- [20] RUSU A A, COLMENAREJO S G, GULCEHRE C, et al. Policy distillation[C]// International Conference on Learning Representations, 2016: 953–960.
- [21] OH J, GUO Y, SINGH S, et al. Self-imitation learning[C]// International Conference on Machine Learning. PMLR, 2018: 3878–3887.
- [22] LEVINE S, KOLTUN V. Guided policy search[C]// International Conference on Machine Learning. PMLR, 2013: 1–9.
- [23] SUN P, SUN X, HAN L, et al. Tstarbots: defeating the cheating level builtin AI in StarCraft II in the full game[EB/OL]. (2018–12–27)[2021–08–04]. <https://arxiv.org/abs/1809.07193.pdf>.
- [24] JADERBERG M, MNIH V, CZARNECKI W M, et al. Reinforcement learning with unsupervised auxiliary tasks[C]// International Conference on Learning Representations, 2017: 371–385.
- [25] ZAMBALDI V, RAPOSO D, SANTORO A, et al. Deep reinforcement learning with relational inductive biases[C]// International Conference on Learning Representations, 2018: 1125–1131.
- [26] VINYALS O, EWALDS T, BARTUNOV S, et al. Starcraft II: a new challenge for reinforcement learning[EB/OL]. (2017–08–16)[2021–08–04]. <https://arxiv.org/abs/1708.04782.pdf>.
- [27] 胡晓峰, 荣明. 关于联合作战规划系统的几个问题 [J]. 指挥与控制学报, 2017, 3(4): 273–280.
HU X F, RONG M. Problems about joint operation planning system[J]. Journal of Command and Control, 2018, 3(4): 273–280. (in Chinese)
- [28] 谢苏明, 毛万峰, 李杏. 关于作战筹划与作战任务规划 [J]. 指挥与控制学报, 2018, 3(4): 281–285.
XIE S M, MAO W F, LI X. About operational planning and operational mission planning[J]. Journal of Command and Control, 2018, 3(4): 281–285. (in Chinese)
- [29] 王飞跃, 刘玉超, 秦继荣, 等. C2M 和 5G: 新时代的智能指挥与控制 [J]. 指挥与控制学报, 2019, 5(2): 79–81.
WANG F Y, LIU Y C, QIN J R, et al. C2M and 5G: intelligent command and control in the connected and smart age [J]. Journal of Command and Control, 2019, 5(2): 79–81. (in Chinese)