

基于大语言模型的知识图谱逻辑规则挖掘框架及应用

程昊翔¹ 龚治兴² 王浩铭¹ 刘世旋¹ 张驭龙² 陈超¹ 范长俊^{1,*}

(1. 国防科技大学 系统工程学院 大数据与决策实验室, 长沙 410073; 2. 解放军31002部队, 北京 100091)

摘要 提出了一种基于大语言模型的知识图谱可解释规则挖掘框架,并探究了其军事应用。该框架包括规则采样、模型规则生成和规则验证3个步骤,利用大语言模型的自然语言处理能力,高效地产生大量逻辑规则。实验结果表明,该框架在大规模知识图谱YAGO上取得最优结果,提高了知识图谱补全任务的效果,验证了大语言模型在逻辑规则挖掘中的作用。

关键词 逻辑规则挖掘,大语言模型,知识图谱,武器装备发展预测,提示词微调,知识图谱补全

引用格式 程昊翔,龚治兴,王浩铭,等.基于大语言模型的知识图谱逻辑规则挖掘框架及应用[J].指挥与控制学报,2025,11(2):202-209

DOI 10.20278/j.jc2.2096-0204.2024.0134

A Logical Rule Mining Framework Based on Large Language Models and Its Applications

CHENG Haoxiang¹ GONG Zhixing² WANG Haoming¹ LIU Shixuan¹ ZHANG Yulong² CHEN Chao¹ FAN Changjun^{1,*}

(1. Laboratory for Big Data and Decision, College of Systems Engineering, National University of Defense Technology, Changsha 410073, China;

2. Unit 31002 of PLA, Beijing 100091, China)

Abstract An explanatory rule mining framework for knowledge graphs based on large language models, Gear-LLMs, is proposed and its military applications are explored. The framework, consisting of such three steps as rule sampling, model rule generation, and rule verification, the natural language processing capability of large language models is utilized to effectively produce a great number of logical rules. The experimental results show that Gear-LLMs achieves the optimal results on the large-scale knowledge graph YAGO and significantly enhances the effects of knowledge graph completion tasks, verifies the significant role of large language models in logical rule mining.

Key words logic rule mining, LLMs, knowledge graph, forecast of weapon and equipments development, prompt tuning, knowledge graph completion

Citation CHENG H X, GONG Z X, WANG H M, et al. A logical rule mining framework based on large language models and its applications[J]. Journal of Command and Control, 2025, 11(2): 202-209

在大数据时代,知识图谱作为知识表示与推理的核心工具,面临传统规则挖掘方法效率低、语义理解不足的挑战^[1]。大语言模型(large language models, LLMs)凭借对自然语言的深层解析能力,为知识图谱的逻辑规则挖掘提供了新路径。其优势在于通过语义关联快速提取隐含规则,显著提升大规模知识图谱的推理效率与准确性。在军事领域,分散的武器装备数据需通过知识图谱实现整合与标准化,以支撑态势分析与决策。LLMs的引入推动了指挥控制(command and control, C2)向集中化、智能化转型^[2],在多域协同中发挥关键作用。本研究拟融合LLMs的逻辑推理能力与知识图谱结构化数据,构建高效可解释的军事决策支持框架。该框架旨在快速

生成逻辑规则,增强装备发展预测能力,为复杂战场环境下的动态决策提供语义化支撑。

为系统梳理技术脉络,下文将分别分析逻辑规则挖掘、基于LLMs进行逻辑推理技术以及基于LLMs进行逻辑规则挖掘的研究现状,深度分析相关领域的研究进展和存在的问题。

逻辑规则挖掘在知识推理等领域应用广泛。然而,早期基于枚举的方法^[3-4],面对大规模知识图谱时效率较低。AMIE^[3]、RLogic^[5]和RLvRL^[6]等方法采样和剪枝策略提升了效率和泛化能力。

深度学习推动了神经符号融合的端到端规则推理研究。NTP^[7]使用可证明微分方法实现多跳推理。NeuralLP^[8]通过梯度优化同步参数学习和知识学习。强化学习^[9]、逻辑规则分解学习^[10]和概率预测^[11]等方法进一步扩展了技术路径。尽管这些模型关注知识图谱的结构信息,但对知识图谱的语义信息利用不足。

为了解决这一问题,研究者开始探索如何更有

收稿日期 2024-04-29 录用日期 2024-08-23

国家自然科学基金 NSFC(62206303)资助,湖南省科技创新计划(2023RC3009)资助

*通信作者简介 范长俊(1990—),男,安徽天长人,博士,副教授。

效地将语义信息融合到知识表示学习中,以提升规则推理的效果。KALE^[12]联合嵌入三元组和逻辑规则。RUGE^[13]通过规则矫正知识嵌入。IterE^[14]使用迭代训练策略,结合嵌入学习、公理归纳和公理注入等方法。尽管这些方法增强了语义关联,但是挖掘过程仍然缺乏可解释性。

综上所述,当前研究虽提升了规则挖掘效率并融合知识图谱的结构和语言信息,但推理方法可解释性不足的问题制约了其在军事等高风险领域的应用拓展。

随着人工智能发展,LLMs在可解释推理和复杂逻辑处理中展现出卓越能力^[15]。当前研究主要通过微调预训练模型^[16]适配具体任务,根据是否调整参数可分为参数高效微调(parameter-efficient fine-tuning, PEFT)与提示词(prompt tuning)微调两类。

PEFT通过优化模型内部参数提升任务性能。主要方法包括:前缀微调(prefix tuning, PT),自适应微调(adaptor tuning, AT),低秩适应微调(low-rank adaptation of large language models, LoRA)和位适应微调(BitFit)^[17]。此类方法通过在模型顶部添加新层或调整部分层权重实现参数更新,通常依赖有限标记数据进行训练。

提示词微调通过外部信息引导推理,不改变模型参数^[18]。其典型方法包括:零样本推理,指不输入样例直接引导模型进行推理^[19];少量样本推理,指通过少量样例引导模型进行推理^[20]以及规则路径推理^[21],指将解决问题的过程写入提示词中引导模型的推理。

当前研究聚焦求解路径推理方法创新。思维链^[22]、思维树^[23]和思维图^[24]利用不同数据结构表征中间推理过程,算法树^[25]和最少到最多提示^[26]通过问题分解策略处理复杂逻辑。这些方法在数学等需严格逻辑的领域成效显著,推动了基于提示词的推理技术发展。

基于LLMs的逻辑推理方法因高可解释性备受关注。Chatrule^[27]率先融合LLMs与知识图谱逻辑推理,取得较好效果。后续研究聚焦LLMs语义优势与知识图谱结构化数据的结合。有研究者采用零样本学习技术生成知识图谱对应的文本描述^[28]。LARK^[29]则通过语义解析将推理转化为上下文查询;LLM-ARK^[30]结合全文检索和知识图谱路径数据进行推理决策;KoPA^[31]整合知识图谱结构信息,实现结构感知推理;StructGPT^[32]采用迭代的阅读-再推理方法,通过结构化数据搜索完成推理任务;KG-GPT^[33]在StructGPT基础上改进,扩展推理范围至整个子图,提高推理性能。

综上所述,当前的逻辑规则挖掘方法通过整合

结构化与语义信息提升推理效能,但仍面临计算成本高、知识理解不充分等局限。因此,本文拟针对上述问题,提出一种基于LLMs进行知识图谱推理的框架(knowledge graph reasoning based on large language models, Gear-LLMs)。该框架可在少量样本提示下高效生成逻辑规则,平衡效率、成本与可解释性。下文将详述其实现机制。

1 Gear-LLMs 框架

Gear-LLMs主要分为3个部分。知识图谱采样、LLMs规则生成、规则的检验和排序,这个过程如图1所示。

1.1 知识图谱规则采样

利用LLMs解决专业领域知识需要相关内容的输入。因此,在知识图谱上进行采样,以获取逻辑规则的输入。

选择每个需要推理的关系,并从知识图谱中采样一定数量的三元组。在此基础上,以每个三元组的头实体为起点,采用宽度优先搜索策略进行游走。在游走过程中,检查当前节点与头节点之间是否存在关系。当游走到尾节点时,将获得的逻辑规则存储起来,从而得到关系实例。根据关系实例的出现频率进行总结,得到逻辑规则。该过程如图2所示。

图2展现了从锚点(e_1, e_2)出发,寻找可以解释关系 r 的规则的过程。在游走过程中检测到 e_3 与 e_1 存在相连关系,即

$$r_3 \leftarrow r_1 \wedge r_2$$

这是一条用于解释关系 r_3 的规则实例。搜索到终点 e_2 后整个搜索路径就是一条用于解释关系 r 的规则实例

$$r \leftarrow r_1 \wedge r_2 \wedge r_3$$

通过基于锚点的采样方法在保证获取目标规则的同时,提高了规则采样的效率。

得到了足够的规则实例后,按照出现的频率进行排序,出现频率高的实例即可被归纳为逻辑规则,用于下一步规则的生成。

1.2 LLMs规则生成

利用LLMs针对特定问题求解的关键在于确保LLMs能够全面理解相关领域的知识。因此,本框架采用提示词微调的方法向大型模型传递逻辑规则。

提示词主要包含3部分内容。背景信息,用于阐明任务的类型和逻辑规则的含义。逻辑规则示例,通过采样得到的逻辑规则,向模型传递知识图谱的内部结构^[34]。用户需求,用于向LLMs输入具体




图1 Gear-LLMs框架图

Fig. 1 The framework of Gear-LLMs




图2 游走过程示意图

Fig. 2 Schematic diagram of wandering process

的任务要求。一个实例输入输出如图3所示。

由于LLMs存在幻觉问题,因此,需要对得到的逻辑规则进行验证。由于不合法的关系可能是知识库中关系的近义关系,本文通过比较语义相似性。选择规则库中相似度最高且超过阈值的规则进行替换。替换在确保逻辑规则有效的同时充分利用了大型语言模型的语义理解能力。

1.3 规则检验

在知识图谱推理中,通常采用支持度、覆盖度和置信度等指标来评估逻辑规则的质量。通过基于这些指标值的排序和筛选,可以得到适用于下游任务的高质量规则。以下将详细介绍这些指标及其具体含义:

规则 ρ 的支持度可以定义为在知识图谱 H 中,满足规则 ρ 的三元组的数量:




图3 生成逻辑规则示例图

Fig. 3 An example diagram of generation of logic rules

$$\text{support}(\rho) = \#(e_x, e_y) : \rho_h(e_x, e_y) \wedge \rho_b(e_x, e_y) \quad (1)$$

其中, $\#$ 表示计数操作; (e_x, e_y) 是指以 e_x 为头实体以 e_y 为尾实体且通过任意实体关系连接的实体对; ρ_h 为规则头; ρ_b 为规则体,式(2)~式(4)中对应符号均表示相同含义。显然,高支持度的规则通常意味着它能够提供更 valuable 的信息。并且,如果某条规则的支持度为0,则应将其剔除。

规则 ρ 的覆盖度反映了规则体所蕴含的事实数量与知识图谱中所有事实数量的比率。覆盖度越高,说明规则体能够覆盖更多已知事实,从而可能发现更多潜在知识。

$$cov(\rho) = \frac{support(\rho)}{\#(e_x, e_y): \rho_h(e_x, e_y)} \quad (2)$$

规则 ρ 的置信度反映了规则头在规则体成立时出现的频率。它定义为满足规则头的事实数,除以满足规则体的所有事实数。置信度越高,说明规则体成立时,规则头也成立的情况越多,因此,规则质量越好。

$$conf(\rho) = \frac{support(\rho)}{\#(e_x, e_y): \rho_h(e_x, e_y)} \quad (3)$$

在实际知识图谱任务中,往往完全获得整个知识图谱的信息,因此,研究者提出了基于部分知识图谱的检验指标:基于部分完整假设(partial completion assumption, PCA)的置信度^[3]。基于PCA置信度是指满足规则头的事实数,除以知识图谱中已经搜索过的实体数量。

$$PCAconf(\rho) = \frac{support(\rho)}{\#(e_x, e_y): \rho_h(e_x, e_y)} (e_x, e_y) \in H^* \quad (4)$$

其中, H^* 表示知识图谱中已知的部分,相较于置信度,PCA置信度在实际应用中可以更好地衡量逻辑规则的效果。

1.4 知识图谱补全

知识图谱补全是自动预测并填充知识图谱中缺失的实体或关系的任务。由于现实世界中构建的知识图谱往往存在残缺,对知识图谱进行补全可以提高知识图谱的完整性,从而提高其应用价值。逻辑规则常被用于知识图谱补全,因此,本文采用知识图谱补全任务来检验Gear-LLMs的效果。

1.4.1 数据说明

选择3个常见的知识图谱进行实验。表1简要展示了3个知识图谱中实体、关系和三元组的数量。Family^[35]知识图谱描述了家族关系的联系,WN-18RR (WordNet-18 revised and reduced)^[36]表示语法

表1 数据说明
Table 1 Data description

实体	关系	三元组
Family	12	17 615
WN-18RR	11	40 963
YAGO	37	409 008

关系,YAGO (yet another great ontology)^[37]则包括地理、历史、文化等多方面知识。

此外,选择了知识图谱规则挖掘领域的3个经典模型AMIE, RLogic和NCRL与Gear-LLMs进行对比。

1.4.2 评价指标

本文通过模型预测结果位于前 k 位的比例 Hits@ k ,来衡量模型预测的准确性。采用Hits@1和Hits@10两个指标分别表示模型预测第一个结果正确和前十个结果中存在正确结果的概率。式(5)说明了Hits@ k 的计算方法。

$$Hits@k = \frac{1}{|S|} \sum_{i=1}^{|S|} I(\text{rank}_i \leq k) \quad (5)$$

此外,本文还使用平均倒数排名(mean reciprocal rank, MRR)指标衡量整体预测效果。MRR指所有测试三元组正确实体排名的倒数平均值,该指标更强调从整体观测预测的效果,强调了靠前排名的预测结果的重要性。

$$e_{MRR} = \frac{1}{|S|} \sum_{i=1}^{|S|} \frac{1}{\text{rank}_i} \quad (6)$$

其中, S 是测试集的三元组集合; $|S|$ 是集合中三元组的数量。 I 是指示函数,当预测正确的实体出现在前 k 个预测结果中时,函数值为1,否则为0, rank_i 表示第 i 个三元组的预测排名。

1.4.3 结果分析

表2中,加粗部分表示该指标中性能最好的结果。Gear-LLMs在大规模知识图谱YAGO中取得了最优的结果。相比之下,使用降维方法的AMIE无法处理超大规模的知识图谱。在Family数据集中,所有三元组均以符号的形式表示,其包含的语义信息较少。但是,Gear-LLMs仍然取得了和其他模型相近的效果,说明Gear-LLMs框架是将LLMs的语义理解能力和知识图谱的结果信息结合使用,而非仅利用语义挖掘规则。

在理论知识图谱上验证效果后,进行仿真实验,探究Gear-LLMs在武器装备发展情况预测任务中的效果。

2 仿真实验

2.1 数据来源与分析

本实验使用公开的武器装备数据集进行仿真实验。数据来源于利用爬虫获取的华成防务公司开发的墨子·未来指挥官军事推演软件数据库,环球军事网。经过预处理构造知识图谱,其中,包含9 529个实体和16个关系。实体主要包括各种型号的武器装

表2 实验结果
Table 2 Experiment results

模型	MRR			Hit@1			Hit@10		
	Family	WN-18RR	YAGO	Family	WN-18RR	YAGO	Family	WN-18RR	YAGO
AMIE	0.88	0.46	0.01	77.67	46.10	0.77	99.58	47.82	2.14
RLogic	0.88	0.46	0.36	81.30	44.45	25.33	97.20	53.81	51.40
NCRL	0.91	0.65	0.38	85.20	56.21	27.42	99.30	84.42	53.64
Gear-LLMs	0.87	0.52	0.41	80.50	43.24	32.40	98.05	67.20	57.25

备，武器装备的研发单位、装备的组成部分等信息。关系主要说明各个装备的隶属关系，零部件组成等内容。表3具体展示了5条三元组。

表3 示例三元组展示
Table 3 Display of example triplets

头实体	关系	尾实体
楔尾预警机	气动布局	后掠翼
6605、6610型扫雷艇	搭载	SK-2
YLC-4	极化类型	左旋圆极化
AS565黑豹运输机	属于	法国
SPS-95K	技术体制	频率捷变

为了更好地展示数据之间的联系，采用Neo4j进行数据可视化。展示部分数据如图4所示。

2.2 问题建模与求解

雷达极化类型参数对于提升雷达系统的性能至关重要。假设A国研发了一种新型雷达，B国拟利用先前掌握的情报和其他相关信息间接探测A国雷达的极化类型参数。对该问题建模求解，按照算法流程从知识图谱中挖掘逻辑规则，部分逻辑规则如表4所示。

表4中“inv_”表示原关系的逆向推理关系。例如，原三元组中雷达为头实体，尾实体为某种技术体制。则“inv_技术体制”表示由具体的技术体制推导雷达类型。

如果要探测雷达极化类型参数，最好同时知道雷达的PRI类型，技术体制和脉宽类型。如果只能探测到部分参数，则效果较差。将这些信息具体展示在知识图谱中如图5所示。从图5中可以直观感受到这些参数之间的复杂连接关系。




图4 部分知识图谱数据

Fig. 4 Partial knowledge graph data

表4 部分逻辑规则及其置信度
Table 4 Selected logic rules with corresponding confidence scores

规则头	规则体	主成分置信度
极化类型	PRI类型	0.244
	技术体制	0.258
	PRI类型, inv_技术体制, 脉宽类型	0.354
	天线扫描方式, inv_技术体制, PRI类型	0.401
	脉内调制类型	0.133

2.3 结果分析

进一步分析图5中的关系和实体可以发现，对




图5 雷达相关数据

Fig. 5 The related data of radar

于两个特定的雷达型号，它们的“极化方式”可以通过逻辑规则“脉内调制类型”“脉内调制类型，PRI类型”推导得出。图6展示了PRI类型和脉内调制两条关系与极化类型之间的关联，可以通过这两条关系推理得到极化类型。这对于一种新研发的雷达具有重要意义，即可以帮助军事指挥和决策人员快速推理该型装备的性能参数。




图6 参数推理图

Fig. 6 Diagram of parameter inference

为了进一步说明通过本框架得到的逻辑规则的合理性，本文利用所提出的框架挖掘了全部的16种关系所对应的逻辑规则，并将这些逻辑规则

用于知识图谱补全任务。同时进行消融实验，检验了去除LLMs后 Gear-LLMs 的效果，实验结果如图7所示。




图7 知识图谱补全结果

Fig. 7 Results of knowledge graph completion

可以看出，借助LLMs，推理的效果有了明显提高。相比于仅仅通过采样得到的规则，利用LLMs进行筛选的规则预测完全正确的概率，即Hits@1指标值，提高了0.164。MRR和Hits@10也分别提高了0.147和0.266，这说明LLMs的逻辑推理能力对知识图谱逻辑规则挖掘的效果有显著提升。

3 结论

本文利用LLMs在自然语言理解上的优势，提出

了一种基于大语言模型在知识图谱上挖掘关联关系的 Gear-LLMs 框架,并探究了其在军事知识图谱上进行武器装备发转预测的应用。本框架融合了少量的知识图谱规则路径作为大语言模型提示词,引导模型产生新的规则,经过排序和检验后,用于预测武器装备之间的关联关系。同时,利用知识图谱补全任务检验了整体效果,并通过消融实验说明了大语言模型在本框架中的重要作用。本文将大语言模型融入武器装备发展预测,充分利用了大语言模型自然语言处理能力强、知识库广的特点,为未来的军事问题求解探索了方向。

未来将针对现实情况下军事数据数量少,难以获取等特点,进一步探究如何利用大语言模型进行多步推理,充分利用现有数据,提高数据不足的情况下发现规则的能力。

References

- [1] 曹江,徐新海,尹峻松.军事智能时代的集成科学[J].指挥与控制学报,2023,9(1):3-5.
CAO J, XU X H, YIN J S. Integrated science in the era of military intelligence[J]. Journal of Command and Control, 2023, 9(1): 3-5. (in Chinese)
- [2] 阳东升,卢经纬,李强,等.超大预训练模型在指挥控制领域的应用与挑战[J].指挥与控制学报,2023,9(2):146-155.
YANG D S, LU J W, LI Q, et al. Issues and challenges of ChatGPT-like large scale pre-trained model for command and control[J]. Journal of Command and Control, 2023, 9(2): 146-155. (in Chinese)
- [3] GALÁRRAGA L A, TEFLIOUDI C, HOSE K, et al. AMIE: association rule mining under incomplete evidence in ontological knowledge bases[C]// International World Wide Web Conference, 2013: 413-422.
- [4] CHEN Y, GOLDBERG S, WANG D Z, et al. Ontological pathfinding[C]// ACM Conference on Management of Data, 2016: 835-846.
- [5] CHENG K, LIU J, WANG W, et al. Rlogic: recursive logical rule learning from knowledge graphs[C]// ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022: 179-189.
- [6] OMRAN P G, WANG K, WANG Z, et al. Scalable rule learning via learning representation[C]// International Joint Conference on Artificial Intelligence, 2018: 2149-2155.
- [7] ROCKTÄSCHEL T, RIEDEL S. End-to-end differentiable proving[C]// Neural Information Processing Systems, 2017: 3788-3800.
- [8] YANG F, YANG Z, COHEN W. Differentiable learning of logical rules for knowledge base reasoning[C]// Neural Information Processing Systems, 2017: 2319-2328.
- [9] LU S, LIU B, MILLS K G, et al. R5: Rule Discovery with reinforced and recurrent relational reasoning[C]// International Conference on Learning Representations, 2021.
- [10] CHENG K, AHMED N, SUN Y. Neural compositional rule learning for knowledge graph reasoning[C]// International Conference on Learning Representations, 2022.
- [11] QU M. RNNLogic: learning logic rules for reasoning on knowledge graphs[C]// International Conference on Learning Representations, 2021.
- [12] GUO S. Jointly embedding knowledge graphs and logical rules[C]// Conference on Empirical Methods in Natural Language Processing, 2016: 192-202.
- [13] CHENG K. Knowledge graph embedding with iterative guidance from soft rules[C]// AAAI Conference on Artificial Intelligence, 2018: 4816-4823.
- [14] ZHANG W, PAUDEL B, WANG L, et al. Iteratively learning embeddings and rules for knowledge graph reasoning[C]// International World Wide Web Conference, 2019: 2366-2377.
- [15] 潘雨黛,张玲玲,蔡忠闽.基于大规模语言模型的知识图谱可微规则抽取[J].计算机科学与探索,2023,17(10):2403-2412.
PAN Y D, ZHANG L L, CAI Z M. Differentiable rule extraction with large language model for knowledge graph reasoning[J]. Computer Science and Exploration, 2023, 17(10): 2403-2412. (in Chinese)
- [16] 王海峰,李纪为,王宇,等.预训练语言模型及其应用[J].Engineering,2023,25(6):51-65.
WANG H F, LI J W, WU H, et al. Pre-trained languages model[J]. Engineering, 2023, 25(6): 51-65. (in Chinese)
- [17] NING D, QIN Y J, YANG G, et al. Parameter-efficient fine-tuning of large-scale pre-trained language models[J]. Nature Machine Intelligence, 2023, 5(3): 220.
- [18] 官璐,何康,斗维红.微调大模型:个性化人机信息交互模式分析[J].新闻界,2023(11):44-51.
GUAN L, HE K, DOU W H. Fine-tuning large model: analysis

- sis of personalized human-machine information interaction mode[J]. Press Circles, 2023(11): 44-51. (in Chinese)
- [19] TAKESHI K, SHIXIANG S G, MACHEL R, et al. Large language models are zero-shot reasoners[C]// Conference on Neural Information Processing Systems, 2022.
- [20] BROWN T. Language models are few-shot learners[C]// Conference on Neural Information Processing Systems, 2020: 1877-1901.
- [21] 马瑞新, 李泽阳, 陈志奎, 等. 知识图谱推理研究综述 [J]. 计算机科学, 2022, 49(S01): 74-85.
MA R X, LI Z Y, CHEN Z K, et al. Review of reasoning on knowledge graph[J]. Computer Science, 2022, 49(S01): 74-85. (in Chinese)
- [22] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models [C]// Proceedings of the 36th International Conference on Neural Information Processing Systems, 2022: 24824-24837.
- [23] YAO S, YU D, ZHAO J, et al. Tree of thoughts: deliberate problem solving with large language models[C]// Proceedings of the 37th International Conference on Neural Information Processing Systems, 2023: 11809-11822.
- [24] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: solving elaborate problems with large language models[C]// Proceedings of the 38th AAAI Conference on Artificial Intelligence. AAAI Press, 2024: 17682-17690.
- [25] SEL B, AL-TAWAHA A, KHATTAR V, et al. Algorithm of thoughts: enhancing exploration of ideas in large language models[C]// Proceedings of the 41st International Conference on Machine Learning, 2024: 44136-44189.
- [26] ZHOU D. Least-to-most prompting enables complex reasoning in large language models[C]// International Conference on Learning Representations, 2023.
- [27] LUO L, JU J, XIONG B, et al. ChatRule: mining logical rules with large language models for knowledge graph reasoning [EB/OL]. (2023-09-04)[2023-10-12]. <https://arxiv.org/abs/2309.01538>.
- [28] AXELSSON A, SKANTZE G. Using large language models for zero-shot natural language generation from knowledge graphs[EB/OL]. (2023-07-14)[2023-10-20]. <https://arxiv.org/abs/2307.07312>.
- [29] CHOUDHARY N, REDDY C K. Complex logical reasoning over knowledge graphs using large language models[EB/OL]. (2023-05-02)[2023-10-20]. <https://arxiv.org/abs/2305.01157>.
- [30] HUANG Y. Evaluating and enhancing large language models for conversational reasoning on knowledge graphs[EB/OL]. (2023-12-18)[2024-01-10]. <https://arxiv.org/abs/2312.11282>.
- [31] ZHANG Y, CHEN Z, GUO L, et al. Making large language models perform better in knowledge graph completion[C]// Proceedings of the 32nd ACM International Conference on Multimedia (MM'24). Association for Computing Machinery, 2024: 233-242.
- [32] JIANG J, ZHOU K, DONG Z, et al. StructGPT: a general framework for large language model to reason over structured data[EB/OL]. (2023-05-16)[2024-01-10]. <https://arxiv.org/abs/2305.09645>.
- [33] KIM J, KWON Y, JO Y, et al. KG-GPT: a general framework for reasoning on knowledge graphs using large language models[EB/OL]. (2023-10-11)[2023-12-10]. <https://arxiv.org/abs/2310.11220>.
- [34] 翟社平, 张宇航, 柏晓夏. 融合实体邻域信息知识图谱嵌入负采样方法 [J]. 计算机工程, 2023, 49(3): 95-104.
ZHAI S P, ZHANG Y H, BO X X. Knowledge graph embedding negative sampling method integrating entity neighborhood information[J]. Computer Engineer, 2023, 49(3): 95-104. (in Chinese)
- [35] HINTON G E. Learning distributed representations of concepts[C]// Proceedings of the Eighth Annual Conference of the Cognitive Science Society, 1986: 12.
- [36] DETTMERS T, MINERVINI P, STENETORP P, et al. Convolutional 2D knowledge graph embeddings[C]// AAAI Conference on Artificial Intelligence, 2018: 32.
- [37] SUCHANEK F M, KASNECI G, WEIKUM G. Yago: a core of semantic knowledge[C]// International World Wide Web Conference, 2007: 697-706.