



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目： 基于杀伤链与大模型的时敏目标订单式打击研究
作者： 陈海，范长俊，孙博良，程杰，孔骏锋，袁雨辰
网络首发日期： 2026-05-12
引用格式： 陈海，范长俊，孙博良，程杰，孔骏锋，袁雨辰. 基于杀伤链与大模型的时敏目标订单式打击研究[J/OL]. 计算机科学.
<https://link.cnki.net/urlid/50.1075.TP.20260512.1419.006>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于杀伤链与大模型的时敏目标订单式打击研究

陈海 范长俊 孙博良 程杰 孔骏锋 袁雨辰

国防科技大学系统工程学院 长沙 410073

(chenhai_486@163.com)

摘要 针对时敏目标打击领域存在的传统优化方法建模僵化、决策过程不透明，以及深度强化学习方法样本需求大、奖励函数设计复杂、结果可靠性验证困难等挑战，提出一种订单式打击与大语言模型赋能的混合智能决策新方法。该方法构建了以动态“订单”为核心的火力资源自适应调度模型，并创新性地引入大语言模型作为战略顾问角色，形成 STIRA-LLM 与 KPSA-LLM 两大核心算法：前者利用大语言模型的逻辑推理能力加速复杂约束下的优化求解，后者则专注于生成符合战术逻辑的自然语言解释以提升决策可理解性。实验验证表明，该框架在多项关键指标上均取得显著提升，并能在大规模动态对抗环境中保持稳定高效的求解性能。同时，系统具备生成层次化、可审阅的战术意图与方案依据的能力，有效增强了人机协同的透明度与指挥信任。研究通过机理模型与认知智能融合，为智能化战争条件下实现高效、可靠且具有解释性的自适应决策提供了一条具有实践价值的技术途径。

关键词： 时敏目标；杀伤链；武器目标分配；大语言模型；决策智能；混合整数规划；人机协同

中图分类号 TP399

Order-Based, LLM-Augmented Kill-Chain for Time-Sensitive Target Engagement

CHEN Hai, FAN Chang-Jun, SUN Bo-Liang, CHENG Jie, KONG Jun-Feng and

Yuan Yu-Chen

College of Systems Engineering, National University of Defense Technology, Changsha, 410073

Abstract This paper proposes a hybrid intelligent decision-making method that integrates on-demand strike and large model empowerment to enhance the effectiveness of time-sensitive target strikes. The approach constructs an order-based fire strike model and introduces a large language model to act as a strategist, forming two core algorithms: STIRA-LLM and KPSA-LLM, which respectively achieve accelerated optimization solving and interpretable results. Experiments demonstrate that the proposed algorithm significantly outperforms pure optimization methods in terms of strike effectiveness, decision speed, and interpretability. It is well-suited for large scale dynamic adversarial environments and offers a new pathway for human-machine collaborative decision-making in intelligent warfare.

Keywords Time-sensitive target, Kill chain, Weapon-Target Assignment, Large Language Model, Decision intelligence, Mixed-Integer programming, Human-Machine collaboration

当前，DeepSeek、ChatGPT 等大语言模型（LLM）迅速发展，推动人工智能驱动决策范式向融合人类认知与机器计算的混合智能演进^[1]。这一变革在军事指挥控制领域尤为关键^[2-8]：现代战争日益智能化、信息化，战场环境高度复杂、不确定^[9]。时敏目标因其高时效、高价值与高威胁，已成为影响战局的核心要素^[10]。俄乌冲突中伊斯坎德尔导弹猎杀海马斯火箭炮的战例^[11]，便凸显了快速闭合杀伤链对打击时敏目标的决定性意义：从发现到打击的决策链条中，每一秒延迟都可能导致目标丧失^[12-14]。因此，构建兼具数学优化精度与战场态势理解能力的智能决策系统，已成为军事人工智能的前沿课题。

1 问题的提出

1.1 传统武器目标分配：理论基础与局限

武器目标分配问题自上世纪中期提出以来，一直是军事运筹学领域的经典研究对象^[15]。传统的火力打击资源分配模型，多基于组合优化理论框架，将打击任务抽象为在约束条件下寻求目标函数最优解的数学规划问题^[16-22]。这类方法通过精确的数学语言描述武器性能、目标特性、射程限制、弹药消耗等要素，并借助混合整数规划、动态规划等成熟算法寻求静态最优解。经过数十年的发展，相关理论体系日趋完善，在预设条件明确、战场态势相对稳定的场景中展现出较强的实用价值。

然而，当面对瞬息万变的现代战场态势时，这种基于数学规划的传统范式逐渐暴露出三个层

次的本质性局限。首先是建模层面的僵化性问题,传统模型严重依赖精确的数学公式来描述战场要素及其关系^[23],这种对形式化的极致追求使其难以有机融入指挥员的作战经验、战略意图以及来自战场文本情报^[24]。例如,指挥员基于长期作战经验对某类目标的风险评估,或是侦察报告中关于敌军可能采取机动规避行动的推断,这些难以量化但对决策至关重要的信息,在传统数学模型中往往被简化甚至忽略。

其次是决策过程不透明特性带来的信任危机。优化算法的求解过程对指挥员而言决策过程不透明,仅能看到输入参数与输出方案,却无法洞悉算法为何做出特定决策,这种不透明性在高风险的军事环境中尤为致命^[25-27]。当算法给出的方案与指挥员的直觉判断相左时,缺乏可理解性的决策建议很难获得采纳。

第三个局限体现在时效性维度。面对大规模、动态出现的时敏目标,纯优化算法面临计算复杂度的指数级增长。以混合整数规划为例,当决策变量规模达到数百甚至数千时,即使采用先进的求解器,计算时间也可能从秒级延伸至分钟甚至小时级别,这与时敏目标打击对分钟级乃至秒级决策的苛刻要求存在显著矛盾^[28-32]。俄军在冲突初期暴露出的杀伤链响应迟缓问题,正是这一局限性在实战中的真实写照^[33]。

这些局限性并非某个具体算法的缺陷,而是传统计算决策范式在面对复杂动态对抗环境时的系统性短板,从根本上呼唤着决策范式的革新^[34]。

1.2 订单式火力打击:作战模式的创新

近年来,随着网络中心战、马赛克战等新型作战理念的兴起,军事领域对分布式、敏捷化火力打击模式的探索不断深入。订单式火力打击作为一种新兴作战模式,凭借其在快速响应、灵活调度方面的显著优势,逐渐受到广泛关注^[35-39]。其核心理念在于将目标打击任务类比为商业领域的订单,使用动态派单、灵活响应的运作逻辑来组织作战活动,从而在杀伤链层面实现决策流程的优化与闭合速度的提升。

从机理上看,订单式火力打击的创新性体现在其对传统自上而下强制派单模式的突破。具体而言,该模式支持两种任务分配方式:一是“发单-申单-派单-做单”的自主竞标模式,允许打击节点根据自身状态主动申领任务;二是“发单-派单-做单”的强制派单模式,适用于需要集中指挥的紧急情况。

从杀伤链视角分析,订单式火力打击的核心价值在于通过流程重构实现决策环节的简化与加速。传统杀伤链模型往往将侦察、指控、打击严格划分为串行环节,信息需逐级上报、决策需逐层下达,这种层级化结构在面对时敏目标时不可避免地产生时延累积。订单式模式则通过赋予打击节点一定的自主决策权,使得侦察信息能够更

直接地转化为打击行动,在一定程度上实现了侦察、指控、决策的融合简化,从而显著加速杀伤链的整体运转速度。

这一作战方式的实战价值已在多个冲突中得到验证。在俄乌冲突中,乌克兰军队运用特种作战小分队,采用订单式作战方式,成功对俄军装甲目标实施了多次高效打击^[40]。其作战流程体现了典型的订单式特征:依托先进情报系统精准定位目标,借助任务规划软件快速匹配最优火力资源,就近分配给执行单位,完成打击后即时反馈效果,形成闭环管理。这一实践充分展示了订单式作战在减少资源浪费、提升灵活性与响应速度方面的突出优势,有力印证了其在现代高强度对抗环境中的实用价值。

但是,尽管订单式模式在机制设计层面具有明显优势,其有效实施仍依赖于底层的智能决策算法支撑。如何在“申单-派单”的双阶段决策框架下,既保证打击节点的自主方案质量,又确保指挥机构的全局优化效能,同时满足时敏目标的严苛时效要求,这些问题亟需新的技术手段来解决。

1.3 大模型赋能:计算决策到混合智能决策

面对传统优化方法与订单式作战需求,学术界与工程界进行了多方向探索。一种思路是深化运筹优化模型本身,例如通过引入分解协调技术、启发式算法等手段提升大规模问题的求解效率^[41]。另一种思路是探索智能算法的应用,如深度强化学习、多智能体协同等新兴技术。前者在一定程度上改善了计算性能,但未能从根本上解决建模僵化与可解释性缺失的问题;后者虽展现出一定的学习与适应能力,但面临奖励函数设计复杂、训练样本需求巨大、在高风险军事决策中可靠性验证困难等现实挑战,距离实战应用仍有较大距离^[42-45]。

大语言模型的突破性进展为解决上述难题开辟了全新路径。以 GPT 系列、DeepSeek 等为代表的大语言模型(LLM),通过在海量文本数据上的预训练,获得了跨领域的通用知识储备、强大的自然语言理解与生成能力,以及令人瞩目的涌现推理能力,特别是思维链推理能力的出现,使其具备了模拟人类决策思维过程的潜力。这些特性使大语言模型(LLM)有望成为连接人类指挥意图与机器计算能力的认知桥梁,推动军事决策从纯计算驱动向理解-推理-优化协同的混合智能范式演进。

具体而言,大语言模型(LLM)在时敏目标打击决策链条中可发挥多层次作用。在态势理解层面,大语言模型(LLM)能够快速解析来自无人机侦察报告、雷达信号摘要、电子侦察等多源异构的文本情报,提取结构化战场态势信息,并基于军事领域知识对目标进行初步优先级评估^[46]。这种能力突破了传统系统只能处理结构化数据的限制,为决策提供了更丰富的信息基础。

在决策方案生成层面, 大语言模型 (LLM) 可基于战场规则和历史案例知识, 为优化算法提供高质量的初始解或搜索启发信息^[47]。

在复杂博弈推演层面, 大语言模型 (LLM) 能够模拟对抗双方的战略思维^[48]。在分段决策场景中, 大语言模型 (LLM) 可基于当前态势推演敌方可能采取的反制措施, 从而辅助制定更具前瞻性和鲁棒性的打击策略。

更重要的是, 大语言模型 (LLM) 具备的自然语言交互能力^[49], 使其能够直接理解指挥员的高层意图并生成符合军事话语体系的决策建议, 这为实现真正意义上的人机协同决策创造了条件。

基于上述原因, 本文提出将大语言模型引入基于杀伤链的时敏目标订单式火力打击决策过程, 探索一种大语言模型 (LLM) 与运筹优化深度融合的混合智能决策方法, 以期在理论范式、算法设计与实战应用之间架起桥梁。

2 KTSOF-LLM 混合智能决策机理

2.1 总体架构

美国空军上校约翰·博伊德提出的 OODA 循环理论, 将作战过程抽象为观察 (Observe)、判断 (Orient)、决策 (Decide)、行动 (Act) 四个阶段的持续迭代^[41]。这一理论揭示了决策速度对作战效能的决定性影响。能够更快完成 OODA 循环的一方将在对抗中占据主动。然而, 传统的基于纯优化算法的决策系统在判断环节缺乏对战场态势的深层理解能力, 且决策输出缺乏可解释性, 这实质上阻碍了 OODA 循环的高效运转。

基于杀伤链的时敏目标订单式火力打击模型 (Kill-chain-based Time-sensitive Order-oriented Firestrike Model, KTSOF) 与大语言模型融合 (KTSOF-LLM) 的混合智能决策架构, 正是为了突破这一瓶颈而设计。该架构将决策流程重构为三个紧密耦合的层次, 形成“理解-推理-优化-解释”的闭环。

1) 态势感知与理解层, 作为整个决策系统的认知前端。该层接收来自多种侦察节点的异构数据, 包括光学侦察的图像、雷达的回波信号、电子侦察的频谱数据, 以及人工情报的文本报告等。大语言模型在此扮演态势理解员角色, 其核心任务是把这些碎片化、非结构化的原始情报转化为机器可处理的结构化战场态势摘要。这一过程实质上是将大语言模型 (LLM) 的语义理解能力注入传统的数据处理流程, 使系统获得了类似人类情报分析员的认知能力。

2) 混合智能决策层, 这是整个架构的核心创新所在。接收到结构化态势摘要后, 决策过程并非直接进入数学优化, 而是分为两条并行且相互影响的通路:

(1) 大语言模型 (LLM) 战略家通路: 基于态势摘要、内置的军事领域知识以及指挥员通过自然语言表达的高层意图, 进行思维链推理。其输出包括三类关键信息, 目标优先级的推荐调

整、基于战术原则的打击策略建议、以及高质量的初始分配方案。

(2) 运筹优化通路: 基于 KTSOF 模型的数学框架, 将打击问题精确形式化为带约束的优化问题。关键创新在于, 此时优化问题的参数设置、约束条件的松紧程度、以及求解的初始解, 都深度受到大语言模型 (LLM) 输出的影响。优化器在这一经过认知增强的数学框架内进行精确求解, 从而既保持了数学优化的严谨性, 又融入了战场态势理解的灵活性。

3) 方案生成与解释层, 将技术层面的决策结果转化为指挥员可理解、可信赖的作战方案。该层将优化器得出的最优数学解, 与大语言模型 (LLM) 在推理过程中生成的中间结论相结合, 生成双重输出: 一是可直接执行的打击方案 (包含详细的武器-目标分配、打击时序、资源调度等信息); 二是自然语言形式的解释报告。该报告以符合军事话语体系的方式, 向指挥员阐述方案的决策逻辑, 包括为何优先打击某些目标、为何选择特定武器、存在哪些潜在风险及应对措施等。

Final Decision Explanations Generated by LLM




图1 大语言模型生成的最终决策解释示例

Fig.1 Example of the final decision explanation generated by the large language model

整个架构的运作逻辑体现了对 OODA 循环的深化: 态势理解层对应增强的“观察-判断”, 混合决策层对应智能化的决策, 方案执行及解释层则连接行动并通过可解释性反馈加强判断。更重要的是, 通过引入大语言模型 (LLM) 的推理能力, 整个循环不再是机械的数据流动, 而是融入了类人的认知过程, 从而有望在决策质量与速度上同时取得突破。

2.2 KTSOF 模型的数学描述

基于杀伤链的时敏目标订单式火力打击模型 KTSOF 构成了本文混合智能方法的数学基础。该模型以 OODA 循环理论为指导, 将作战体系抽象为四类节点的网络化协同: 侦察节点集合 O 负责目标探测与跟踪, 指控节点集合 D 负责信息融合与决策制定, 打击节点集合 A 负责火力实施, 而时敏目标集合 T 则是作战的对象。模型的核心在于形式化描述杀伤链的闭合条件及优化目标。

从形式化角度, 模型通过三组决策矩阵刻画杀伤链各环节的资源分配: 侦察决策矩阵 X_o 表征侦察节点与目标的观测关系, 指控决策矩阵 X_d 描述指控节点的任务分配, 打击决策矩阵 X_a 则确定武器与目标的匹配。杀伤链的闭合要求这三个环节必须形成完整链路, 即对于任意待打击目标, 必须存在至少一条从侦察到指控再到打击

的畅通路程。这一逻辑通过通信矩阵 L 和指控矩阵 K 进行约束。用数学语言表达, 即对于目标 t , 只有当存在侦察节点 o 、指控节点 d 、打击节点 a , 使得 $x_o(o, t)=1, x_d(d, t)=1, x_a(a, t)=1$ 且 $x(o, d)=x(d, a)=x(d, o)=x(d, a)=1$ 时, 才构成一条可用的闭合杀伤链。

在指控中心规定的硬约束条件 C_{hard} 下 (包括武器射程物理限制、弹药库存上限、时敏目标的时间窗口要求、毁伤概率阈值等不可违背的刚性约束) 模型寻求最大化综合打击效能。该效能函数通常综合考虑目标价值 (摧毁高价值目标的收益)、毁伤效果 (考虑武器对目标的杀伤概率)、资源消耗 (弹药成本、平台损耗)。由此可得优化目标函数为

$$\max \sum w_j \cdot P_{kill(j)} - \lambda \cdot Cost \quad (1)$$

KTSOF 模型的核心在于引入订单式双阶段决策机制。传统武器目标分配问题通常是集中式的全局优化, 而 KTSOF 将其分解为申单与派单两个阶段。在申单阶段, 各打击节点基于局部可见的目标信息与自身状态, 自主规划可行的打击方案并上报; 在派单阶段, 指挥机构收集所有申单方案后, 在全局视角下进行优化选择, 确保每个目标打击任务仅被分配给一个打击节点, 同时最大化整体效能。

2.3 KTSOF-LLM 模型

在 KTSOF 数学框架的基础上, 引入大语言模型相关的形式化变量与函数, 构建了增强模型 KTSOF-LLM。

首先定义战场态势空间 S , 其包含所有侦察节点获取的原始异构数据。大语言模型 (LLM) 的第一个核心功能是学习一个态势理解映射 $f_{LLM}: S \rightarrow BSS$, 将原始态势空间映射为结构化的战场态势摘要 BSS (Battlefield Situation Summary)。该摘要采用预定义的数据结构, 包含目标列表、属性标注、威胁评级、上下文信息等字段。这一映射过程利用了大语言模型 (LLM) 在预训练阶段习得的军事领域知识与语义理解能力, 实质上是将非结构化的情报文本转化为机器可处理的语义表征。

接着定义大语言模型 (LLM) 的策略函数 $\Pi_{LLM}(BSS, I)$, 其输入为战场态势摘要 BSS 以及指挥员的自然语言指令 I , 输出三类决策增强信息。第一类是目标权重调整向量 w' , 用于修正优化目标函数中各目标的优先级系数。大语言模型 (LLM) 基于态势理解与指挥意图, 对某些目标 (如指挥所、防空系统) 赋予更高权重, 对另一些目标 (如疑似假目标) 降低权重, 这种动态调整使优化目标更贴近实战需求。第二类是软约束集合 C_{soft} , 用于补充传统硬约束。例如, 指挥员可能通过自然语言表达“优先使用远程火力”“避免在居民区附近打击”等战术偏好, 大语言模型 (LLM) 将这些偏好转化为数学形式的软约束加入优化模型。第三类是初始解或搜索启发信息 H_{init} , 大语言模型 (LLM) 通过思维链推理生成一个高潜力的打击方案草图, 并将其转化为优化问题的可行初始解。

经由 LLM 增强后, KTSOF-LLM 的优化目标函数修正为:

$$\max \sum w'_j \cdot P_{kill(j)} - \lambda \cdot Cost \quad (2)$$

约束条件上, 优化问题同时受到传统硬约束 C_{hard} (物理定律、资源上限) 和大语言模型 (LLM) 生成的软约束 C_{soft} (战术偏好、风险规避) 的双重约束, 形成刚柔并济的约束体系。求解过程中, 优化器从大语言模型 (LLM) 提供的高质量初始解 H_{init} 出发, 能够缩短搜索空间探索的时间。



图2 基于 OODA 循环的 KTSOF-LLM 模式

Fig.2 KTSOF-LLM Pattern Based on the OODA Loop

2.4 模型创新性分析

传统的决策模型主要建立在运筹优化基础之上, 其“数据-模型-结果”的范式在定义明确的静态场景中可求得数学最优解。然而, 该范式的封闭性使其难以吸纳指挥员经验、战略意图及战场文本情报等难以量化的先验知识, 导致其在瞬息万变的真实战场环境中适应性不足。针对这一根本性局限, 亟需实现从计算智能到混合智能的范式演进。

KTSOF-LLM 模型将决策流程重新架构为“理解-推理-优化-解释”的闭环。在这一范式中, 大语言模型扮演战略家角色, 其核心功能是作为连接人类定性认知与机器定量计算的桥梁。它通过自然语言理解解析战场态势与指挥意图, 并运用其思维链推理能力, 为后续的数学优化问题生成高质量的初始解与启发式策略。此举不仅显著提升了求解效率, 更在机理上融合了符号主义的逻辑严谨性与连接主义的语义理解能力, 使决策系统兼具人类的认知灵活性与机器的计算精度。

在范式创新的引导下, 模型进一步在方法架构层面引入了智能建模机制, 以克服传统优化模型因严格依赖数学公式而存在的固有刚性。具体而言, KTSOF-LLM 通过大语言模型 (LLM) 引入了语义层的动态调节能力。一方面, 模型将约束条件区分为必须满足的硬约束如物理定律与资源上限) 和可动态调整的软约束 (如战术偏好与风险容忍度), 大语言模型 (LLM) 能够根据实时态势灵活生成或调整这些软约束。另一方面, 优化目标函数中的关键参数 (如目标权重) 不再固定, 而是可由大语言模型 (LLM) 根据当前作战阶段与战略重心进行情境化校准。这种设计使得数学模型从静态的蓝图转变为具备动态响应能力的有机体, 从而获得了应对战场不确定性的内在适应性。

上述范式与架构的创新, 共同服务于人机协同效能的实质性提升。传统优化算法因其决策过程不透明特性, 决策过程不透明, 导致指挥员难以理解和信任。

KTSOF-LLM 模型的第三个创新点在于通过可解释性输出, 构建了可信透明的决策闭环。模型的输出不再仅限于最优解方案, 还融合了大语言模型 (LLM) 生成的自然语言解释报告。该报告能够清晰阐述方案的决策逻辑、多目标权衡过程及潜在风险, 将数学求解结果转化为符合军事常识的战术建议。这一机制极大地增强了指挥员对 AI 决策过程的认知与信任, 使人在回路的核心理念从原则性要求转化为可操作的实践, 确保了最终决策责任的明确性与人机协同的高效性, 为智能决策在高风险军事环境下的可靠应用奠定了坚实基础。

3 基于 KTSOF-LLM 的算法设计

3.1 STIRA-LLM 算法: 全局优化

时敏目标即时响应算法 (Sensitive Target Immediate Response Algorithm, STIRA) 基于混合整数规划 (MIP) 模型, 以全局最优为目标, 通过 Gurobi 求解器实现快速决策。其核心思想是通过数学建模将时敏目标打击问题转化为多约束优化问题, 在满足弹药储备、射程限制、时间窗口等约束条件下, 最大化综合打击效能。STIRA-LLM 算法则是在此基础上的增强版本, 其核心思想是利用大语言模型 (LLM) 加速和引导优化求解器, 适用于对打击效能要求极高、需要快速集中决策的场景。算法流程具体步骤如下:

- 1) 输入与态势解析: 输入实时战场数据 S (包含侦察节点上报的多源情报) 和指挥员通过自然语言表达的作战指令 I 。
- 2) 大语言模型 (LLM) 态势理解与初始规划: 调用 f_{LLM} 生成战场态势摘要 (Battlefield Situation Summary, BSS)。调用 $\Pi_{LLM}(BSS, I)$, 模拟人类参谋的决策思维: 首先分析战场态势特点, 识别出高价值目标、紧急目标等关键对象; 然后基于军事常识与战术原则, 获得调整后的目标权重 w' 、软约束 C_{soft} 和初始解建议 H_{init} 。关键步骤为大语言模型 (LLM) 进行思维链推理, 生成高潜力的打击方案草图, 并转化为优化问题的可行初始解 X_{init} 。
- 3) Gurobi 优化求解: 算法进入数学优化阶段, 将增强后的优化问题输入 Gurobi 求解器, 并将 X_{init} 设置为初始解。Gurobi 利用其分支定界等算法, 从这一高质量起点出发, 极大缩短寻找最优解的时间。
- 4) 输出与解释: 输出最优分配方案 X^* , 并融合大语言模型 (LLM) 之前的推理步骤, 生成最终的自然语言解释。




图 3 时敏目标即时响应算法 (STIRA-LLM) 流程图

Fig.3 Flowchart of the Time-Sensitive Target Instantaneous Response Algorithm (STIRA-LLM)

3.2 KPSA-LLM 算法: 分段博弈

KPSA (Kill-chain Phased-closure and Segmentation Algorithm, KPSA) 的核心思想是将时间窗口内的打击任务按照目标出现的时间序列分解为多个时间片段, 在每个片段内进行“申单-派单”决策, 从而将大规模问题分解为若干中小规模子问题。KPSA-LLM 则在此基础上, 通过引入大语言模型 (LLM) 的多阶段博弈推演能力, 使算法不仅能够分段处理, 还能在各段之间进行前瞻性的战略预判与动态调整。算法流程具体步骤如下:

- 1) 目标分段与首轮决策: 将时间窗口内出现的时敏目标按时间片段分段。对第一段目标, 采用类似 STIRA-LLM 的流程进行申单-派单决策。
- 2) 大语言模型 (LLM) 驱动的多阶段博弈推演: 关键创新点: 在每一段打击决策后, 将当前决策方案、己方资源消耗状态、以及敌方可能采取的反制措施作为提示词输入大语言模型 (LLM)。大语言模型 (LLM) 模拟扮演红方指挥员, 基于军事常识进行推理, 预测敌方在下一时间段的可能行动。根据推演结果, 大语言模型 (LLM) 对下一时间段的目标出现概率、位置分布进行动态修正, 并给出后续资源分配的建议。
- 3) 动态调整与闭环执行: 将大语言模型 (LLM) 的推演结果反馈给下一时间段的决策流程。指挥节点根据修正后的战场态势, 进行新一轮的申单-派单。




图4 杀伤链分段闭合算法 (KPSA-LLM) 流程图

Fig.4 Flowchart of the Kill chain Phased closure Segmentation Algorithm (KPSA-LLM)

4 实验与结果分析

4.1 实验设置

4.1.1 实验环境与数据集

实验环境配置如表 1 所示。大语言模型 (LLM) 通过调用 DeepSeek 的 API 接口实现, 该模型是国内领先的开源大语言模型 (LLM) 之一, 在中文理解与推理任务上表现良好, 同时支持较长的上下文窗口, 适合处理复杂的军事态势描述。

表 1 实验环境配置 Table 1 Experimental Environment Configuration	
类别	配置/参数
硬件环境	CPU: AMD Ryzen9 7945HX
内存	32.0 GB DDR4
软件环境	Python 3.9, Gurobi Optimizer 11.0.3
大语言模型	Deepseek-v3

数据集设计借鉴了俄乌冲突中伊斯坎德尔猎杀海马斯的典型战例, 模拟了从连级到旅级的不同作战规模。具体而言, 小规模场景 (S1) 包含 4 个武器单元和 8 个时敏目标, 模拟连级单元的遭遇战; 中规模场景 (S2) 扩展至 12 个武器单元和 30 个目标, 对应营级作战; 大规模场景 (S3) 则达到 40 个武器单元和 100 个目标, 模拟旅级全域对抗。

4.1.2 对比算法与评估指标

对比算法选择上, 为全面评估所提方法的性能优势, 本文设置了多组对比实验, 包含基于传统任务式指挥的贪婪求解方法作为基准 (Baseline), 同时纳入 STIRA 和 KPSA 两种传统优化算法、基于深度强化学习的武器目标分配算法 (DRL-WTA) 作为参照。具体对比算法包括:

- 1) 传统贪婪算法: 基于启发式规则的快速分配方法, 按照目标价值与武器效能的简单匹配进行分配;

- 2) DRL-WTA 算法: 基于深度强化学习的武器目标分配方法, 采用多智能体强化学习框架, 通过大量仿真训练学习最优分配策略;
- 3) 传统 STIRA 算法和 STIRA-LLM 算法: 分别代表纯数学优化方法与 LLM 增强的全局优化方法;
- 4) 传统 KPSA 算法和 KPSA-LLM 算法: 分别代表传统分段优化方法与 LLM 增强的分段博弈方法。

评估指标体系从四个维度构建, 以全面刻画算法的综合性能。第一个维度是总打击效能, 定义为所有被成功打击目标的加权价值之和, 综合考虑目标价值、毁伤概率等因素, 该指标直接反映作战任务的完成质量。第二个维度是总决策时间, 记录从接收战场数据到输出最终方案所需的计算时间, 衡量算法的时效性。第三个维度是总打击成本, 统计完成任务所消耗的弹药价值与平台损耗, 反映资源利用效率。第四个维度是未被覆盖时敏目标价值, 即因资源不足或时间窗口错过而未能打击的目标总价值, 该指标越低说明任务覆盖率越高。此外, 为量化大语言模型 (LLM) 的贡献, 实验定义 LLM 贡献度指标, 计算公式为

$$\text{贡献度} = \frac{\text{LLM增强算法性能} - \text{传统算法性能}}{\text{传统算法性能}} \quad (3)$$

结果以百分比形式表示大语言模型 (LLM) 带来的性能提升幅度。

4.1.3 大模型实现细节

为确保输出的稳定性与可控性, 对所有 LLM 调用采用统一的推理参数配置: 温度设置为 0.7 以平衡创造性与确定性, 最大 token 数设为 2000 以确保输出完整性。同时, 针对不同算法的决策需求设计了两类专业化的提示词模板。对于 STIRA-LLM 算法, 采用战场态势理解提示词, 引导 LLM 综合分析目标价值、空间分布、时间约束等多维因素, 输出每个目标的优先级权重 (1.0-2.0); 对于 KPSA-LLM 算法, 采用博弈对抗提示词, 引导 LLM 模拟敌方视角, 预测各目标的隐藏概率与调整后的优先级。两类提示词均采用结构化设计, 明确要求 LLM 以 JSON 格式输出, 并通过系统角色设定 (“You are a military tactical AI assistant”) 激发模型的专业化推理能力。



图5 使用大语言模型 (LLM) 示意图

Fig.5 Schematic Diagram Using the Large Language Model (LLM)

4.2 结果与分析

4.2.1 整体性能对比

从打击效能这一核心指标看, STIRA-LLM 算法在小、中、大三个规模数据集上分别达到 7658、37003、99251 的效能值, 相比传统 STIRA 算法分别提升 26.3%、23.1%和 5.7%, 平均提升幅度达到 18.4%。KPSA-LLM 算法同样表现优异, 在三个数据集上的效能分别为 5514、33101、100139, 相比传统 KPSA 算法提升 5.7%、5.9%和 3.6%, 平均提升 5.1%。与 DRL-WTA 算法相比, STIRA-LLM 和 KPSA-LLM 在打击效能上分别高出 32.5%和 28.7%, 这主要归因于 LLM 增强方法能够更好地融入战场态势理解和战术知识, 而 DRL 方法受限于训练样本的覆盖度和奖励函数设计的局限性。

更为关键的是, LLM 增强算法在所有测试场景中均实现了目标完全覆盖, 而传统方法在 S1 场景中遗漏了价值 777 的目标, 在 S2 场景中遗漏了价值 828 的目标, 在 S3 场景中遗漏了价值 504 的目标。DRL-WTA 算法虽然在训练场景中表现良好, 但在面对与训练数据分布不同的测试场景时, 目标覆盖率显著下降, 遗漏目标价值平均达到 1250。这一结果表明, LLM 的态势理解与优先级调整能力, 有效提升了资源分配的合理性, 避免了高价值目标的遗漏。

在决策时间方面, LLM 增强算法相比传统算法有显著增加, 这主要源于 API 调用的网络延迟。STIRA-LLM 的决策时间从传统 STIRA 的 0.01 秒增至 7.07-12.56 秒, KPSA-LLM 从 0.0006-0.0037 秒增至 15.95-92.69 秒。DRL-WTA 算法的推理时间为 0.05-0.15 秒, 虽然快于 LLM 方法, 但其训练时间成本极高 (通常需要数万次仿真迭代, 耗时数天至数周), 且难以快速适应新的战场态势变化。LLM 方法的时间成本在当前的云端 API 调用模式下不可避免, 但仍在实战可接受范围内 (秒级响应)。此外, KPSA-LLM 的时间开销显著高于 STIRA-LLM, 因为 KPSA-LLM 在每个阶段都进行 LLM 调用 (共 3 次), 而 STIRA-LLM 仅调用 1 次。这一差异凸显了算法设计的权衡: STIRA-LLM 追求单次全局优化的效率, KPSA-LLM 追求多阶段适应的鲁棒性。未来通过本地化部署轻量级 LLM 或采用异步调用机制, 可进一步降低时间开销。

从成本控制角度, LLM 增强算法展现出更优的资源利用效率。在大规模 S3 场景中, STIRA-LLM 的打击成本为 26900, 低于传统 STIRA 的 27588 (降低 2.5%); KPSA-LLM 的成本为 24972, 低于传统 KPSA 的 27254 (降低 8.4%)。DRL-WTA 算法的打击成本为 29350, 明显高于 LLM 增强方法, 这反映了 DRL 方法在资源分配优化上的不足。




图 6 (a) 总打击效能对比图 (电子版为彩图)

Fig.6(a) Overall Strike Effectiveness Comparison Chart (in color for the electronic version)




图 6 (b) 总决策时间对比图 (电子版为彩图)

Fig.6 (b) Overall Decision Time Comparison Chart (in color for the electronic version)




图 6 (c) 总打击成本对比图 (电子版为彩图)

Fig.6 (c) Overall Strike Cost Comparison Chart (in color for the electronic version)




图 6 (d) 未被覆盖时敏目标价值对比图 (电子版为彩图)

Fig.6 (d) Uncovered Time-Sensitive Target Value Comparison Chart (in color for the electronic version).

值得关注的是算法在不同规模下的表现差异。在小规模 S1 场景中, STIRA-LLM 凭借全局优化优势取得了最高效能 7658, 显著领先于 KPSA-LLM 的 5514 (提升 38.8%), 说明当问题规模

可控时，集中式全局优化仍是最佳选择。但随着规模扩大至 S3，KPSA-LLM 不仅成功求解，还取得了略高于 STIRA-LLM 的效能（100139 vs 99251），同时在成本控制上表现更优。DRL-WTA 算法在大规模场景中遇到了维度灾难问题，决策质量显著下降。

STIRA-LLM：优势在于求解质量和速度。通过大语言模型（LLM）提供高质量初始解，可将 Gurobi 的求解时间降低一个数量级，同时保证解的（近似）最优性。其决策中心化程度较高，适用于通信畅通、信息完整的联合打击任务。

KPSA-LLM：优势在于可扩展性和鲁棒性。通过分阶段处理和引入大语言模型（LLM）博弈推演，有效降低了计算复杂度，并能适应敌方的动态反制。其决策更具分布式和适应性特点，适用于通信受限、高度对抗的复杂战场环境。




图7 LLM在四个评估指标中对于算法的贡献度

Fig.7 Contribution of LLM to the Algorithm across Four Evaluation Metrics

两种算法并非互斥，而是可根据战场态势动态选择或组合使用，为指挥员提供灵活、智能的决策工具。

4.2.2 可解释性案例分析

可解释性是 LLM 增强算法区别于传统方法的核心优势之一^[50]。为具体展示这一能力，分析 S1 场景中的一个典型决策实例。在该场景中，侦察节点同时发现两个目标：目标 T1 位于坐标（4.2， 3.1），初步判定为海马斯火箭炮系统（高价值真目标），具有明显的机动特征；目标 T2 位于坐标（2.8， 5.6），疑似为指挥车辆（中等价值），但电磁信号特征与已知真实目标存在偏差。武器单元包括一辆伊斯坎德尔导弹发射车（精确打击能力强但成本高）与两门自行火炮（成本低但精度有限）。

传统 STIRA 算法的输出仅包含数值化的分配方案：将伊斯坎德尔导弹分配给 T1，将火炮分配给 T2，预期总效能为 1523。这一方案虽然在数学上最优，但指挥员无从得知算法为何做出这样的选择，当战场态势紧张时，这种决策过程不透明输出难以获得信任。DRL-WTA 算法同样存在可解释性不足的问题，其决策依赖于神经网络的隐层表示，难以提供清晰的决策依据。

STIRA-LLM 算法则在给出相同分配方案的同时，生成了详细的推理解释报告：

“经态势分析，目标 T2 的电磁信号特征（大语言模型（LLM）假设频率 1.2GHz，脉冲重复频率 300Hz）与真实‘海马斯’系统的已知特征（大语言模型（LLM）假设频率 1.5GHz，PRF 500Hz）存在显著偏差，结合其静止状态，判定为疑似诱饵目标，优先级下调 25%。目标 T1 展现出典型的机动规避行为（速度 12km/h，方向多次变化），且位于开阔地形，判定为高价值真实目标，优先级上调 30%。基于上述分析，将高价值精确制导武器（伊斯坎德尔）优先分配给 T1 以确保摧毁，对 T2 采用成本较低的火炮实施牵制性打击。该方案预期可摧毁 1 个高价值目标，压制 1 个中等价值目标，总效能 1523，弹药消耗 185 单位，风险等级：低。”

4.2.3 大语言模型（LLM）贡献度的消融实验

为深入理解大语言模型（LLM）在混合智能算法中的作用机理，实验进一步对 LLM 的贡献进行了量化拆解。通过控制变量法，分别测试了“仅使用 LLM 态势理解”、“仅使用 LLM 初始解加速”、“仅使用 LLM 权重调整”以及“LLM 全功能”四种配置下的性能，以识别各项能力的相对重要性。




图8 消融实验结果

Fig.8 Ablation Study Results

结果显示，态势理解是效能提升的主要来源，仅大语言模型（LLM）态势理解单独使用时即带来 7.3% 的效能提升，贡献了全功能版本约 40% 的增益。这验证了大语言模型（LLM）在目标优先级识别上通过理解高价值目标优先打击等军事常识，大语言模型（LLM）能够有效引导优化算法聚焦关键目标。同时，态势理解在覆盖率改进上表现最突出（60.0%），显著降低了目标遗漏风险。成本增加的原因在于大语言模型（LLM）提升了高价值目标的优先级，导致系统倾向于为这些目标分配成本更高的精确制导武器。这一代价在追求最大效能的场景中是可接受的，但在成本敏感场景中需要权衡。

初始解加速兼顾效率与经济性，虽然效能提升最小，但在时间开销（3.3 秒）和成本控制（+2.3%）上表现最优。这一结果表明，大语言模型（LLM）生成的初始解能够有效减少优化器的搜索空间，加速收敛，且不会显著增加资源消耗。

相比之下，权重调整提供平衡的综合性能。其在效能（+6.4%）、时间（5.3 秒）、成本（+5.0%）、覆盖（+50.0%）四个维度上均处于中等水平。

4.3 讨论

实验结果表明, 大语言模型 (LLM) 赋能的智能决策在面向时敏目标订单式打击的杀伤链快速闭合方面具有:

1) 有效性: 融合大语言模型 (LLM) 的混合智能算法在打击效能、决策效率上均优于或相当于传统优化方法, 传统算法仅输出分配方案, 而 LLM 混合智能算法提供完整的决策链条, 包括目标优先级判定依据、资源分配理由和风险应对策略。这种透明化决策过程显著增强了人机协同的信任基础。

2) 场景依赖性: 实验揭示了两种 LLM 增强算法的明显场景适应性差异。STIRA-LLM 在中小规模、信息较完整、对效能要求极高的场景中表现最佳, 其全局优化特性能够充分发挥。典型应用场景包括: 对敌方指挥中枢的精确斩首打击、关键节点的定点清除、高价值目标的集中火力突击等。KPSA-LLM 则在大规模、目标动态分批出现、对抗激烈的场景中更具优势。典型应用场景包括: 大规模防空压制任务、持续数小时的火力打击战役、区域拒止作战中的动态目标打击等。更进一步, 两种算法可根据战场态势动态切换: 作战初期使用 STIRA-LLM 进行精确规划, 随着态势复杂化切换至 KPSA-LLM 进行适应性调整。这种灵活性是混合智能方法相比单一算法的独特优势。

3) 局限性: 当前实验依赖的 API 存在响应延迟和成本问题, 在实战中可能面临通信中断或经济可持续性问题。解决方向包括: 部署轻量化的本地大语言模型 (LLM) (如经过剪枝量化的领域专用模型)、设计模型缓存机制以减少重复调用、探索边缘计算架构等。此外, 由于难以获取精准确定的公开军事资料, 大语言模型 (LLM) 的军事领域知识也有待深化, 未来研究应聚焦于轻量化模型部署、领域自适应训练等方向。

5 总结与展望

5.1 研究总结

本文针对信息化战争中时敏目标打击的决策难题, 立足于杀伤链快速闭合的需求, 深入剖析了传统纯优化方法的局限性。为应对挑战, 开展了一项探索性研究: 将大语言模型这一前沿人工智能技术引入军事决策回路。主要工作总结如下:

1) 提出了大语言模型 (LLM) 赋能的混合智能决策新范式: 构建了 KTSOF-LLM 模型, 将大语言模型定位为战略家, 使其与运筹优化模型协同工作, 实现了从计算决策到“理解-推理-优化”范式的转变。

2) 设计并实现了两种混合智能算法: 针对不同作战场景, 设计了 STIRA-LLM 和 KPSA-LLM 算法。前者通过大语言模型 (LLM) 加速优化求解, 兼顾效能与速度; 后者利用大语言模型 (LLM) 进行博弈推演, 提升大规模动态环境的适应性与鲁棒性。

3) 验证了方法的有效性与优越性: 通过多粒度仿真实验证明, 所提方法不仅在传统性能指标上表现优异, 更在可解释性、抗干扰能力等

指标上取得突破, 为指挥员提供了更可信、更智能的决策支持。

5.2 未来展望

本研究仍处于探索阶段, 未来工作可从以下几个方向深入:

1) 模型优化与领域适配: 当前使用的通用大语言模型 (LLM) 虽然具备广泛知识, 但在军事专业领域的深度与准确性仍有提升空间^[51]。未来应收集军事领域的专业文本、历史战例、作战条令、装备手册等数据, 对开源大语言模型 (LLM) 进行领域自适应训练, 包括持续预训练以注入领域知识、指令微调以增强任务执行能力、基于人类反馈的强化学习以形成军事决策价值观。最终目标是打造专属的军事参谋大语言模型, 使其在战场态势理解、战术原则应用、博弈推演准确性等方面达到专业水准。同时, 应探索轻量化模型技术, 通过剪枝、量化、蒸馏等手段, 将大语言模型 (LLM) 压缩至可在边缘设备部署的规模, 以解决 API 调用延迟与通信依赖问题, 满足实战环境下的离线运行需求。

2) 算法深度融合: 一个有前景的方向是将大语言模型 (LLM) 与强化学习相结合: 利用大语言模型 (LLM) 的常识推理能力辅助强化学习的探索过程, 例如通过大语言模型 (LLM) 预测高价值的状态-动作对以引导探索, 或利用大语言模型 (LLM) 生成合理的奖励函数以减轻人工设计负担。另一方向是多智能体强化学习与大语言模型 (LLM) 的协同, 在大规模分布式决策场景中, 各智能体可通过大语言模型 (LLM) 进行自然语言通信与协调, 提升协同效率。此外, 还可探索大语言模型 (LLM) 与大数据、跨媒体的结合, 利用大语言模型 (LLM) 的知识指导算法的搜索方向^[52]。这些深度融合方案有望进一步释放混合智能的潜力。

3) 跨域协同作战应用: 现代战争日益呈现多域联合特征, 涉及陆、海、空、天、电、网等多个作战域的协同。未来研究可探索: 如何利用大语言模型 (LLM) 理解与规划跨域杀伤链, 例如卫星侦察-空中指挥-海上打击-陆基评估的跨域协同; 如何在电磁频谱管理、网络攻防等新型作战领域应用混合智能决策; 如何在无人系统集群作战中, 利用大语言模型 (LLM) 实现集群的自主协同与任务分配。

4) 人机交互与实战验证: 当前研究主要基于仿真实验, 缺乏真实指挥员参与的验证。未来在推演中, 真实指挥员可通过自然语言与系统交互, 提出作战意图、质疑 AI 方案、调整决策参数, 系统则实时响应并解释调整理由。最终目标是通过实兵演习等方式, 在真实对抗环境中验证混合智能决策方法的实战价值, 推动其从实验室走向战场。

结束语

大语言模型 (LLM) 为决策智能带来了革命性机遇, 本文研究表明, 将其与经典运筹优化方法深度融合, 是构建下一代智能化指挥信息系统的一条有效路径。随着大语言模型 (LLM) 技术的不断成熟、军事领域数据的逐步积累、以及理论方法的持续深化, 这种混合智能决策模式有

望在未来战场上成为提升作战效能、加速杀伤链闭合、实现人机协同的关键力量。从更宏观的视角看,这也是人工智能从感知智能、认知智能向决策智能演进的重要实践,为探索通用人工智能在复杂决策任务中的应用积累了宝贵经验。未来的智能化战争,将不再是人与机器的简单分工,而是人的战略智慧与机器的计算能力深度融合的协同博弈。

参考文献

- Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//Advances in Neural Information Processing Systems, 2022, 35: 24824-24837.
- Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems, 2017: 5998-6008.
- Huang W, Xia F, Xiao T, et al. A survey on large language models for automated planning[J]. arXiv preprint arXiv:2502.12435, 2025.
- Song Y, Katz B, Srivastava S. On the prospects of incorporating large language models (LLMs) in automated planning and scheduling[J]. arXiv preprint arXiv:2401.02500, 2024.
- Wang L, Ma C, Feng X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.
- Qin L, Wu W, Liu D, et al. Autonomous Planning and Processing Framework for Complex Tasks Based on Large Language Models[J]. Acta Automatica Sinica, 2024, 50(5): 916-929.
- Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.
- Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems, 2022, 35: 27730-27744.
- Yao S, Zhao J, Yu D, et al. ReAct: Synergizing reasoning and acting in language models[C]//International Conference on Learning Representations, 2023.
- Zhou D, Schärli N, Hou L, et al. Least-to-most prompting enables complex reasoning in large language models[C]//International Conference on Learning Representations, 2023.
- Zhao G H, Rao Y, Liu P T. Operational Management of Kill Chain for Time-Sensitive Target Strike from the Perspective of Iskander Hunting HIMARS[J]. Journal of Command and Control, 2025, 11(5): 529-539.
- Liu P, Yuan W, Fu J, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. ACM Computing Surveys, 2023, 55(9): 1-35.
- Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners[C]//Advances in Neural Information Processing Systems, 2022, 35: 22199-22213.
- Jiao P B, Gong Z X, Luo Z H, et al. Applications and Considerations of Large Models in Force Recommendation[J]. Journal of Command and Control, 2025, 11(2): 137-145.
- Manne A S. A target-assignment problem[J]. Operations Research, 1958, 6(3): 346-351.
- Ahuja R K, Kumar A, Jha K C, et al. Exact and heuristic algorithms for the weapon-target assignment problem[J]. Operations Research, 2007, 55(6): 1136-1146.
- Kline A, Ahner D, Hill R. The weapon-target assignment problem[J]. Computers & Operations Research, 2019, 105: 226-236.
- Li X, Zhou D, Pan Q, et al. Weapon-target assignment problem by multiobjective evolutionary algorithm based on decomposition[J]. Complexity, 2018, 2018: 8623051.
- Bogdanowicz Z R, Tolano A, Patel K, et al. Optimization of weapon-target pairings based on kill probabilities[J]. IEEE Transactions on Cybernetics, 2013, 43(6): 1835-1844.
- Wang C, Fu G, Zhang D, et al. Solving the dynamic weapon target assignment problem by an improved multiobjective particle swarm optimization algorithm[J]. Applied Sciences, 2021, 11(19): 9254.
- Sonuc E, Sen B, Bayir S. A parallel simulated annealing algorithm for weapon-target assignment problem[J]. International Journal of Advanced Computer Science and Applications, 2017, 8(4): 87-92.

- 22 Lloyd S P, Witsenhausen H S. Weapons allocation is NP-complete[C]//Proceedings of the 1986 Summer Computer Simulation Conference, 1986: 1054-1058.
- 23 Li Q, Zhang H, Wang Y. Research Progress on Weapon-Target Assignment: Models, Algorithms and Applications[J]. Systems Engineering and Electronics, 2022, 44(6): 1909-1920.
- 24 Karasakal O. Air defense missile-target allocation models for a naval task group[J]. Computers & Operations Research, 2008, 35 (6) : 1759-1770.
- 25 Schick T, Schütze H. Exploiting cloze-questions for few-shot text classification and natural language inference[C]//Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics, 2021: 255-269.
- 26 Zhao G H. Revisiting the Operational Management System through the Application of Kill Chain in the Russia-Ukraine Conflict[J]. Tactical Missile Technology, 2022(4): 116-125.
- 27 Salmeron J, Wood R K, Baldick R. Worst-case interdiction analysis of large-scale electric power grids[J]. IEEE Transactions on Power Systems, 2009, 24 (1) : 96-104.
- 28 Fulghum D A, Wall R, Butler A. Compressing the kill chain[J]. Aviation Week & Space Technology, 2003, 158 (10) : 52-59.
- 29 Grant T J, Cheatham J B, Truszkowski W F. Autonomy in joint strike operations[J]. Johns Hopkins APL Technical Digest, 2000, 21 (4) : 572-579.
- 30 Dockery J T, Woodcock A E. The military landscape: Mathematical models of combat[M]. Woodhead Publishing, 1993.
- 31 Huber R K, Niemeyer J. Modeling and analysis for defense[M]. Springer Science & Business Media, 2012.
- 32 Peng Y, Wang Y, Song Y. A multi-objective memetic algorithm for time-dependent vehicle routing problem with time windows[J]. IEEE Access, 2020, 8: 44619-44631.
- 33 Li Q, Wang F Y. Conceptual Analysis of Mosaic Warfare and Research on Future Land Battlefield Network-Information System and Intelligent Countermeasures[J]. Journal of Command and Control, 2020, 6(2): 87-93.
- 34 Keane J, Carr S. A brief history of early unmanned aircraft[J]. Johns Hopkins APL Technical Digest, 2013, 32 (3) : 558-571.
- 35 Wolsey L A. Integer programming[M]. John Wiley & Sons, 2020.
- 36 Bixby R E. A brief history of linear and mixed-integer programming computation[J]. Documenta Mathematica, 2012, 2012: 107-121.
- 37 Achterberg T. SCIP: Solving constraint integer programs[J]. Mathematical Programming Computation, 2009, 1 (1) : 1-41.
- 38 Land A H, Doig A G. An automatic method for solving discrete programming problems[J]. Econometrica, 1960, 28 (3) : 497-520.
- 39 Gurobi Optimization LLC. Gurobi optimizer reference manual[R]. 2023.
- 40 Nemhauser G L, Wolsey L A. Integer programming and combinatorial optimization[M]. Wiley, 1988.
- 41 Bryant D J. Rethinking OODA: Toward a modern cognitive framework of command decision making[J]. Military Psychology, 2006, 18 (3) : 183-206.
- 42 Gunning D, Stefik M, Choi J, et al. XAI—Explainable artificial intelligence[J]. Science Robotics, 2019, 4 (37) : eaay7120.
- 43 Adadi A, Berrada M. Peeking inside the black-box: A survey on explainable artificial intelligence (XAI) [J]. IEEE Access, 2018, 6: 52138-52160.
- 44 Shneiderman B. Human-centered artificial intelligence: Reliable, safe & trustworthy[J]. International Journal of Human-Computer Interaction, 2020, 36 (6) : 495-504.
- 45 Wang F Y. Parallel Intelligence Theory and Parallel Systems Methodology[J]. Chinese Journal of Intelligent Science and Technology, 2019, 1(1): 1-8.
- 46 Boulanin V, Verbruggen M. Mapping the development of autonomy in weapon systems[R]. St

ockholm International Peace Research Institute, 2017.

- 47 Scharre P. Army of none: Autonomous weapons and the future of war[M]. WW Norton & Company, 2018.
- 48 Work R O, Brimley S. 20YY: Preparing for war in the robotic age[R]. Center for a New American Security, 2014.
- 49 Morgan F E, Boudreaux B, Lohn A J, et al. Military applications of artificial intelligence: Ethical concerns in an uncertain world[R]. RAND Corporation, 2020.
- 50 Sayler K M. Artificial intelligence and national security[R]. Congressional Research Service, 2020.
- 51 Wang F. Y, Wang X, Yuan Y. Artificial Intelligence and Intelligent Manufacturing[J]. Science China Information Sciences, 2018, 48(1): 80-90.
- 52 Li D Y. Advancing to Artificial Intelligence 2.0 [J]. Science and Technology Review, 2016, 34(3): 6.

CHEN Hai, born in 2003, is a CCF Student Member (A33752G) at the National University of Defense Technology. His research primarily focuses on complex networks, and kill chains & time-sensitive targets.



FAN Chang-Jun, born in 1990, is an associate professor with a Ph.D. at the College of Systems Engineering, National University of Defense Technology. His research focuses on intelligent planning and decision-making.

陈海，出生于 2003 年，国防科技大学系统工程学院，硕士，CCF 学生会员（A33752G），主要研究方向为机器学习与运筹优化。

范长俊，出生于 1990 年，国防科大系统工程学院，博士，副教授，研究领域：智能规划与决策。

孙博良，出生于 1986 年，国防科大系统工程学院，博士，副研究员，研究领域：指挥控制、大数据、机器学习、人工智能。

程杰，出生于 2001 年，国防科技大学系统工程学院，硕士，主要研究方向为机器学习与运筹优化。

孔骏锋，出生于 2002 年，国防科技大学系统工程学院，硕士，主要研究方向为机器学习与组合优化。

袁雨辰，出生于 2002 年，国防科技大学系统工程学院，硕士，主要研究方向为机器学习与组合优化。

